

## 2024华为：eCPM优化利器，AIE框架提升广告CTR预测精度



SmartMindAI

专注搜索、广告、推荐、大模型和人工智能最新技术，欢迎关注我

已关注

18 人赞同了该文章


收起

### Introduction


**点击率<sup>+</sup> (CTR)** 预测在在线广告系统中非常重要，因为它直接影响用户满意度和公司收入。CTR 是指广告展示时用户点击广告的概率，广告商提交每次点击成本 (CPC) 出价，表示他们愿意为每次点击支付的金额。广告平台通常结合预测点击率 (pCTR) 和CPC出价来计算有效千次展示成本 (eCPM)，用于排名和最大化预期收益。

然而，在线广告系统中的复杂拍卖环境对CTR预测提出了巨大挑战。首先，eCPM排名标准由 pCTR和CPC出价决定，这意味着CPC出价也会直接影响最终排名结果。CPC出价随时间变化，影响排名和用户点击，但在构建CTR模型时，这些信息没有被明确考虑，导致估计偏差。其次，拍卖环境高度动态，众多第三方需求方平台 (DSP) 参与竞争，导致广告拍卖结果波动和不稳定。

通常，CTR预测模型高度依赖离线训练数据，缺乏对出价信息和拍卖环境的感知能力。因此，在实际应用中，CTR模型在离线时显示出高准确性，但在在线环境中却无法显著改进，这种情况很常见。



(a) CTR-Market Price relationship

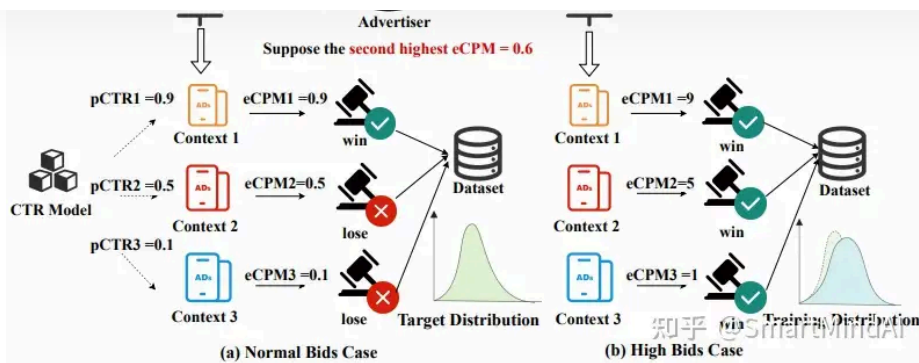


(b) Market Price Distribution

为了模拟高度动态的拍卖环境并减轻离线和在线的不一致性，我们在点击率预测阶段需要考虑拍卖环境和出价信息。点击率预测和市场定价建模任务之间存在紧密联系。图1 (a) 显示，在我们的工业数据集中，点击率与四个行业的市场定价呈正相关。有些工作在点击率预测中引入市场定价，但缺乏对不同场景下市场价格分布的精细建模，无法捕捉市场价格分布的多样性，导致结果不佳。市场价格的分布显著变化，如图1 (b) 所示。我们展示了在实际广告平台的四个选定行业中市场价格的分布，垂直轴表示场景，水平轴显示市场价格的相对值。因此，如何利用包括市场定价在内的拍卖信号以及区分市场环境的属性来改进点击率预测，是一个关键问题，我们称之为“拍卖信号利用难题”。

**推荐系统<sup>+</sup>** 常受到热门效应、位置效应和选择性偏差等影响。在广告推荐中，点击率预测还面临拍卖带来的特定偏见。例如，高出价广告即使点击相关性低，也更容易赢得拍卖，获得更多曝光，但这些曝光往往面向不相关用户，导致点击率降低。这种现象称为“拍卖效应偏斜”。

知乎



假设一个CTR模型在三种不同上下文中为某广告输出的pCTR分别为0.9、0.5和0.1。如果广告商正常出价1美元，只能在点击率为0.9的情况下赢得拍卖。但如果出价10美元，则在所有上下文中都能获胜，导致不相关曝光增加，点击率降低。这种现象在广告推荐中很常见，处理拍卖效应偏斜非常重要。

为解决拍卖信号利用问题和拍卖效应偏斜，我们提出了“增强广告信息的CTR预测框架”（AIE），包括两个模块：自适应市场价辅助模块（AM2）和出价校准模块（BCM）。AM2通过动态网络捕捉不同场景下的市场价格变化，BCM合理利用出价信息，缓解数据中的拍卖效应偏斜，使其更接近目标分布。

## Method

### Problem Formulation

考虑训练数据集  $\mathcal{D} = \{(\mathbf{x}_j, y_j)\}_{j=1}^{|\mathcal{D}|}$  包含  $|\mathcal{D}|$  个样本，其中  $\mathbf{x}_j = \{c_1, \dots, c_i, \dots, c_I\}$  和  $y_j$  分别代表CTR预测的通用特征和第  $j$  个样本的二进制点击标签。在线广告领域的CTR预测任务是构建一个预测模型，以估计用户在特定上下文中点击特定广告的概率，可以表示为：

$$\hat{y} = CTR\_model(\mathbf{x})$$

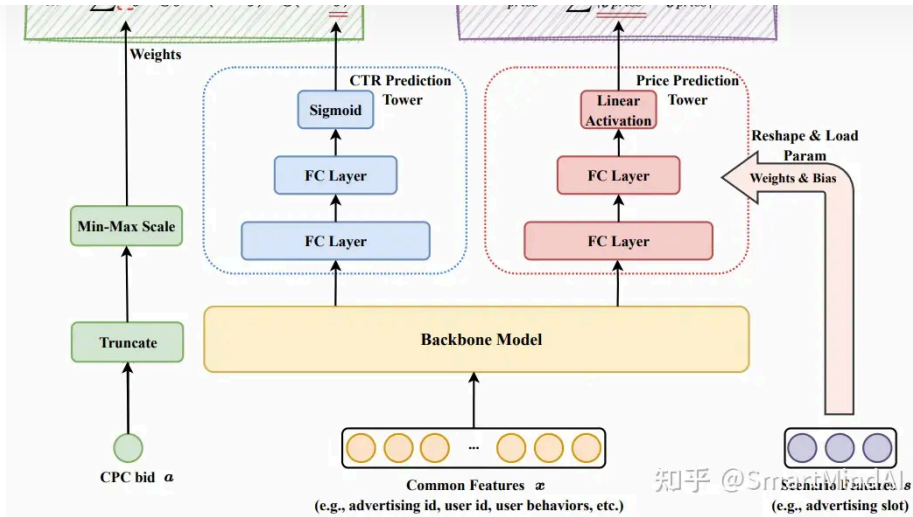
其中  $\mathbf{x}$  是关于用户、广告和上下文的通用特征，用于预测相关性。

然而，CTR模型通常忽略了任何后拍卖信息，仅基于通用特征进行预测，导致如图2所示的问题。因此，在训练阶段我们需要考虑这种后拍卖信息。特征  $\mathbf{a}$  代表了后拍卖信息，包括市场价格、CPC出价等。特征  $\mathbf{s}$  代表与场景相关的特征，指示拍卖环境。拍卖信息只能在离线训练中使用，因为它们都是CTR预测模型的后特征。结合通用特征  $\mathbf{x}$ ，我们在这里定义的广告推荐任务可以表示为：

$$\hat{y} = CTR\_model(\mathbf{x}, \mathbf{a}, \mathbf{s})$$

我们的目标是通过利用额外的拍卖信息来提高CTR预测模型<sup>+</sup>的性能。

### Overview



如图所示，由于拍卖信息对于CTR预测模型是后验信息的，我们仅在训练阶段使用它，并设计了两个可插拔模块：适应性市场辅助模块（AM2）和出价校准模块（BCM）被设置以利用拍卖信息来提升CTR预测模型的性能。适应性市场辅助模块（AM2）通过多目标结构进行学习，以让模型在拍卖信息中学习获取有用知识的方式部署。

### Adaptive Market-price Auxiliary Module

变化莫测的拍卖环境和广告推荐市场下的激烈市场竞争对点击率预测模型提出了巨大的挑战。拍卖相关的因素对排名eCPM的影响极为显著，从而导致预测结果未能达到预期。在广告推荐中面临的关键问题是如何利用各种拍卖信息来增强点击率预测模型。因此，我们提出了AM2来在细粒度级别上建模拍卖信息。

在工业应用中，市场价格与实际点击率在一定程度上存在正相关现象，如图1(a)所示。通过设计一个辅助任务来适应市场价格的变动，作为基于共享底层结构的主要点击率预测任务的补充，可以学习到通过共享嵌入和主干模型共享的信息。此外，为了捕捉市场价格分布的差异，价格预测<sup>+</sup>塔的权重和偏置通过动态权重网络生成，该网络通过场景特征输入可以区分不同的拍卖环境。给定价格预测塔的输入 $h^{(0)}$ ，即主干模型的最终层表示，价格预测塔的多层感知器<sup>+</sup>（MLP）可以表示如下：

$$h^{(1)} = MLP(h^{(0)})$$

$$h^{(k)} = \sigma(W^{(k-1)}h^{(k-1)} + b^{(k-1)}), \quad k \in [1, \dots, N]$$

$$W^{(k)}, b^{(k)} = Reshape(Split(E^s))$$

其中 $\sigma$ 是激活函数<sup>+</sup>，N是多层感知器的深度， $E^s$ 是指定场景嵌入。

MLP的最后层输出对应于市场价格的预测值<sup>+</sup>，记为 $h^{(N)}$ 。特别是，通过重塑和分割，指定场景嵌入生成的权重 $W^{(k)}$ 和偏置 $b^{(k)}$ 被创建。MLP的每层层数和隐藏单元的数量是需要调整的超参数<sup>+</sup>。根据我们的经验，对于价格预测塔和CTR预测塔，一个轻量级的MLP足以达到良好的整体性能。

在我们获得市场价格的预测值后，我们将其与实际市场价格进行比较，计算回归损失，可以表示为：

$$\mathcal{L}_{price} = \sum |\hat{y}_{price} - y_{price}|$$

其中，我们使用MAE回归损失，因为它不需要预先了解市场价格的统计桶化知识，并且在性能上优于分类损失。

然后，AIE可以通过优化点击率预测损失和价格预测损失的加权和来进行联合训练。最终损失公式如下：

$$\mathcal{L} = \mathcal{L}_{ctr} + w * \mathcal{L}_{price}$$

佳。

## Bid Calibration Module

在 CPC 计费模式下，可以通过有效 eCPM 对广告进行排序，从而最大化广告收入。CPC 投标直接影响广告的最终 eCPM 排名，进而影响广告的曝光度。如图所示，高投标额可能导致更多的广告曝光，其中一些是质量较低的曝光，导致点击率较低。直观上，我们可以重新加权训练样本以校正训练分布的偏差。具体来说，我们为 CPC 投标较高的正面样本分配更高的权重。这里我们仅对正面样本进行重新加权，因为它们可以影响训练数据中的正面样本比例，而且由于用户会点击它们，所以它们值得更多的关注。

通过这种方式，我们提高了具有高投标额样本的训练数据中的点击率，使其接近目标分布。在某些极端情况下，总会有非常大的投标值，我们需要裁剪原始值，以避免极端值对我们训练损失的影响。然后，通过最小最大缩放将裁剪后的值转换到特定的范围内作为最终的加权因子。为了控制预测偏差，重新加权后正面样本的比例与原始比例保持一致，这意味着一些具有低投标额的正面样本权重会降低。整个过程可以分为两个阶段。第一步，即进行裁剪，可以表示为：

$$C' = \text{clip}(C, \min, \max)$$

其中， $C$ 代表原始的样本级别的原始CPC竞价价值， $C'$ 代表剪切后的CPC竞价价值。在移除异常值后的 $C$ 的统计最小值和最大值，可以表示为： $C$ 的范围是 $\min, \max$ 。随后 $C'$ 转换到指定范围后，可以表示为： $C'$ 的范围是 $\text{new\_min}, \text{new\_max}$ ：

$$\alpha = a + \frac{(b-a)}{(\max-\min)} * (C' - \min)$$

$$\mathcal{L}_{ctr} = \sum \alpha y \log \hat{y} + (1 - y) \log(1 - \hat{y})$$

这里的 $\alpha$ 是每个样本的最终加权因子<sup>+</sup>。通过考虑CPC出价作为辅助信息<sup>+</sup>，我们校准了训练的CTR分布以接近目标分布，从而使CTR预测更加准确。我们的方法更适合那些广告商不频繁调整竞价策略的场景。在我们的工业实践中，广告商每日调整出价，我们的模型可以每小时甚至更快地进行更新，以确保BCM捕获实时拍卖信息。

## Discussion

首先，我们想探讨BCM与之前的去偏纠正方法，如逆倾向得分法（IPS）之间的联系和差异。IPS是一种适用于工业产品的实用去偏方法，可以被视为重新加权学习的一个特定案例。在本例中，倾向得分率可以定义为：

$$p_i = \frac{P(x_i, y_i)}{Q(x_i, y_i)}$$

训练分布是 $P(x, y)$ ，目标分布是 $Q(x, y)$ ，排除竞拍因素的影响。然而，在广告推荐中，无法排除竞拍因素的影响，观察到的分布可能是偏斜的。因此，我们采用了竞拍校准模型（Bid-Calibrated Model）来校准训练分布。这类类似于逆倾向评分格式（Inverse Propensity Score），最优函数的形式可以表示为：

$$\hat{\theta} = \underset{\theta \in \Theta}{\operatorname{argmin}} \sum \frac{l(z_i, \theta)}{p_i} + \lambda R(\theta)$$

其中 $z_i = (x_i, y_i)$ 是从训练分布中抽取的观测样本， $\theta$ 属于参数集 $\Theta$ ， $l(z_i, \theta)$ 定义了损失函数<sup>+</sup>， $R(\theta)$ 是正则化项。这里的 $p_i$ 通过每个样本的权重项 $\alpha$ 的倒数来近似。

其次，我们从另一个角度解释BCM的功能。BCM提升了高出价样本的点击率。如果我们认为出价较高的项目在线广告系统中具有更高的价值，那么这些高价值项目的预测点击率pCTR也会被提高。在与第三方DSP竞争高价值流量时，平台将获得优势并增加获胜的机会。这样一来，平台的收入将增加。因此，通过BCM的操作，平台不仅提升了高价值样本的点击率，还增强了在竞争中的优势，从而增加了收入。

## Overall Performance



Metric	Model	DNN	DCN	DeepFM	AutoInt	FiBiNET	DCNV2	DFFM	RelImpr. (Avg)
AUC	Baseline	0.7755	0.7770	0.7757	0.7738	0.7763	0.7766	0.7766	-
	MTAE	0.7780	0.7769	0.7759	0.7772	0.7763	0.7776	0.7757	0.32%
	AIE	0.7792*	0.7797*	0.7780*	0.7793*	0.7785*	0.7781*	0.7782*	1.01%
csAUC	Baseline	0.7762	0.7777	0.7763	0.7743	0.7768	0.7771	0.7775	-
	MTAE	0.7792	0.7770	0.7768	0.7777	0.7768	0.7781	0.7761	0.30%
	AIE	0.7798*	0.7804*	0.7786*	0.7798*	0.7792*	0.7787*	0.7787*	1.00%
Rev	Baseline	26.489	27.317	27.640	26.778	26.544	27.681	26.440	-
	MTAE	27.947	27.591	26.147	27.641	27.376	27.386	27.476	1.47%
	AIE	28.428*	28.355*	27.652*	28.536*	27.808*	27.954*	27.540*	3.95%
Rev NDCG	Baseline	0.1249	0.1289	0.1304	0.1263	0.1252	0.1306	0.1247	-
	MTAE	0.1318	0.1301	0.1233	0.1304	0.1291	0.1292	0.1296	0.65%
	AIE	0.1341*	0.1338*	0.1305*	0.1346*	0.1312*	0.1319*	0.1299*	3.97%

- 点击率预测 根据表格，可以观察到AIE在AUC上相对于MTAE和不同基线模型+实现了显著改进。AIE和MTAE都可以适应任何基线模型。MTAE在基线模型上的性能与基线模型相等或更好，这证明了竞拍信息的建模是必要的且有益的。在所有主干模型上，AIE都提供了更好的AUC性能。具体而言，例如在AutoInt上，AIE提高了AUC最多，RelImpr为2.01%，并且在所有基模型上平均提高了1.01%的RelImpr。相较于MTAE，所有基模型上的平均RelImpr从0.32%提升至1.01%，这是一个显著的提升。这是由于我们对竞拍信息进行了更细致的建模。
- 收入评估 我们可以通过表中观察到，调整后的csAUC的趋势与AUC大致相同。MTAE在大多数情况下都超越了基线，证明了添加辅助任务以预测市场价格的有效性。然而，MTAE在某些基线上（如DCN）的改进并不稳定，这可能是因为它采用了多分类损失，其效果依赖于对市场价格分类方式的精确理解。相比之下，AIE采用了回归损失，可以避免通过手动经验将市场价格分桶为多类。因此，AIE在csAUC上获得了1.00%的实际改进，因为它对拍卖信息的建模更为全面。展示的Rev值被除以1000。AIE在所有选定的基线上都表现得最好，特别是在Rev和Rev NDCG上。AIE在Rev上的平均实际改进为3.95%，在Rev NDCG上的平均实际改进为3.97%，这表明它具有很强的优化收入能力。
- 推荐倾向探索 为了找出AIE倾向于向用户推荐什么样的广告，我们进行了一项实验。如表所示，我们将测试集中的广告按照出价价格分为三组，其中出价最高的三分之一归类为'高'，最低的三分之一归类为'中'，其余的归类为'低'。我们选择DCN作为基准，然后计算基准和基准+AIE下被推荐的广告比例。以下是一些观察结果：（i）平均而言，AIE推荐的'高'和'中'组项目比例显著增加；（ii）相比之下，'低'组项目的推荐比例由AIE减少。总体收益为正，因为推荐了更多频率的'中'和'高'组项目，为平台带来了更大的价值。这些结果与AIE的直觉一致，它在训练阶段更关注高出价样本，因此向更多用户推荐高价值项目。结合CTR预测中展示的AUC改进，我们可以得出结论，AIE不仅增强了CTR预测模型的排序能力，还使CTR预测模型能够感知高价值流量，从而提高收益。

Online Industrial A/B Test

为了评估我们的框架（即AM2和BCM）在实际工业应用中的性能，我们在一个为期一个月的在线A/B测试中，在我们的在线广告平台上进行了测试。

Table 4: Online A/B testing results of AM2 and BCM modules compared to the base model.

Model	RPM	eCPM	CTR	Bias
Base+AM2	+1.83%	+3.94%	+1.21%	+2.58%
Base+AM2+BCM	+6.14%	+5.76%	+2.44%	-5.38%

表显示了三种模型的结果，其中AIE在RPM上提高了6.14%，在eCPM上提高了5.76%，在CTR上提高了2.44%，而预测偏差减少了5.38%。AIE的全流量从5%，10%，20%，50%增加到100%，每一步都观察了2-3天，在每个观察区间内，AIE的增强是确定的。在表4中，关于eCPM的改进率的AM2和AIE的置信区间+分别是2.36和4.75。置信区间的上下限都是正数，表明实验结果具有统计显著性。此外，与基础模型相比，AIE的预测偏差大幅减少，证明了BCM在缓解拍卖偏差方面的有效性。AM2在RPM上分别提高了基础模型的1.83%，eCPM提高了3.94%，CTR提高了1.21%，证明了详细使用拍卖信息的方法的有效性。经过一个月的评估，AIE成为了在这种场景下承载所有在线流量的主要模型。

发布于 2024-09-13 11:50 · IP 属地北京

ctr 华为 提高ecpm



理性发言，友善互动



发布



还没有评论，发表第一个评论吧

推荐阅读

**中国之怪圈：华为犯下致命错误**

华为傻瓜了，开源了自己的鸿蒙核心代码，本来期待和友商合作生态，结果不但被国外白嫖，而且友商趁机借鉴精华推出自己的系统。不偏不倚，赶在华为开源一两年后。这些友商背后又是美国资...  
东周



**华为还能再挺多久？**

无线深海



**确定了！华为正式宣布，这天终于要来了！**

嘉龙科技



**深度解读华为云AI战略：靠AI赢得下一个十年？**

华为云开发... 发表于程序