

赞同 4

分享

META-2023 CAViaR: 情景感知的视频推荐重排序



SmartMindAI

专注搜索、广告、推荐、大模型和人工智能最新技术，欢迎关注我

已关注

4 人赞同了该文章

Introduction

Facebook的视频推荐系统⁺使用深度神经网络分类模型来预测用户对视频的兴趣，并根据预测分数进行排名。这确保了推荐视频的个性化和多样性。

$$s_{ij} = P(E(u_i, v_j) | F(u_i, v_j))$$

本文使用深度神经网络为base类模型来预测用户对视频的正向交互事件的概率。这是一个仅基于视频 v_j 信息的pointwise模型。然而，由于未考虑视频间的交互，该模型可能会高估视频 v_j 的预测得分，同时忽略其他位于该视频上方的视频可能提供的信息。

$$s'_{ij} = P(E(u_i, v_j) | F'(u_i, v_j, v_{(j-1)}, v_{(j-2)}, \dots))$$

Novelty and Diversity

新颖性和多样性是两个关键概念。新颖性指向用户展示新体验的能力，而多样性则指在Feed中提供不同类型的体验。先前的研究利用上下文信息来推荐新内容，以更好地理解用户并满足其需求。

然而，最初的建议主要关注如何减少重复的内容。一种常见的方法是使用MMR算法，该算法在每次迭代时考虑项目的相关性和与其他后续项的相似性。一些研究还专注于设计更有效的子模函数，例如Tschitschek等人使用子模函数进行物品选择，或者Teo等人使用子模函数和类别的平行项对物品进行重新排序。

Generalized Contextual Ranking

我们的方法是利用视频在列表中的位置信息训练深度神经网络，为每个用户提供个性化的处理。相比以往研究，我们的方法在pointwise分类模型中引入多样性，可在工业级推荐系统中实现无成本的模型训练和线上推理。此外，我们强调多样性并非独立于相关性和用户参与度目标，而是通过提升相关性和捕捉多样性相关信息的特征得以增加。

System Design

知乎




Figure 1: After the main ranking pass, we successively slot videos in the final ranked order.

我们通过贪心算法⁺来计算和利用 s'_{ij} ，其中 u 是用户， i 和 j 分别表示原排序和更新后的视频索引， K 为总视频数量。

$$s'_{uv_j} \leftarrow P(E(u, v_j) | F'(u, v_j, v_{(j-1)}, v_{(j-2)}, \dots))$$

$$v'_j \leftarrow \operatorname{argmax}_x \|s'_{uv_x}\|$$

该算法通过

$$s'_{ij} = \max_k s_{ik}$$

在每个位置插入视频。

Algorithm 1 Re-ranking a feed using a contextual model

```
for  $i \in 1:K$  do
  for  $j \in i:i+w$  do
     $s'_{uv_j} \leftarrow P(E(u, v_j) | F'(u, v_j, v_{(j-1)}, v_{(j-2)}, \dots))$ 
  end for
   $v'_j \leftarrow \operatorname{argmax}_x \|s'_{uv_x}\|$ 
end for
```

该方法使用精排⁺类似的预测模型⁺来实现视频流的多样性重排序，但可能导致延迟回归（复杂度为 $O(K \cdot n)$ ）。为避免此问题，提出一种基于需求的重新排序方法，即仅向用户提供一小部分项目，以降低用户设备的空间限制和时间消耗。通过利用用户行为，我们的技术可以在减少延迟影响的同时，使用分类模型对Feed进行重新排序。

Contextual Features

- 平均嵌入：我们使用预训练的视频嵌入。这些嵌入可以用于视频理解嵌入等。我们提取每个窗口大小为 k 的视频的平均嵌入。
- 相似性特征：对于当前视频，我们计算其与上方 k 个视频的^{点积}⁺，以得到相似度得分。这个得分可以用来表示当前视频与其他视频之间的相似程度。
- 视频主题：我们利用自动分类器标记的视频主题，提取给定视频和周围视频之间主题的一致性的信息，并将其用作多样性衡量标准。

Contextual Model

本文提出了一个上下文模型用于重新排名。该模型利用上下文特征来提高预测能力，并被称为上下文模型。模型采用深度神经网络结构，包含用户侧特征和视频侧特征。在嵌入层中，通过稀疏特征转化为数值表示。模型包括多个密集层，使用ReLU作为^{激活函数}⁺。最后层包含多个目标，每个目标对应于正用户参与事件。此外，模型还接受更多的用户和视频基特征作为输入。

我们训练了两版模型：[基线模型](#)⁺和上下文模型。上下文模型增加了十种额外的上下文特征。所有模型都采用Adam优化器（学习率0.005，批处理大小为128）。原始数据训练了21天，之后每天增加的新数据上反复训练。数据单次训练通过。

Result

Model Calibration

模型校准是[评估模型](#)⁺并理解其过度预测的方法。

$$calibration = \frac{\sum prediction}{\sum label}$$

为理解推荐系统中的多样性问题，我们通过绘制模型校准度与表示Feed多样性的特征间的关系来研究。其中，使用用户最活跃事件来计算校准度，且将相似性作为衡量Feed多样性的指标，该指标基于每个视频的预训练嵌入，这些嵌入表示内容和主题的相似性，相似度得分通过取视频的嵌入向量与上一个5个视频在Feed中的平均嵌入向量的点积计算得出，并将得分分为几个桶进行展示。在图中，可以看出相似度得分越高，预测越过度校准，且在大多数数据中有很大改进空间。我们还检查了使用上下文特征训练的上下文模型的校准度，并发现该模型对于所有相似度得分都能很好地校准，与我们的假设相符。

Offline performance

我们将探讨通过改进模型校准能否提升其他模型评估指标。我们采用归一化熵衡量二元预测任务的离线性能，其定义为预测损失与背景CTR（点击率）熵之比，越低越好。背景CTR是训练数据的平均经验CTR。



Figure 3: Progression of percentage improvement in offline normalized entropy for the contextual model as training progresses, using the main ranking model as a baseline

模型性能与基准模型比较：在三个模型中有所提高，分别提高了1.2%，0.85%，和1.4%。离线收益表明模型将在线受益。

A/B testing

在线A/B测试结果表明，上下文模型显著提高了用户的参与度。

具体表现为：图4中的用户到达顶部页面的比例提高了1.7%，每日活动增加了1.6%（即一天内不同用户观看视频的次数）。考虑到Facebook应用每天有数十亿的用户参与视频，这项改进是非常重大的。

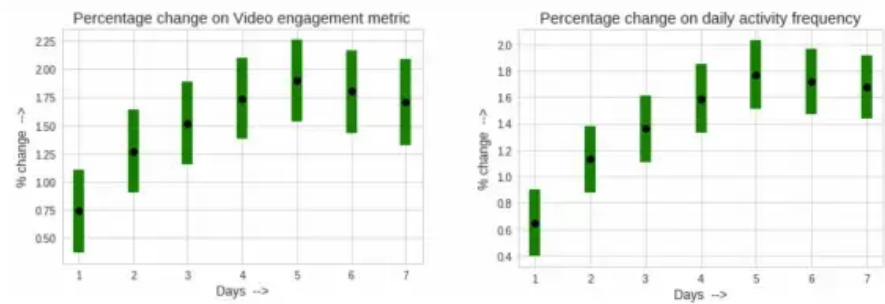


Figure 4: Improvement in engagement metrics in an online A/B test. 知乎 @SmartMindAI

Conclusion

优化用户参与度可以引入多样性，因为我们的模型考虑了多样性与用户参与度的关系。这种方法不需要在系统中平衡任何多样性与参与度之间的权衡，只需考虑因缺乏多样性而受到影响的用户和项目。此外，该方法易于应用到大规模推荐系统中，只需利用现有的点对点模型工具和支持基础设施即可。

原文《CAViaR: Context Aware Video Recommendations》

关注我，追踪最新技术
www.zhihu.com/people/smartmindai



编辑于 2024-02-19 10:35 · IP 属地北京

Meta分析 meta-learning 视频推荐

 理性发言，友善互动



还没有评论，发表第一个评论吧

推荐阅读