

## 亚马逊2023 ALCIR: 利用半监督对抗学习提升商品相关推荐的效果

**SmartMindAI**

专注搜索、广告、推荐、大模型和人工智能最新技术，欢迎关注

已关注

3 人赞同了该文章

### Introduction

许多现代电子商务网站为他们的客户提供了补充的物品推荐。例如，当在线用户购物时，他们可能会收到适合的裤子建议。在实践中，这些建议通常会以“经常一起购买”的标签出现，并且是电子商务平台交叉销售<sup>+</sup>的重要驱动因素。推荐的排序基于消费者社区的行为模式<sup>+</sup>，如共同购买。此外，可以考虑使用领域知识，如推荐的商品必须来自目标类（如裤子）或不同于种子项类别的其他类。但在一些领域，如eBay，商品目录可能非常不稳定，缺乏交易数据。对于冷启动种子内容，无法使用协同信号，如商品共购。此时，可能需依赖其他方法，如处理内容的侧面信息，如描述或属性。利用总体使用数据推断互补类别集合，对特定类别的物品进行推荐，并且可以减少无关推荐和推断时间，这种方法在电商网站上常见。

作者提出一种深度学习模型，维护每个物品类别的潜在空间，将商品表示转化为潜在空间，定位给定类别空间中的与种子内容接近的内容。这种方法通过基于监督学习的训练方法，使用包含互补内容的对的信息，学习类别之间的关系，即使对于没有现有信息的给定类别和内容，也可以利用可用的内容信息。建议使用新半监督模型进行互补项推荐，并通过实验证明其在不同实验设置下的优越性以及扩展架构中添加CycleGAN元素的好处。在现有文献中未见利用CycleGAN改进互补项推荐的方法。

### Overview of Proposed Approach

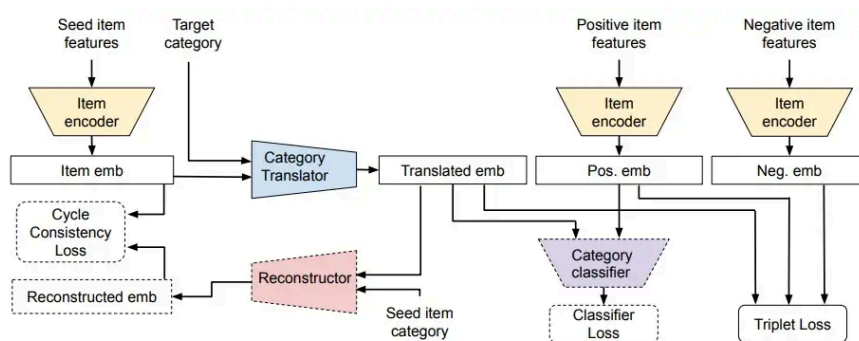


Figure 1: The proposed model architecture. Elements with dashed lines are part of the adversarial learning network.

在无交互数据的情况下，如何从目标类别推荐互补项？我们考虑使用已知类别的内容和额外的侧信息作为种子项，同时假设存在一个包含对互补内容的标记集。该模型有助于解决这一问题。最大化余弦相似度<sup>+</sup>的项 $c$ 在类别集合 $I_c$ 中的值。

$$\operatorname{argmax}_{i \in I_c} \cos(v_s^c, v_i)$$

### Supervised Learning Component

化方法<sup>+</sup>处理。最后，我们将所有特征的代表concatenated并传递给另一个MLP。

## Adversarial Learning Component

在监督学习中，有效性的提高受限于标记数据的数量。在补充内容推荐中，由于数据稀缺，更稀有的类别的标记对可能不足。为了解决这个问题，我们引入了对抗学习组件，实现在无监督下的学习。这种方法利用目录中所有内容的特征信息<sup>+</sup>，即使在某一特定类别中没有标签的互补项。例如，当我们得到一件特定的衬衫时，这种情况会发生在裤子类别中。因此，这是一种半监督学习方法。请注意，对抗学习仅用于改进训练过程。在推理阶段，只需要物品编码器和类别翻译器的输出来决定推荐结果。

## Architecture Elements

为了解决这个问题，引入了“重构器”，它鼓励“类别翻译者”保持一致性和保留种子项的特性。具体而言，该网络接收一个已编译的表示 $v_i^c$ 和原始种子项的类别。然后，它的目标是通过返回一个向量 $v_i'$ 来重构原始种子项的表示 $v_i$ ，使得

## Model training

为了允许整个架构的端到端学习，最终损失由这两种损失的加权和以及监督学习组件的损失函数<sup>+</sup>给出。权重损失构成凸组合，并由超参数确定。

重构器的损失在我们的方法中是欧几里得距离<sup>+</sup> $\|v_i - v_i'\|^2$ 。由于损失中的两个项 $v_i$ 和 $v_i'$ 都是通过学习网络得到的输出，因此可以达到退化的但最优的损失。例如，如果“item encoder”和“category translator”返回相同固定值，无论输入如何，那么损失将为0。为了克服这个问题，我们回想一下，这个损失的目的在于激励“category translator”不要忽略种子项的重要特性，这些特性由 $v_i$ 表示。因此， $v_i$ 作为这个损失的标签。因此，我们将反向传播梯度从 $v_i$ 停止，因为这个损失。

我们指出，这个过程进一步提高了“item encoder”，由于从 $v_i'$ 获得的Jacobian。段落标题第一类是item encoder的真正输出。即，我们两次调用classifier，输入的种子项 $v_s$ 和正项 $v_p$ 的嵌入，其中标签类别是从目录中获取的。但是，我们注意到标准实现也会影响到item encoder。具体来说，这最终会导致模型退化，因为类别是item encoder的输入。因此，为了在牺牲模型的实际目标（提供推荐）的基础上，使item encoder与category translator协作，提高该损失，item encoder被激励去合作。例如，item encoder可能会输出类别嵌入，而忽略其其余输入特征。

因此，我们通过阻止classifier的梯度通过item encoder的参数来实施模型。我们的实验表明，这显著提高了性能。关于第二类输入的分类器，我们回忆一下类别翻译的目标是创建一个嵌入向量 $v_s^c$ ，使得分类器<sup>+</sup>将 $v_s^c$ 分类为如果它属于类别 $c$ 。为了避免情况发生，即类别翻译器找到边缘案例（对抗性示例），只有欺骗分类器，但不像真实物品在类别 $c$ 中的向量看起来，那么重要的是训练分类器使用类别翻译器的输出向量 $v_s^c$ 和标签类别 $c$ 。如果这样做了， $v_s^c$ 被用于训练类别翻译器和分类器，但是它们有不同的目标。类别翻译器旨在欺骗分类器，而后者需要挑战类别翻译器。为了解决这个问题，我们使用对抗训练并添加反向梯度层。这意味着在反向传播期间，类别翻译器获取原始梯度，而分类器则受到梯度相反方向的影响。

## Specific CycleGAN Adaptations

具体而言，我们将阐述如何创新地从CycleGAN中汲取灵感来解决互补商品推荐的问题。CycleGAN是一种变体生成对抗网络<sup>+</sup>，包括两个生成器和两个判别器，它们同时训练。生成器<sup>+</sup>学习将图像从源域传输到目标域，而生成器则学习将图像从目标域传输回源域。判别器的目标是在源域<sup>+</sup>和目标域上分别区分真实的图像和生成的图像。这些网络的训练通过对抗训练完成。通常，我们会希望生成器能尽可能地保持输入图像的重要特征，这样就能确保生成的图像更接近源域，而非只属于目标域。

为了达到此目的，我们引入了循环一致性损失，该损失需要使生成的图像尽可能地接近原始图像。本文探讨了一种基于item encoder、category translator和classifier的模型，其中item encoder产生真实的分布，category translator作为G，classifier作为D，reconstructor作为F。Classifier的目标是输出与来自item encoder的真实概率接近于1的输入，并且对来自category

的"真实分布"实际上是item encoder生成的，这是一个学习网络，而不是真实的图像。此外，我们通过阻止种子项向量引起的梯度来解决这个问题。

Experimental Evaluation

我们进行了深入的实验评估。我们的所有代码都在线共享以供复现。

Experiment Design

在预处理阶段，我们过滤掉类别数量小于五的类。使用预训练的ResNet152模型。对于多张图片的内容，只取第一张。对连续的价格使用等深度均匀分箱转换为20个bins。使用80%的数据进行训练，剩余部分用于验证和测试。为模拟冷启动问题，验证集和测试集中种子内容不在训练集中。

- 流行度定义：使用标记集合计算每项的流行度，方法是记录种子物品中对每项被标记为互补项的数目。
- 新提出的神经网络模型DCF用于解决冷启动问题。模型未公开其源代码，因此我们根据原论文实现并发布了模型。
- 提出一种变体：DCF-Hard，利用类别信息进行硬负采样，负样本仅来自目标标签类下的内容。
- P-Companion 是另一个最近的神经网络模型。由于其代码没有公开发布，我们在我们的仓库中实现了它并将其代码发布出来。为了使其与我们的问题设置兼容，我们进行了两项修改。首先，我们控制目标类别，其次，我们删除了协作信息以支持冷启动问题。

我们通过手动调整模型和基线的超参数，并在每个数据集上执行此操作来优化模型。这些超参数的具体值可在代码仓库中获取。

Table 1: Dataset statistics

Statistic	Clothing	Toys	Home
#items	14,591	20,510	29,258
#item pairs	53,375	112,964	162,497
#categories	126	124	286
#category pairs	4,621	5,734	18,999
Avg. items per category	115.8	165.4	102.3
Max items per category	808	2,558	796
Min items per category	12	15	11

Results

Main Results

表1报告了实验主要结果，其中包括推荐者分配的类别。我们提出的算法名为"抗学习用于互补物品推荐"，简称"ALCIR"。为了研究各个组成部分的影响，我们展示了(a)仅包含在第Section中提及的监督学习组件的"ALCIR-Sup"的结果和(b)与第Section中描述的完整模型对应的全部要素的"ALCIR"的结果。

Method	NDCG	HR@1	HR@5	HR@10	Cov. (%)
Clothing Dataset					
Popularity	0.238	0.051	0.153	0.234	6.99
DCF	0.211	0.011	0.059	0.111	7.24
DCF-Hard	0.226	0.019	0.083	0.147	40.49
P-Companion	0.238	0.030	0.102	0.169	84.59
ALCIR-Sup	0.298	0.074	0.203	0.302	89.92
ALCIR	0.316	0.092	0.233	0.332	88.5
Toys Dataset					
Popularity	0.231	0.038	0.126	0.200	5.13
DCF	0.193	0.009	0.042	0.081	5.96
DCF-Hard	0.208	0.017	0.064	0.111	36.72
P-Companion	0.235	0.028	0.104	0.172	93.78
ALCIR-Sup	0.297	0.073	0.205	0.303	90.46
ALCIR	0.308	0.078	0.224	0.330	82.62
Home Dataset					
Popularity	0.251	0.048	0.160	0.255	8.2
DCF	0.211	0.011	0.051	0.102	8.32
DCF-Hard	0.221	0.014	0.046	0.077	12.82
P-Companion	0.245	0.032	0.111	0.187	94.45
ALCIR-Sup	0.296	0.068	0.197	0.293	93.44
ALCIR	0.304	0.077	0.210	0.312	94.38

表1显示了在所有三个数据集上，ALCIR 在准确度指标方面始终优于所有基线。通常，该差距很大。我们还注意到我们的模型的监督部分 (ALCIR-Supervised) 已经超过了基线。然后，对抗性部分成功地进一步提高了这些已经很强的结果。考虑到其他模型的排名，我们注意到基于流行度的方法是一个难以击败的基准。DCF 模型和改进后的 DCF-Hard 模型从未达到流行项推荐的精度水平。P-Companion 工作得更好，但仍然没有达到热门项推荐的[点击率](#)水平。只有在 NDCG 方面，P-Companion 达到了相似的性能水平。流行度方法的强大表现并不令人惊讶。对数据集的检查揭示了最受欢迎的前十个内容覆盖了最多五分之一到四分之一的标记互补项。此外，评估了一个共同购买方法也显示了 P-Companion 没有超过这种流行度为基础的方法在[用户中心](#)的研究中。相比之下，我们提出的模型始终优于流行度模型。

我们还注意到 ALCIR 能够实现高的覆盖率，范围从82%到94%。只有 P-Companion 方法达到了甚至稍微更高的目录覆盖率。由于设计原因，流行度方法只推荐非常受欢迎的内容，导致最低的目录覆盖率。有趣的是，DCF 方法也有很低的目录覆盖率。改进后的 DCF 版本 (DCF-Hard) 在很大程度上帮助解决了覆盖率问题。表最后展示了我们考虑所有上述相关类别进行补充内容推荐时的性能结果。自然地，在所有模型中，此实验的性能结果都低于当类别已知情况。然而，我们注意到，提出的模型ALCIR在这一问题设置中也更优。



Method	NDCG	HR@1	HR@5	HR@10	Cov. (%)
Clothing Dataset					
Popularity	0.099	0.001	0.005	0.007	0.06
DCF	0.111	0.000	0.001	0.002	0.09
DCF-Hard	0.118	0.001	0.003	0.007	1.82
P-Companion	0.111	0.000	0.002	0.003	0.62
ALCIR-Sup	0.150	0.009	0.036	0.060	59.36
ALCIR	0.170	0.012	0.060	0.098	60.55
Toys Dataset					
Popularity	0.102	0.001	0.003	0.005	0.04
DCF	0.124	0.000	0.001	0.002	0.06
DCF-Hard	0.148	0.003	0.010	0.016	5.67
P-Companion	0.123	0.001	0.001	0.002	5.12
ALCIR-Sup	0.172	0.010	0.044	0.021	64.56
ALCIR	0.181	0.009	0.016	0.071	56.03
Home Dataset					
Popularity	0.093	0.000	0.001	0.002	0.03
DCF	0.117	0.000	0.001	0.002	0.05
DCF-Hard	0.117	0.000	0.002	0.003	0.13
P-Companion	0.117	0.000	0.001	0.001	1.61
ALCIR-Sup	0.143	0.005	0.021	0.033	53.42
ALCIR	0.150	0.008	0.030	0.049	55.53

Additional Analyses

为验证假设，我们通过计算每对互补类别在全部数据集内的训练数据数量并将其分入10个等规模的桶内来评估全完备性<sup>+</sup>学习方法的相对贡献。然后，我们将按照每个类别对的监督数据数量对桶进行排序，并观察桶内不同模型的性能指标。结果发现，全完备性学习方法在处理稀有的类别对时表现较好，而在处理非常受欢迎的类别对时则相对较弱。这一现象在Toys和Home数据集上尤为显著。该分析支持了我们的假设，即在特定稀有的类别上，全完备性模型具有较大的优势。本文研究了一种模型，其核心特征是使用三元组<sup>+</sup>损失、循环一致性损失和分类器损失。为了验证这些损失函数对整体模型性能的影响，进行了非监督训练研究，并将结果显示在表1中。结果显示，所有的组件均能提高模型性能，尤其是未使用标记数据且仅利用分类器和循环一致性的模型表现最差，这是符合预期的，因为已知标记数据的重要性。




Figure 2: Performance with respect to the amount of labeled data

Method	NDCG	HR@1	HR@5	HR@10
Clothing Dataset				
Classifier+Cycle	0.21	0.015	0.059	0.114
	(-33.5%)	(-83.9%)	(-74.7%)	(-65.7%)
ALCIR-Sup	0.298	0.074	0.203	0.302
	(-5.7%)	(-19.4%)	(-13.1%)	(-8.9%)
Triplet+Cycle	0.311	0.087	0.226	0.319
	(-1.8%)	(-5.6%)	(-3.1%)	(-3.8%)
Triplet+Classifier	0.305	0.082	0.213	0.306
	(-3.5%)	(-11.3%)	(-8.8%)	(-7.5%)
ALCIR	0.316	0.092	0.233	0.332
Toys Dataset				
Classifier+Cycle	0.207	0.016	0.07	0.124
	(-32.9%)	(-79.5%)	(-68.7%)	(-62.5%)
ALCIR-Sup	0.297	0.073	0.205	0.303
	(-3.7%)	(-6.4%)	(-8.7%)	(-8.2%)
Triplet+Cycle	0.294	0.072	0.205	0.303
	(-4.4%)	(-6.8%)	(-8.3%)	(-8.4%)
Triplet+Classifier	0.298	0.073	0.209	0.309
	(-3.3%)	(-6.6%)	(-6.6%)	(-6.5%)
ALCIR	0.308	0.078	0.224	0.330



亚马逊

亚马逊公司（Amazon，简称亚马逊；NASDAQ：AMZN），是美国最大的一家网络电子商务公司，位于华盛顿州的西雅图。是网络上最早开始经营电子商务的公司之一，亚马逊成立于1995年，一开始只经营网络的书籍销售业务，现在则扩大了范围相当广的其他产品，已成为全球商品品种最多的网上零售商和全球第二大互联网企业，在公司名下，也包括了AlexaInternet、a9、Iab126、和互联网电影数据库（Internet Movie Database，IMDB）等子公司。亚马逊及其它销售商为客户提供数百万种独特的全新、翻新及二手商品，如图书、影视、音乐和游戏、数码下载、电子和电脑、家居园艺用品、玩具、婴幼儿用品、食品、服饰、鞋类和珠宝、健康和个人护理用品、体育及户外用品、玩具、汽车及工业产品等。2018年9月5日，亚马逊宣布向奔驰订购两万辆货车，用于最后一公里快递服务

浏览量 11.2 亿      精华 936,615      讨论量 93.6 万

关注话题

亚马逊 (Amazon.com)    电子商务    工业级推荐系统

赞同 3    添加评论    分享    喜欢    收藏    申请转载    ...



理性发言，友善互动