

美团2023-揭秘DBPMaN，用行为路径匹配网络助推CTR模型，效果升级



SmartMindAI

专注搜索、广告、推荐、大模型和人工智能最新技术，欢迎关注我

已关注

26 人赞同了该文章

论文原文《A Deep Behavior Path Matching Network for Click-Through Rate Prediction》

Introduction

美团外卖APP是一款提供餐饮及零售服务的移动应用。用户可以通过该APP浏览并选择各种POI（如餐馆、食品店和咖啡馆）并订购食品，随后这些食品将被快速送至用户手中。该应用期望通过理解用户决策背后的心理学并为用户推送相关候选内容，从而提升点击率（CTR），并进一步提高交易量和广告收入。在用户行为方面，我们观察到APP上的用户行为是体现用户决策心理的重要表现。尽管现有的CTR预测模型⁺已从长序列或多类行为的角度分析了用户行为，但这些模型仅采用候选人和历史行为序列中的点对点激活，并未考虑包含用户决策痕迹的连续行为的影响。因此，对于点击目标POI的行为，我们将该行为之前的连续行为，包括浏览POI、下单等视为行为路径。通过观察美团外卖APP的历史数据，我们发现行为路径和点击行为之间存在密切关联。然而，对用户行为路径进行建模面临三大挑战：行为路径稀疏、噪声干扰以及精确匹配。首先，用户与APP交互有限，捕捉其全部行为困难。为解决此问题，我们利用对比学习来优化用户行为路径的学习。其次，用户行为路径存在大量噪声。例如，用户因封面点击POI，若不喜欢则立即返回。此行为会成为路径中的噪声。为减少其影响，我们构建了一个动态激活网络来关注路径中的关键行为。因为某些行为对后续行为影响更明显，动态激活更高效。最后，我们提出一个两级匹配机制。在**第一级**⁺中，计算当前路径与历史路径的激活权重并选择最相似的历史路径前k个。在第二级中，计算遵循所选路径的点击行为的激活权重以进行CTR预测。

- 本文将用户行为路径匹配引入工业CTR预测中，但面临三大挑战：行为路径的稀疏性、噪声和匹配问题。
- 我们提出了一种深度行为路径匹配网络(DBPMaN)，用于预测CTR，增加了行为路径，提供了行为路径自激活，并在CTR预测中进行了两级匹配。
- 我们对两个不同规模的现实数据集进行了离线实验，并在美团广告中进行了在线A/B测试，实验结果表明DBPMaN是有效的，并取得了较好的效果。

Related Work

点击率预测作为推荐系统⁺的核心部分，一直受到业界和学术界的广泛关注。经典的解决方案是学习特征交互，其中DeepFM、xDeepFM和ONN是早期代表性的深度神经网络模型⁺，而CAN在目前的开源点击率模型中具有最先进的性能。最近，序列行为建模⁺成为点击率预测的新驱动力。所建模行为的粒度从单个行为到多种行为，从短序列到超长序列。这些模型旨在捕捉用户兴趣或意图，并且通常采用点对点激活方法，其输入仅包含单一类型的行为，例如点击，从概率角度估计用户对候选人的兴趣/意图倾向。他们被证明继续提高了点击率预测的准确性。此外，随着Transformer和BERT在NLP领域的巨大成功，它已被引入推荐系统中。以实现不同的召回任务与上述工作相比，我们的工作强调隐含决策标志的行为路径，并将行为路径用作点击率预测的证据基础。

Overview

定义1 (用户行为序列) 设 \mathcal{U} 为用户集合，对于用户 $u \in \mathcal{U}$ ，其行为序列按发生时间排序，记为 $s = [b_1, \dots, b_i, \dots, b_T]$ ，其中 b_i 是第 i 个行为， T 是行为序列的长度。序列包括用户过去一年的行为，每个行为包括互动项目的id、行为类型、发生时间与当前时间的间隔以及序列中的相对位置等。其中，存在三种行为类型：点击、展示和订单。用户行为序列 s 包含大量点击行为，因此可以从 s 中提取出一个点击序列 s^c ，表示为： $s^c = [b_1^c, b_2^c, \dots, b_i^c, \dots, b_t^c]$ ，其中 t 表示点击序列的长度。

定义3. (用户行为路径) 对于在 s^c 中的第 i 个点击行为 b_i^c ，设 $b_{m(i)}$ 表示在行为序列 s 中相应的行为，其中 $m(i)$ 表示在 s 中第 i 个点击行为发生的位置。那么，相对于点击行为 b_i^c 的用户行为路径，记为 p_i ，是子序列

$[b_{m(i)-l}, \dots, b_{m(i)-2}, b_{m(i)-1}]$ 在 s 中，其中 l 是行为路径的预设长度。

从用户行为路径的定义中，我们可以明显地发现点击行为和行为路径是一一对应的对应关系。举例来说，在历史用户行为序列中，有三个长度为预设值3的用户行为路径：一个相对于 h_4 ，一个相对于 h_7 ，一个相对于 h_{11} 。

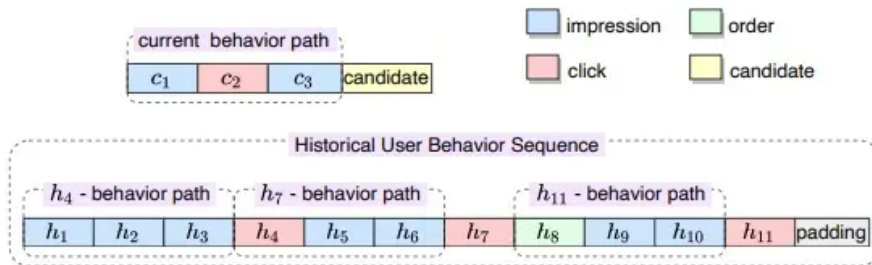


Figure 1: Example of user behavior paths where $l=3$.

定义4. 行为路径序列 对于 s 中的所有点击行为，我们得到对应的用户行为路径序列 P ，表示为 $P = [p_1, \dots, p_i, \dots, p_t]$ ，其中 p_i 是相对于点击行为 b_i^c 的用户行为路径。其次，介绍了DBPMaN模型的组成、结构及流程。DBPMaN模型由一个嵌入层和三个模块组成，这三个模块分别是路径增强模块（PEM）、路径匹配模块（PMM）和路径增强模块（PAM），其结构如图所示。

DBPMaN采用多个特征作为输入，其中包括物品信息、用户信息和用户行为序列。这些特征经过嵌入层处理后，通过求和池化计算出用户行为序列的嵌入、用户嵌入和候选物品嵌入。PEM旨在挖掘用户行为路径中不同行为的贡献，以学习更准确的路径嵌入。具体而言，给定每个行为路径及其对应的点击行为，PEM首先激活重要的行为路径，然后优化路径嵌入以获得更准确的表示。PMM将当前行为路径和历史行为路径的嵌入作为输入，搜索与当前路径最具相似性的前 k 个历史路径，并激活与候选物品相应的 k 个点击行为。PAM的目标是通过对比学习来学习更精确、更有信息量的行为路径嵌入。具体来说，我们屏蔽每个历史行为路径以获得两个增广路径并将其输入到嵌入层和PEM中以计算它们的嵌入，然后采用InfoNCE损失作为对比损失来拉近相同行为路径的嵌入。DBPMaN使用负对数似然函数 $-\log \sigma(\cdot)$ 作为主要损失函数进行训练，并结合主要损失和对比损失作为优化目标。

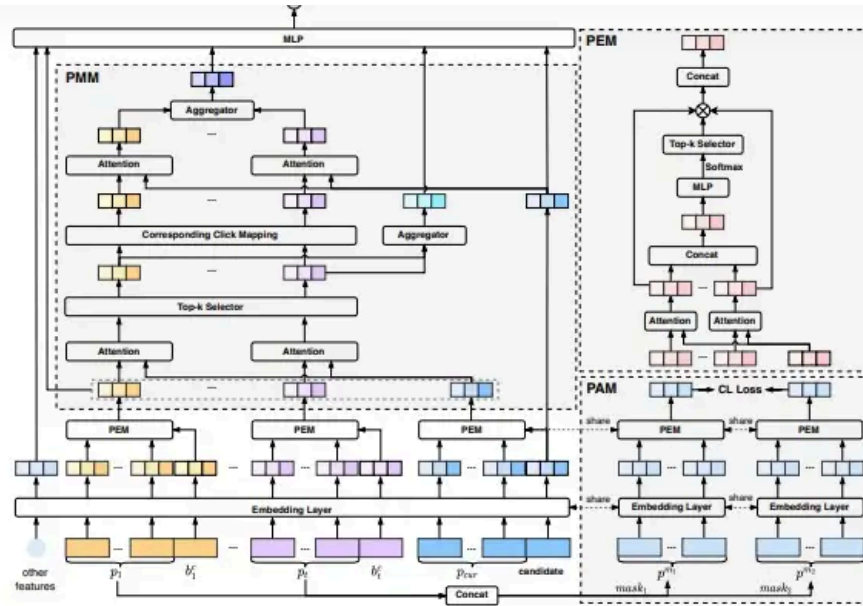


Figure 2: Structure of DBPMaN. (1) PEM enhances the path representations. (2) PMM matches the paths. (3) PAM augments the paths.

Path Enhancing Module (PEM)

对于行为路径 $[b_{m(i)-l}, \dots, b_{m(i)-2}, b_{m(i)-1}]$ 和下面的点击行为 b_i^c ，嵌入层将生成它们的嵌入，表示为 $\mathbf{e}_{m(i)-l}, \dots, \mathbf{e}_{m(i)-2}, \mathbf{e}_{m(i)-1}$ 和 \mathbf{e}_i^c 。进一步，一串嵌入

$[\mathbf{e}_{m(i)-l}, \dots, \mathbf{e}_{m(i)-2}, \mathbf{e}_{m(i)-1}]$ 被表示为 \mathbf{s}_i 。

我们首先在用户行为路径上应用局部激活单元，它执行加权连接池化以自适应计算行为路径的嵌入，如式所示。

$$\mathbf{e}_{m(i)-j}^{te} = a(\mathbf{e}_{m(i)-j}, \mathbf{e}_i^c) \cdot \mathbf{e}_{m(i)-j}, \quad 1 \leq j \leq l$$

$$\mathbf{s}_i^{te} = [\mathbf{e}_{m(i)-l}^{te}, \dots, \mathbf{e}_{m(i)-2}^{te}, \mathbf{e}_{m(i)-1}^{te}]$$

$$\mathbf{p}_i^{te} = \text{concat}(\mathbf{s}_i^{te})$$

$$\text{score}_i = \text{softmax}(\text{MLP}(\mathbf{p}_i^{te}))$$

Path Matching Module (PMM)

对于用户，其行为序列中可能存在大量行为路径，但仅有少数与当前路径相似，可体现用户当前兴趣。PMM旨在搜索与当前路径最相似的首个k个行为路径，并获取相应的k个点击行为，这些点击行为被认为对用户当前兴趣有较大贡献。具体而言，已知增强历史路径嵌入序列

$$\mathbf{P}_e = [\mathbf{p}_1^e, \mathbf{p}_2^e, \dots, \mathbf{p}_t^e]$$

和增强当前行为路径嵌入 \mathbf{p}_{cur}^e ，将每个 $\mathbf{p}_i^e \in \mathbf{P}_e$ 和 \mathbf{p}_{cur}^e 输入到一个评分门并获得一个相似性得分 g_i^p ，这反映了相应历史行为路径的重要性。评分门的计算如等式 (2.1) 所示。

$$g_i^p = \text{MLP}(\text{concat}(\mathbf{p}_{cur}^e, \mathbf{p}_i^e, \mathbf{p}_{cur}^e \otimes \mathbf{p}_i^e))$$

因此，我们可以得到一个相似度分数列表 $\mathbf{g}^p = [g_1^p, g_2^p, \dots, g_t^p]$ ，将其排序并选出前k个分数。根据这些分数，我们获取相应的历史路径和对应的点击行为。对于选中的点击行为，其序列表示为

$\mathbf{s}_c = [\mathbf{e}_{c1}, \mathbf{e}_{c2}, \dots, \mathbf{e}_{ck}]$ 。再将每个选定路径嵌入乘以相应分数，得到调整后的嵌入，如式。

$$\mathbf{E}^p = \text{concat}(\text{Filter}(\mathbf{g}^p, [g_i^p \cdot \mathbf{p}_i^e, 1 \leq i \leq t], k))$$

$$\mathbf{g}_i^c = \text{MLP}(\text{concat}(\mathbf{e}^{cl}, \mathbf{e}_{ci}, \mathbf{e}^{cl} \otimes \mathbf{e}_{ci}))$$

最后，将 \mathbf{P}_e ， \mathbf{E}^p ， \mathbf{E}^c ， \mathbf{e}^u 和 \mathbf{e}^{cl} 连接起来，然后

$$\mathbf{E}^c = \text{concat}([g_i^c \cdot \mathbf{e}_{ci}, 1 \leq i \leq k])$$

后输入到一个 MLP 层中，该层输出预测的 CTR。

数据集：我们采用以下两个数据集进行实验。

淘宝：一个公开数据集，包含10天的互动数据。[数据预处理](#)方式与CAN相同。 美团：美团外卖应用收集的工业数据集，包含1亿用户的14天互动数据。

Table 1: Statistics of datasets.

Datasets	#Users	#Items	#Categories	#Interactions
Taobao	987991	4161138	9437	100095182
Meituan	100000000	15755909	184	5648922411

DeepFM。该方法结合了因子分解机与深度学习，可处理低阶和高阶特征交互。

xDeepFM。此方法采用提出的压缩交互网络（CIN）生成特征交互，并将CIN和一个基础深度神经网络进一步组合成统一的模型。

DIN。此方法设计了一个局部激活单元，用于学习与候选相关的历史行为中的用户兴趣表示。

DIEN。此方法设计了一个兴趣提取器层和一个兴趣演化层，以从行为序列中捕获兴趣。

ONN。此方法为不同的操作学习不同的表示。

CAN。此方法通过协同作用单元解开表示学习和特征交互建模的纠缠。

****度量标准****

在离线实验中，我们采用AUC和RelaImpr作为评估标准；在线实验中，我们选取CTR和CPM(Cost-Per-Mille) 作为评估标准。

****实现细节****

我们利用Tensorflow实现了DBPMan。对于所有模型，我们选择Adam优化器，并设定学习率为0.001。模型参数以[高斯分布](#)进行初始化（均值设为0，[标准差](#)为0.01）。此外，物品嵌入的维度设置为18。

Table 2: Performance results on offline evaluations.

Model	Taobao		Meituan	
	AUC	RelaImpr	AUC	RelaImpr
DeepFM	0.8125	-13.19%	0.6673	-1.55%
xDeepFM	0.8366	-10.61%	0.6693	-1.25%
ONN	0.8689	-7.16%	0.6705	-1.08%
DIN	0.9308	-0.54%	0.6753	-0.37%
DIEN	0.9324	-0.37%	0.6761	-0.25%
CAN	0.9359	0.00%	0.6778	0.00%
DBPMan	0.9381	0.24%	0.6812	0.50%

Performance Comparison

我们进行了比较实验，将我们的模型与上述竞争对手进行了比较。两个数据集上不同模型的表现结果如表所示。从结果我们发现，所有模型在两个数据集上的表现排名相同，我们的DBPMan超越了所有竞争对手。我们认为，DBPMan中的路径到路径激活[注意力机制](#)有助于击败其他模型，包括基于注意力模型(即DIN、DIEN和ONN)，这些模型采用候选人和历史行为序列中个人行为的点对点激活。有趣的是，我们的DBPMan模型在美团数据集上的表现比淘宝数据集上对其他模型

路径变得容易。

Ablation Study

我们在美团数据集上进行了消融实验，以评估DBPMaN关键模块的贡献。比较了三个变体，即DBPMaN w/o PEM、DBPMaN w/o PMM和DBPMaN w/o PAM。结果如表所示。从表中可以发现，与原始DBPMaN相比，这三个变体在所有三个指标上都存在下降。其中DBPMaN w/o PMM的性能下降幅度最大，这表明PMM比其他两个模块更为重要。

Table 3: Ablation study on Meituan dataset.

Model	AUC	CTR	CPM
DBPMaN	0.6812	-	-
DBPMaN w/o PEM	0.6789	-0.6%	-0.5%
DBPMaN w/o PMM	0.6769	-1.0%	-1.1%
DBPMaN w/o PAM	0.6801	-0.2%	-0.2%

Online A/B test

在美团外卖平台上进行了A/B测试，测试时间跨度为2022年8月10日至2022年8月23日，测试期为14天。基准模型是最后一个在线CTR模型，仅采用点对点激活方法。实验结果详见下表，其中 l 表示行为路径长度⁺。目前，DBPMaN ($l=8$) 已在线部署，为主流量用户提供服务。

备注：关注我，跟踪最新技术不迷路

编辑于 2023-11-25 12:08 · IP 属地北京

ctr 美团 推荐系统

赞同 26 添加评论 分享 喜欢 收藏 申请转载 ...



理性发言，友善互动



还没有评论，发表第一个评论吧

推荐阅读