

赞同 39

分享

## 美团2024：利用SRP4CTR预训练embedding与序列建模优化精排CTR



SmartMindAI

专注搜索、广告、推荐、大模型和人工智能最新技术，欢迎关注我

已关注

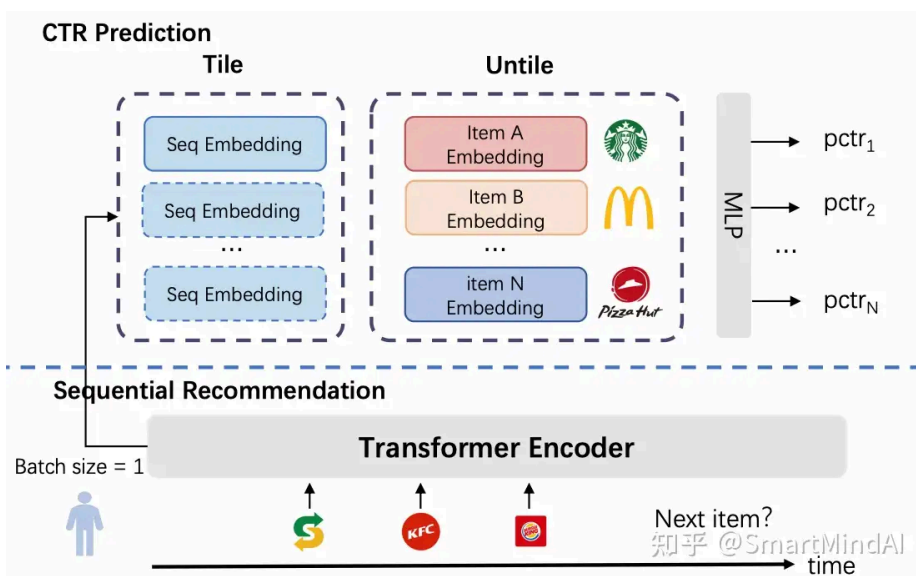
39 人赞同了该文章

收起

### Introduction

通过用户的行为序列建模是CTR预测的主要手段，更长的行为序列在工业界推荐系统中已成为趋势。传统方法倾向于通过点击标签进行监督学习，忽略了序列中的大量信息。这些信息不仅包含了内容ID，还包含了丰富的辅助信息，如价格和行为类型。为了利用和构建序列信息，引入了自我监督的预训练来解决序列推荐任务，其目标是预测下一个。受到这种启发，我们引入了自我监督预训练方法来处理CTR预测任务。然而，目前的自我监督预训练方法仅以内容ID作为输入或输出，无法充分编码辅助信息。实际上，充分挖掘内容ID和辅助信息中的信息有助于提升CTR预测的效果。

另一个挑战是如何将预训练与CTR预测任务集成。当前的方法将CTR预测与预训练模型相结合，根据编码信息的形式可以分为以下两类：1) 仅与用户相关。2) 与用户和内容相关。



在工业级的CTR预测模型中，具有极高的 QPS，在线系统使用单独的工作流来处理用户和内容。对于仅针对用户的预训练，如图所示，用户（行为序列）信息被编码一次，然后将此信息重复应用于内容，显著降低了推理成本。当在相同用户下有大量样本n可供计算时，由transformer引入的 $\mathcal{O}(L^2)$ 复杂度可以显著降低到可忽略的 $\mathcal{O}(L^2/n)$ 。然而，仅与用户相关的预训练模型只能获得序列信息的单一表达，然后将其与内容信息连接起来学习用户兴趣。这些方法未能从预训练模型

在本文中，我们提出了一种新的微调框架，旨在将基于transformer的预训练模型适应为CTR预测任务，我们称之为SRP4CTR。

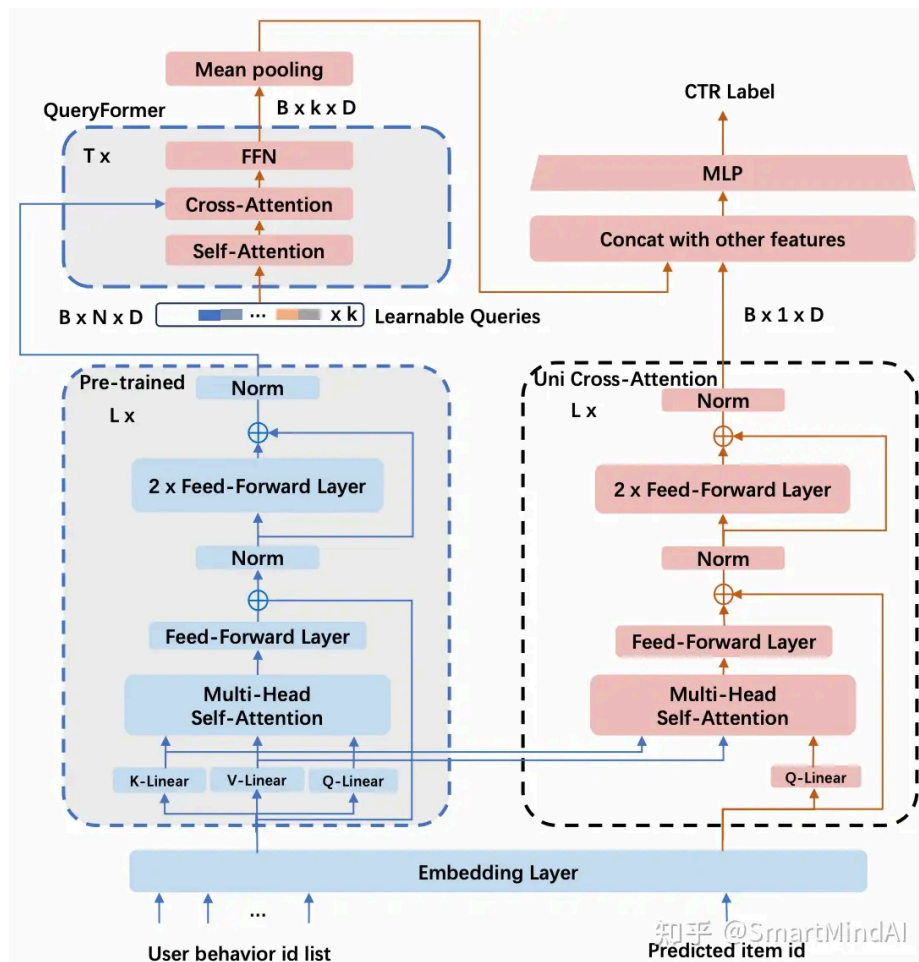
在预训练阶段，为了同时编码内容ID和辅助信息，我们引入了一个新的双向transformer模型，命名为精细粒度BERT（FG-BERT）。FG-BERT同时在输入和输出中使用所有辅助信息，并在编码辅助信息的同时进行多属性掩码预测。

在微调阶段，我们引入了一种单一交叉注意力机制，它在预测内容和预训练模型之间建立了一个单向注意力连接。大部分计算仍然可以通过折叠推理来减少，而单一交叉注意力只增加了少量的推理成本，以捕捉预测内容从预训练模型中获得的兴趣。

此外，与仅依赖单一的CLS令牌或“*mask*”令牌进行预测的序列推荐任务不同，从用户行为的数百个令牌中识别有用信息以进行CTR预测也提出了一个重大挑战。在本文中，我们提出了一个Querytransformer编码器<sup>+</sup>，使用少量可学习的Query令牌来聚合数百个用户行为令牌，然后将它们传递给CTR模型。

## METHODOLOGY

SRP4CTR旨在利用基于transformer的预训练序列来提升CTR任务的学习效率。




## Sequential Recommendation Pre-training

自监督预训练用于解决数据稀疏问题、增强数据表示，并提高长尾商品的推荐性能。我们采用的方法是，利用双向transformer进行建模，并使用封闭式目标进行自监督预训练。然而，与大多数仅需要建模商品ID的序列推荐任务不同，现实世界的推荐系统涉及用户点击日志，其中包含的不仅仅是商品ID，还有各种侧信息。对于预训练模型，其下游任务是CTR预测，因此编码不仅需要商品ID，还需要相应的侧信息。为了解决这个问题，我们提出了精细粒度BERT（FG-BERT）来完成任

等，形式上：

$$\mathbf{S}_i = [(f_{i1}, f_{i2}, \dots, f_{iM}), (b_{i1}, b_{i2}, \dots, b_{iN})]$$

FG-BERT通过进一步引入预测行为相关特征的训练目标，增强了BERT的编码效果。具体来说，由于商品ID和其对应的属性特征是明确关联的，我们直接将商品相关特征的嵌入求和，得到第*i*个记录的内容通用表示 $\mathbf{x}_i$ 。同样，我们将所有行为相关特征的嵌入求和，得到侧信息表示 $\mathbf{s}_i$ 。



如图所示，在FG-BERT中，我们引入了两种不同类型的随机mask：内容相关mask和行为相关mask。对于行为相关mask，我们移除一个元素的与行为相关的所有动作。mask表示为：

$$\mathbf{s}^* = \{\mathbf{s}_{j_1}, \mathbf{s}_{j_2}, \dots, \mathbf{s}_{j_p}\}, j_p < L$$

剩余的集合表示为 $\tilde{\mathbf{s}}$ 。相应地，内容相关mask的集合表示为：

$$\mathbf{x}^* = \{\mathbf{x}_{k_1}, \mathbf{x}_{k_2}, \dots, \mathbf{x}_{k_q}\}, k_q < L$$

剩余的集合表示为 $\tilde{\mathbf{x}}$ 。对于FG-BERT，给定 $p(\mathbf{s}^*)$ 和 $p(\mathbf{x}^*)$ 的概率分别为：如上所述，FG-BERT通过预测行为相关特征进一步提升了编码效果，确保了模型在处理长尾商品推荐任务时的性能。

$$p(\mathbf{x}^*; \Theta) = \prod_i^q p(\mathbf{x}_{k_i} | \tilde{\mathbf{x}}, \tilde{\mathbf{s}}; \Theta)$$

$$p(\mathbf{s}^*; \Theta) = \prod_i^p \prod_n^N p(b_{j_i, n} | \tilde{\mathbf{x}}, \tilde{\mathbf{s}}; \Theta)$$

通过最大化概率 $p(\mathbf{x}^*; \Theta)$ 和 $p(\mathbf{s}^*; \Theta)$ ，FG-BERT采用了多任务方法，以确保 $\Theta$ 是模型的可训练参数，其中。FG-BERT通过交叉熵<sup>+</sup>（CE）损失优化上述目标，以最大化 $p(\mathbf{x}^*; \Theta)$ 和 $p(\mathbf{s}^*; \Theta)$ 的概率。

## Fine-tune for CTR Prediction

### uni cross-attention block

对于下游点击率<sup>+</sup>任务，我们引入了一种单向交叉注意力，使得预测的内容能够从预训练模型中转移相应的信息。如图所示，在单向交叉注意力中，Query由预测的内容组成，而Key和Value则来源于同一层的用户行为序列表示。虽然预测内容与预训练模型的输入共享了相同的表现信息，但在自我监督学习的注意力机制下，与点击率任务所需的注意力机制存在显著差异。因此，我们解绑了单向交叉注意力块与预训练模型之间的参数共享，仅在每一层共享输入的嵌入参数以及Key和Value的投影参数。

在多头自我注意力层之后，预测内容的编码特征将通过基于transformer的层中的前馈网络和残差网络<sup>+</sup>进行处理。此外，我们设置了一个可学习的位置嵌入变量来预测内容，以避免位置语义变化带来的问题。

### Querying Transformer

过交叉注意力机制<sup>+</sup>将预训练模型的输出作为Key和Value进行编码。这个模块旨在区分用户兴趣。此外，在实际应用中，我们还使用用户或上下文特征（如性别、年龄或时间）作为Query的初始化，然后将其映射为多个不同的Query，以适应不同用户的多样化兴趣分布。最后，QueryTransformer仅处理用户信息，从而实现高效推理。

Offline Experiments

Overall Performance

SRP4CTR的整体性能在表中展示。

Table 1: Results (AUC) on public datasets.

| Methods    |                        | MovieLens     | Taobao        |
|------------|------------------------|---------------|---------------|
| CTR based  | PNN[14]                | 0.7376        | 0.6006        |
|            | BST[3]                 | 0.7359        | 0.6021        |
|            | DIN[21]                | 0.7466        | 0.6066        |
|            | DIEN[20]               | 0.7494        | 0.6178        |
|            | CAN[1]                 | 0.7507        | 0.6018        |
| BERT[15]   | BERT-MP                | 0.7595        | 0.5633        |
|            | <b>BERT-SRP4CTR</b>    | 0.7696        | 0.6208        |
| ELECTRA[5] | ELECTRA-MP             | 0.7559        | 0.5580        |
|            | <b>ELECTRA-SPR4CTR</b> | 0.7603        | 0.6197        |
| S3[22]     | S3-MP                  | 0.7526        | 0.5576        |
|            | <b>S3-SRP4CTR</b>      | 0.7592        | 0.6203        |
| FG-BERT    | FG-BERT-MP             | 0.7721        | 0.5651        |
|            | <b>SPR4CTR</b>         | <b>0.7817</b> | <b>0.6230</b> |

我们主要对比了五种传统的点击率（CTR）基于方法：PNN、BST、DIN、DIEN和CAN。我们的策略在各种数据集上展示了对传统端到端建模方法的显著改进。从表可以看出，我们提出的FG-BERT优于其他预训练方法。此外，在MovieLens数据集上，仅通过微调（MP），预训练模型就能超越CTR方法。但是，对于更稀疏的淘宝数据集，MP的性能不如基于CTR的模型。

Long Tail Performance

在表中，我们深入研究了SRP4CTR推荐长尾内容的有效性。

| Methods        | MovieLens     |                | Taobao        |                |
|----------------|---------------|----------------|---------------|----------------|
|                | AUC           | AUC diff       | AUC           | AUC diff       |
| DIN            | 0.7205        | -0.0261        | 0.6044        | -0.0022        |
| CAN            | 0.7208        | -0.0299        | 0.5957        | -0.0061        |
| FG-BERT-MP     | 0.7591        | <b>-0.0130</b> | 0.5686        | <b>+0.0035</b> |
| <b>SRP4CTR</b> | <b>0.7679</b> | -0.0139        | <b>0.6225</b> | <b>-0.0005</b> |

我们将数据集中出现频率最低的20%的内容定义为长尾内容，并在子数据集上比较了我们方法和传统CTR预测方法<sup>+</sup>的性能。传统的CTR预测方法，如DIN和CAN，倾向于从热门内容中学习得更有效，因此在长尾内容的AUC与所有内容平均AUC之间存在显著的差距。然而，通过预先训练，MP和SRP4CTR都能显著减少长尾内容与其他内容之间的学习差距。

Online A/B test

知乎

的角度来看，与之前的最先进的基线（DIN+MMOE）相比，我们的模型在每秒浮点运算<sup>+</sup>次数（FLOPs）上实现了182%的效率提升。同时，借助推理框架，推理FLOPs仅增长了21%，保持了较高的效率。



原文《Enhancing CTR Prediction through Sequential Recommendation Pre-training: Introducing the SRP4CTR Framework》

编辑于 2024-09-04 11:12 · IP 属地北京

推荐系统 ctr预估 预训练模型



理性发言，友善互动

1 条评论

默认 最新



克里斯不汀

uniCross attention部分做不到只推理一次吧？和候选item有关联。

08-25 · 中国台湾

回复 喜欢

推荐阅读



图技术在美团外卖下的场景化应用及探索

美团技术团... 发表于美团技术博...



新上线美团医美机构运营方案（方法论）

驰知余



医美美团运营方案全攻略（方法论+实操案例拆解）

会飞的鱼 发表于会飞的鱼

美团推荐ATIM：Model the Sequential Depen

这是美团与浙大等高校合作，金融信用卡推荐业务的文章，在KDD2021上，是一种对多习模型的升级，作者还公开了（见reference）背景在推荐里，用户的转化链路往往有多 Glenn