



## 阿里2023推荐技术前沿分享：即时动态兴趣捕捉与CTR预估新突破



SmartMindAI

专注搜索、广告、推荐、大模型和人工智能最新技术，欢迎关注

已关注

53 人赞同了该文章

### Introduction

在工业界，**个性化推荐系统**<sup>+</sup>得到了广泛的应用。以一个电商应用为例，其主要目标是估计用户点击某个项目的可能性。

本文关注如何准确估计Trigger-Induced Recommendation (TIR)场景中的**点击率**<sup>+</sup>。尽管TIR受到越来越多的关注，但在该领域的研究仍较为缺乏。

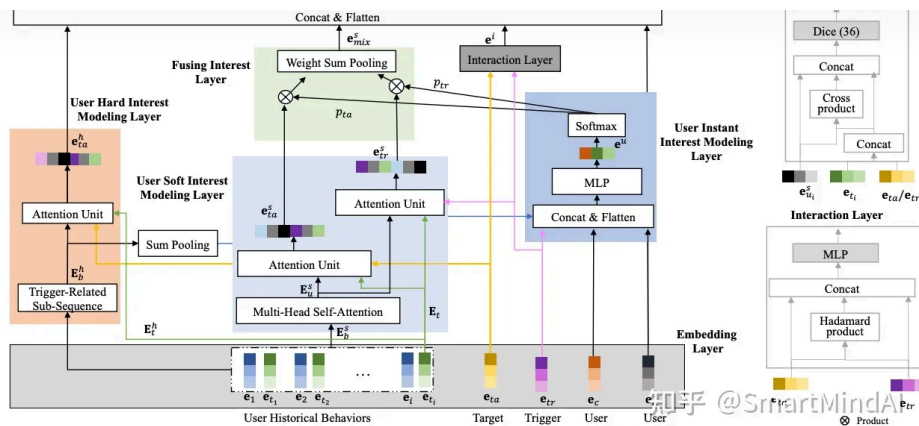
R3S 通过特征交互、语义相似性和**信息增益**<sup>+</sup>来捕捉用户的即时兴趣，但忽略了用户的过去行为这一重要因素。

DIHN 构建了一个兴趣突出网络来学习触发项的即时兴趣和用户的过去行为，但并未考虑到时间信息、用户滑动时即时兴趣的动态变化以及触发项和目标项之间的互动。

而DEI2N则提出了一种新颖的方法，用于TIR场景中的点击率预测。本论文的主要贡献如下：

- 我们将重点介绍Trigger-Induced Recommendation (TIR) 这一新兴工业推荐场景，并讨论现有的Click Through Rate (CTR)方法在此领域的应用挑战。
- 我们提出了一种新的方法DEI2N，以处理TIR场景中的复杂问题。该方法考虑了用户即时兴趣的动态变化、时间信息以及触发项和目标项之间的互动，以进一步提高CTR的性能。
- 我们已在三个真实世界的工业数据集上测试了我们的方法DEI2N，并将其与其他最先进的方法进行了比较。结果表明，我们的方法在所有竞争对手中均表现出最佳性能。此外，消元验证还证实了提出的各组件的有效性。
- 我们已在工业生产环境中实现并部署了DEI2N，并将其成功应用于五个工业电子商务的TIR场景。在线A/B测试结果显示，该方法明显优于当前的基准线。

### The Proposed Method



深度进化即时兴趣网络（DEI2N）方法，其总体结构如下图所示：我们采用了基本的CTR范例，即将Embedding Layer和MLP（多层感知器<sup>+</sup>）模型结合起来。模型共有五个主要组成部分，以便更好地捕捉用户即时兴趣在TIR场景中的变化。其中，

用户即时兴趣建模层负责考虑触发项和用户行为来模拟用户的即时兴趣，并预测当用户向下滚动时即时兴趣强度的变化；

用户软兴趣建模层和用户硬兴趣建模层则根据触发项和目标项从用户的交互中提取用户的兴趣；

而融合兴趣层则利用用户即时兴趣建模层的结果来合并用户从用户软兴趣建模层提取的兴趣；

最后，所有结果特征和剩余特征都被连接起来并输入到MLP层进行最终的CTR预测。

## Embedding Layer

一共有五组输入特征：用户信息，用户历史行为，触发项，目标项和用户上下文。

用户信息包含用户ID和国家ID等；用户历史行为是一个用户的点击或购买的行为序列；触发项和目标项包含物品ID、类别ID、公司ID等；用户上下文则包含用户当前正在浏览的页面编号。

这些特征会被编码成一维热向量，然后通过嵌入层转化为低维度密集特征。经过嵌入层处理后的用户信息、用户历史行为、触发项、目标项和用户上下文分别被表示为 $\mathbf{e}_u$ 、 $\mathbf{E}_b$ 、 $\mathbf{e}_{tr}$ 、 $\mathbf{e}_{ta}$ 和 $\mathbf{e}_c$ 。

$$t_i = \lfloor ((t - \hat{t}_i) / T_f) \rfloor$$

其中 $t$ 是推荐的时戳 $\hat{t}_i$ 是行为交互时戳 $\lfloor \cdot \rfloor$ 是对数函数。接下来，我们可以使用嵌入查找方法来获取时间间隔的嵌入表示，即 $\mathbf{e}_{t_i}$ 。最后，我们将所有的时间间隔嵌入按照时间顺序拼接在一起，形成一个时间间隔向量 $\mathbf{E}_t$ ，其维度为 $d_{time}$ 。这样，我们就得到了用户历史行为的时间间隔表示形式

$$\mathbf{E}_t = \{\mathbf{e}_{t_1}, \mathbf{e}_{t_2}, \dots, \mathbf{e}_{t_T}\} \in \mathbb{R}^{T \times d_{time}}$$

## User Instant Interest Modeling Layer

在TIR场景下，点击触发项可以反映用户的即时兴趣。因此，用户对同一类别触发项的物品初始感兴趣程度较高。然而，随着用户向下滚动，即时兴趣的强度可能会逐渐减弱。这一点已经被证实，即用户向下滚动时，与触发项同类别和不同类别的物品之间的CTR存在明显的差异。因此，能够准确捕捉到用户滚动时即时兴趣强度的变化非常重要，这是现有模型尚未充分考虑到问题。

为此，我们提出了一种新的用户即时兴趣建模层，用于预测用户滚动时即时兴趣强度的变化。在这个层中，我们引入了四个类别特征，包括“用户资料”、“用户环境”、“触发项”和触发相关子序列结果的总池化输入，并将这些输入通过MLP神经网络进行处理，得到两个概率分数 $p_{tr}$ 和 $p_{ta}$ ，它们的和为1。这两个概率分数的形式分别为：

$$p_{tr} = f(\mathbf{x}_{tr}), p_{ta} = f(\mathbf{x}_{ta})$$

其中 $\mathbf{x}_{tr}$ 和 $\mathbf{x}_{ta}$ 分别代表与触发项同类别和不同类别的物品。

在上述模型中，我们引入了一个新的特征向量  $\mathbf{E}_b^h$ ，其中包含了与触发项相同的分类行为的触发关联子序列。需要注意的是，只有当当前浏览的页面属于触发项的类别时  $\mathbf{E}_b^h$  才会包含最近交互的项目。因此  $\mathbf{p}_{tr}$  和  $\mathbf{p}_{ta}$  分别表示触发项和目标项与用户历史行为的相关程度。换句话说，它们负责确定用户对触发项或目标项的兴趣程度。此外，我们还引入了一个新的特征向量  $\mathbf{e}_c$ ，其中包含了用户正在浏览的页面号，因为我们发现页面号是一个非常强的信号，能够很好地指示用户即时兴趣强度的变化。

### User Soft Interest Modeling Layer

在传统CTR预测方法<sup>+</sup>中，通常是通过计算用户历史行为和目标项之间的相关权重来实现用户的兴趣建模。然而，将其严格地应用于TIR可能会导致不理想的结果，因为触发项显示出强烈的即时兴趣信号。因此，在考虑触发项和目标项时是必要的。

为此，我们提出了一个名为User Soft Interest Modeling Layer的方法，该方法可以通过使用Multi-Head Self-Attention (MHSA) 来改进从用户历史行为中提取的物品表示，并引入残差连接<sup>+</sup>、丢弃和层标准化来进一步提高物品表示。为了更明确地引入时间信息，MHSA的输入被表示为  $\mathbf{E}_b^s$ ，它是用户历史行为向量  $\mathbf{E}_b$  和时间间隔向量  $\mathbf{E}_t$  的拼接。具体来说，MHSA的形式如下：

$$(\mathbf{E}_b, \mathbf{E}_t)^T \xrightarrow{\text{MHSA}} \mathbf{E}_m$$

$$\mathbf{E}_u^s = \text{MHSA}(\mathbf{E}_b^s) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_{H_R}) \mathbf{W}^O$$

$$\mathbf{E}_u^s = \text{MHSA}(\mathbf{E}_b^s) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_{H_R}) \mathbf{W}^O, \quad (2)$$

$$\text{head}_h = \text{Attention}(\mathbf{E}_b^s \mathbf{W}_h^Q, \mathbf{E}_b^s \mathbf{W}_h^K, \mathbf{E}_b^s \mathbf{W}_h^V)$$

$$= \text{Softmax}\left(\frac{\mathbf{E}_b^s \mathbf{W}_h^Q \cdot (\mathbf{E}_b^s \mathbf{W}_h^K)^T}{\sqrt{d_h}}\right) \cdot \mathbf{E}_b^s \mathbf{W}_h^V, \quad (3)$$

其中：

$$\mathbf{W}_h^Q, \mathbf{W}_h^K, \mathbf{W}_h^V \in \mathbb{R}^{d_{\text{model}} \times d_h}$$

是第  $h$  个头查询、密钥和值投影矩阵，其中  $d_{\text{model}}$  是模型的维度  $d_h$  是每个头的维度  $\text{head}_h$  表示一个在子空间<sup>+</sup>中的潜在物品表示。接下来，我们使用两个注意力单元分别提取与目标项和触发项相关的用户兴趣，同时这两个注意力单元也利用了时间信息来改善序列建模<sup>+</sup>并更好地捕捉到用户针对目标项和触发项的兴趣的相关性。需要注意的是，时间信息是用户历史行为的时间间隔表示。例如，可以表示为目标注意力为：

$$A_t^{\text{target}} = \frac{\mathbf{e}_i \cdot (\mathbf{W}_{\text{target}}^Q \text{head}_i + b_{\text{target}})}{\sqrt{\sum_j \mathbf{e}_j \cdot (\mathbf{W}_{\text{target}}^Q \text{head}_j + b_{\text{target}})}}$$

$$\mathbf{e}_{ta}^s = \sum_{j=1}^T a(\mathbf{e}_{u_j}^s; \mathbf{e}_{t_j}; \mathbf{e}_{ta}) \mathbf{e}_{u_j}^s = \sum_{j=1}^T w_{ta_j} \mathbf{e}_{u_j}^s$$

其中

$$\mathbf{e}_{u_j}^s \in \mathbb{R}^{d_{\text{model}}}$$

表示应用注意力机制<sup>+</sup>后的第  $j$  个用户的表示

$$\mathbf{e}_{t_j} \in \mathbb{R}^{d_{\text{time}}}$$

表示第  $j$  个时间间隔的嵌入  $\mathbf{a}$  是图中右上角所示的关注单元。

### User Hard Interest Modeling Layer

该层采用了SIM和DIHN中的硬序列建模方法，通过聚合与触发项类别相同的触发相关子序列来补充提取用户的即时兴趣。这样有助于过滤无关噪音，并覆盖较长的用户历史行为期。子序列的长度

Fusing Interest Layer

$$\mathbf{e}_{mix}^s = p_{tr} \cdot \mathbf{e}_{tr}^s + p_{ta} \cdot \mathbf{e}_{ta}^s$$

其中 $p_{tr}$ 和 $p_{ta}$ 是在 User Instant Interest Modeling Layer 中预测的概率 $\mathbf{e}_{tr}^s$ 和 $\mathbf{e}_{ta}^s$ 是分别针对触发项和目标项时从 User Soft Interest Modeling Layer 提取的用户兴趣表示。

Interaction Layer

交互层接受触发项和目标项作为输入，并通过Hadamard乘法和MLP层学习高阶特征交互。具体来说，Hadamard乘法是一种运算，可以将两个向量相乘并得到一个新的向量。而MLP层则是一个多层感知器网络，它可以对输入的数据进行一系列复杂的处理，最终输出结果。

$$\mathbf{e}^i = \text{MLP}(\mathbf{e}_{ta}; \mathbf{e}_{tr}; \mathbf{e}_{tr} \times \mathbf{e}_{ta})$$

Loss Function

最后，将所有的特征向量 $\mathbf{e}_{mix}^s$ 、 $\mathbf{e}_{ta}^h$ 、 $\mathbf{e}^i$ 和 $\mathbf{e}_u$ 连接在一起，然后通过一个MLP层来进行CTR预测。最后，他们采用了二进制交叉熵损失函数作为损失函数，这是因为这个损失函数在CTR预测任务中已经被广泛应用。

Evaluation

Datasets

他们在三个真实世界数据集上进行了评估。这些数据集的信息被汇总在表格中，并且分别在表中。此外，作者还解释了他们是如何处理阿里巴巴+网站和阿里妈妈+的数据集的。对于阿里巴巴网站的数据集，他们将其转换为一个包含正样本+（用户点击列表中显示的商品）和负样本（未点击商品）的数据集。而对于阿里妈妈的数据集，他们手动设置了触发项，并根据时间限制选择了最新四小时内被点击的样本作为触发项。最后，他们也提供了一个名为ContentWise的数据集来测试他们的方法在不同领域的有效性。他们人工设置了触发项，并根据时间限制选择了最近八小时内被点击的样本作为触发项。当用户查看、购买、评价或访问媒体项时，标签设为正。

Table 1: Statistics of the offline datasets.

Dataset	Users	Items	Categories	Samples
Alibaba.com	373,852	4,715,150	6,736	5,200,000
Alimama	500,000	846,812	12,978	8,552,702
ContentWise	26,186	1,268,988	117,693	2,583,070

Compared Methods

为了验证我们提出的方法的有效性，我们将它与一系列先进的方法进行比较，包括Wide&Deep、DIN、DIEN、DMIN、DIHN和DIAN。我们也重新实现了这些方法，并为其增加了即时兴趣建模的功能，以确保公平和可靠的比较。

- 在 Wide&Deep+TR 模型中，将触发项作为输入加入到捕捉用户即时兴趣的过程中。
- DIN+TRA 模型通过注意力机制来提取与触发项相关的用户即时兴趣，并考虑到现有目标的关注。
- DIEN+TRA 模型使用了与DIN+TRA中相似的注意力策略，以更好地模拟用户的即时兴趣和用户的发展兴趣。
- DMIN+TRA 模型采用了与DIN+TRA相同类型的注意力策略，用于捕捉用户的即时兴趣，并从用户的历史行为中提取多个兴趣。这是一项在线A/B测试实验的基准方法。

参数设置如下： $d_{model} = 72$   $d_{time} = 36$ , 用户profile维度和user context维度分别为36和10; 学习率为0.001, dropout率设为0.1;

在多头注意力模型(MHSA)中, 使用头部数 $H_R = 2$ , 标准化因子 $T_f$ 统一设为60 (每分钟计算时间间隔特征); 用户行为序列最大长度设为20、30和30; 用户触发相关的行为子序列最大长度设为10、20和10; 最后的全连接层神经网络的隐藏层维度和DIEN模型的隐藏层维度一致, 均为200和80; 交互层的全连接层神经网络的隐藏层尺寸为144和72, 而用户即时兴趣建模层的隐藏层尺寸为72和36。

Performance Comparison

我们使用ROC曲线+下面积 (AUC) 和RelaImpr作为评估指标, 这些指标在CTR预测任务中广泛应用。实验结果将在三个实际数据集上呈现。在TIR场景下, 我们发现传统的Wide&Deep、DIN、DIEN和DMIN方法表现不佳, 尤其是在阿里巴巴.com数据集上。经过添加触发项后, 差距超过了20%。主要原因是没有考虑触发项。一旦装备了即时兴趣建模的能力, 它们的表现将进一步提高。这些结果也表明了通过考虑触发项对TIR进行精细建模的必要性。

我们将DEI2N方法与DIHN、DIAN及传统方法进行对比。DMIM+TRA是所有传统方法中的最佳, 实现最优效果。DIAN优于改进版的传统方法, 除了ContentWise外。因为其能够同时处理触发项和目标项。我们的DEI2N方法在所有最先进的方法中获得最高AUC值。

Model	Alibaba.com		Alimama		ContentWise	
	AUC	RelaImpr	AUC	RelaImpr	AUC	RelaImpr
Wide&Deep	0.6096 ± 0.0019	-0.99%	0.6062 ± 0.0008	-7.97%	0.9469 ± 0.0003	-7.28%
DIN	0.6042 ± 0.0016	-5.87%	0.6154 ± 0.0007	0.00%	0.9774 ± 0.0002	-0.95%
DIEN	0.6047 ± 0.0025	-5.42%	0.6155 ± 0.0005	0.09%	0.9779 ± 0.0013	-0.85%
DMIN	0.6107 ± 0.0011	0.00%	0.6154 ± 0.0002	0.00%	0.9820 ± 0.0002	0.00%
Wide&Deep+TR	0.7412 ± 0.0014	111.89%	0.6075 ± 0.0018	-6.84%	0.9713 ± 0.0004	-2.22%
DIN+TRA	0.7425 ± 0.0021	119.06%	0.6155 ± 0.0015	0.09%	0.9803 ± 0.0019	-0.35%
DIEN+TRA	0.7419 ± 0.0019	118.52%	0.6157 ± 0.0004	0.26%	0.9796 ± 0.0015	-0.50%
DMIN+TRA	0.7454 ± 0.0007	121.68%	0.6157 ± 0.0003	0.26%	0.9822 ± 0.0003	0.04%
DIHN	0.7462 ± 0.0006	122.40%	0.6166 ± 0.0008	1.04%	0.9786 ± 0.0012	-0.75%
DIAN	0.7480 ± 0.0016	124.03%	0.6168 ± 0.0002	1.21%	0.9769 ± 0.0003	-1.18%
DEI2N	0.7671 ± 0.0012	141.28%	0.6180 ± 0.0005	2.25%	0.9840 ± 0.0002	0.41%

结果显示, 考虑到用户瞬时兴趣变化的有效性有助于模型理解和应用上下文。此外, 模型利用了用户历史行为的`时间序列`信息, 以及触发项和目标项之间的交互。在阿里巴巴.com上的AUC增加了2.55%, 但相比于Alimama和ContentWise的数据集, 增长较小, 可能是因为这些数据集并未直接从TIR场景收集, 合成的触发项可能不能完全反映TIR真实情况, 此外, 缺乏上下文特征如页面号可能导致模型性能受限。

Online A/B Testing Results

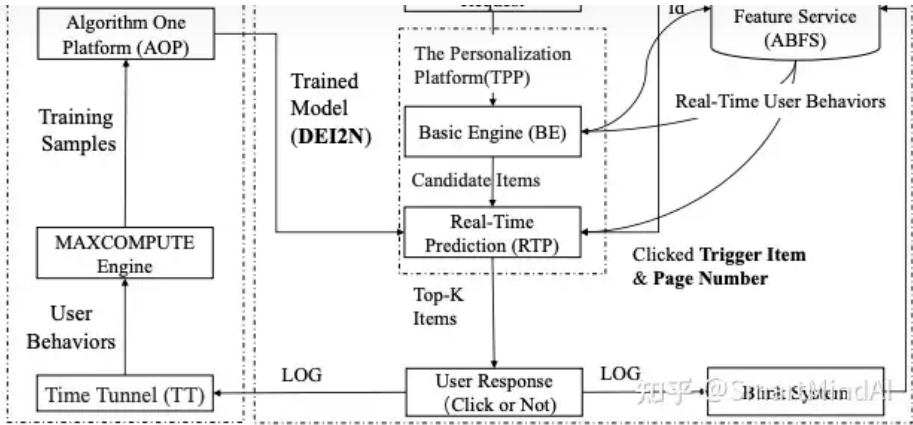
除了离线性能比较, 我们在阿里巴巴`在线推荐`系统中部署了我们的提议方法DEI2N进行A/B测试。DEI2N利用了阿里巴巴集团的多个算法平台部署在阿里巴巴在线推荐系统中。

图3展示了在线部署流程图。基本上, 这个部署由两个主要部分组成: 在线和离线部分。在线部分负责生成最终的top-k项将被暴露给最终用户。具体来说, 个性化平台 (TPP) 接受包含触发项和页面号等上下文特征的实时请求。然后它会顺序处理匹配和排名模块。基本引擎 (BE) 承担匹配角色, 它会从数十百万个候选项目池中生成数千个候选项目。所有基本服务 (ABFS) 都在这里使用, 以返回必要的用户特征, 例如用户简介特征、实时用户历史行为等。



知乎

首发于  
AI 长风破浪



排序模型由实时预测（RTP）承担，其中我们的提议模型DEI2N正在部署。它负责计算候选项目的CTR分数。然后最后的top-k项将被暴露给终端用户。注意，有可能在RTP上部署多个模型，这使得方便地进行A/B测试成为可能。对于离线部分，它记录用户的日志并使用大数据平台MAXCOMPUTE处理这些日志。算法一个平台（AOP）将接收处理后的训练样本，并使用DEI2N模型进行训练。一旦训练完成，它将推送到RTP进行在线服务。

Table 3: Ablation experimental results on Alibaba.com dataset.

Model	Alibaba.com	
	AUC	RelaImpr
DEI2N-NO-UI2M <sup>a</sup>	0.7534 ± 0.0012	-5.13%
DEI2N-NO-TIM <sup>b</sup>	0.7652 ± 0.0013	-0.71%
DEI2N-NO-IL <sup>c</sup>	0.7639 ± 0.0008	-1.20%
DEI2N-NO-UHIM <sup>d</sup>	0.7651 ± 0.0004	-0.75%
DEI2N-NO-USIM <sup>e</sup>	0.7504 ± 0.0010	-0.7%
<b>DEI2N</b>	<b>0.7671 ± 0.0012</b>	<b>0.00%</b>

<sup>a</sup> DEI2N without User Instant Interest Modeling Layer

<sup>b</sup> DEI2N without temporal information modeling

<sup>c</sup> DEI2N without Interaction Layer

<sup>d</sup> DEI2N without User Hard Interest Modeling Layer

<sup>e</sup> DEI2N without User Soft Interest Modeling Layer

我们对五个不同的触发诱导推荐场景进行了几个星期的A/B测试，包括“迷你细节”和“详细推荐”。考虑到DIAN在离线实验中的相对小的改进（通常部署新模型到生产环境的努力并不容易），在商业增长压力下，我们使用已经在线部署的DMIN+TRA作为在线基准模型。DEI2N分别使五种场景的转化率提高了1.31%，0.56%，1.53%，1.13%和0.89%。通过未配对t检验，这些改善是统计学上的显著的。值得一提的是，DEI2N和DMIN+TRA之间的在线平均响应时间几乎相同。因此，DEI2N已经在上述TIR场景中为每天数百万用户提供服务。这表明DEI2N在真实且可扩展的生产环境中具有有效性。

原文《Deep Evolutional Instant Interest Network for CTR Prediction in Trigger-Induced Recommendation》

发布于 2024-03-06 10:45 · IP 属地北京

ctr预估 工业级推荐系统 阿里系

赞同 53 添加评论 分享 喜欢 收藏 申请转载



理性发言，友善互动

表情符号输入框

发布