

## 微软亚研院2023-PGSP：个性化图信号处理助推推荐系统效果提升



SmartMindAI

专注搜索、广告、推荐、大模型和人工智能最新技术，欢迎关注我

已关注

3 人赞同了该文章

### Introduction

个性化偏好完全由用户的历史交互决定，但是，在许多推荐系统中由于数据稀疏问题，少量的历史交互可能不足以准确描述用户的偏好。本文提出了一种PGSP方法，实验显示PGSP有优越预测精度，且具有高训练效率，分析发现混合频率图滤波器是非参数方法。本工作的主要贡献如下

- 一种个性化图信号与增强相似度图方法，用于刻画用户兴趣并提供更个性化的推荐。
- 我们研究了高频信号在观察中的有效性，提出了一种混合频率图滤波器以提高准确性。该滤波器通过调整全局平滑信号和局部平滑信号的比例来实现。
- 我们提出了一种名为PGSP的个性化图信号处理方法，它结合了个性化图信号、增强相似度图和混合频率图滤波器。实验结果表明，相比于最先进的CF方法，PGSP可以获得更高的精度。

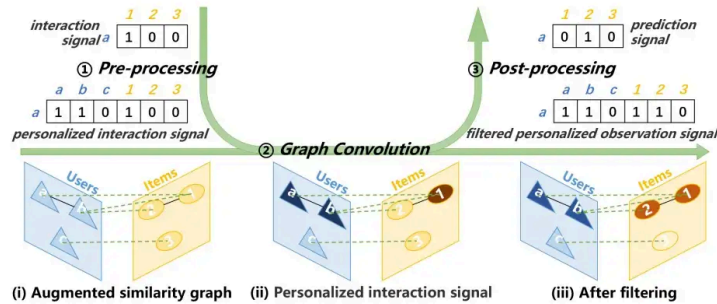


Figure 4: The proposed PGSP method. The personalized graph signal is constructed in the pre-processing stage and input into the augmented similarity graph, which promotes users' potential interests.

### Preliminaries

GSP介绍及在CF中的应用

### Graph Signal Processing

$$TV(\mathbf{x}) = \mathbf{x}^T L \mathbf{x} = \sum_{(v_i, v_j) \in \mathcal{E}} w_{ij} (x_i - x_j)^2. \quad \frac{\|\nabla \cdot \mathbf{x}\|_2}{\|\mathbf{x}\|_2} = \sup_{\mathbf{v} \in C_0^1(\Omega)} \frac{\|\mathbf{x} - \mathbf{v}\|_2}{\|\mathbf{v}\|_2}$$

$$Ray(\mathbf{x}) = \frac{TV(\mathbf{x})}{E(\mathbf{x})} = \frac{\mathbf{x}^T L \mathbf{x}}{\mathbf{x}^T \mathbf{x}} = \frac{\sum_{(v_i, v_j) \in \mathcal{E}} w_{ij} (x_i - x_j)^2}{\sum_{v_i \in \mathcal{V}} x_i^2}.$$

量。

通过 $U^T x_i$ 得到信号 $x_i$ 的图傅立叶变换，并称之为图信号 $x_i$ 在频率域的表现。反过来，通过 $U x_i$ 可以恢复出信号 $x_i$ 。

$$Ray(\mathbf{x}) = \frac{\mathbf{x}^T \mathbf{L} \mathbf{x}}{\mathbf{x}^T \mathbf{x}} = \frac{\mathbf{x}^T \mathbf{U} \mathbf{\Lambda} \mathbf{U}^T \mathbf{x}}{\mathbf{x}^T \mathbf{U} \mathbf{U}^T \mathbf{x}} = \frac{\tilde{\mathbf{x}}^T \mathbf{\Lambda} \tilde{\mathbf{x}}}{\tilde{\mathbf{x}}^T \tilde{\mathbf{x}}} = \frac{\sum_{v_i \in \mathcal{V}} \lambda_i \tilde{x}_i^2}{\sum_{v_i \in \mathcal{V}} \tilde{x}_i^2}.$$

$$\mathcal{H} = U \text{diag}(h(\lambda_1), h(\lambda_2), \dots, h(\lambda_n)) U^T, \mathcal{G}[\mathbf{x}] = h(\mathbf{x}) * \mathbf{x} \\ \mathbf{y} = \mathcal{H} \mathbf{x} = U \text{diag}(h(\lambda_1), h(\lambda_2), \dots, h(\lambda_n)) U^T \mathbf{x}.$$

将图信号从时域转换为频域并应用滤波器，然后再将结果从频域转换回时域的过程称为变换域处理。

### Motivation of Using GSP in CF


从谱域角度看，真实偏好是低频信号，而噪声是高频信号。观测的交互信号是低频信号与高频信号融合。我们通过图卷积有效解决CF问题，关键在于设计由频率响应函数决定的图滤波器。对于式( )，取

$$\mathbf{x} = \mathbf{u}_i,$$

可得

$$Ray(\mathbf{u}_i) = \lambda_i,$$

这意味着对应小特征值的特征向量更为平滑，在全图层上具有平滑性，如全局平滑。当将谱域信号恢复到空间域时，若仅使用更平滑的特征向量作为基矢量，则重构的空间信号在整个图层上具有更低的频率。



**Figure 2: The previous GSP-based CF method. The interaction signal is directly input into the similarity graph.**

图(i)显示了先前工作中使用的项相似图。我们用1表示强节点信号，用0表示弱节点信号。输入图信号为(1, 0, 0)，使得项1具有强节点信号，如图(ii)所示。通过图卷积后，图信号变得平滑，即相似项具有相似的图信号。这改善了项2的信号，并将其推荐给用户a，如图(iii)所示。然而，我们认为真实用户偏好和这两种噪声不能简单地通过频率从谱域分离出来。具体来说，全局平滑信号主要由一般偏好主导，可能不足以捕捉个性化偏好。因此，有必要引入局部平滑但全球粗糙的信号来捕获个性化的偏好，这有助于提高推荐质量。

### The PGSP Method

- 个性图信号: 它包含了更多的用户个性化信息，以便更精确地描述用户。
- 增强相似图，它有更多的图拓扑信息来更有效地利用个性化的图信号。
- 混合频率图滤波器可以同时实现全球信号的平滑和个性化信号的粗糙。

我们提出了 PGSP管道的方法，它包括预处理、图卷积和后处理三个部分，旨在提高准确性。在这个方法中，我们假设存在 $m$ 个用户和 $n$ 个物品，并且它们之间的交互矩阵为 $\mathbf{R} \in \{0, 1\}^{m \times n}$ ，其中 $\mathbf{R}_{ij} = 1$ 表示用户 $i$ 与物品 $j$ 进行了交互。

# 知乎

本文首先介绍通过随机游走基于图结构构建相似矩阵的方法，随后提出个性化图信号与增强相似图的概念。

## Construction of Similarity Graph

仅考虑图的**拓扑结构**<sup>+</sup>时，**node2vec**<sup>+</sup>的结论是：两个节点之间的相似性受以下三因素影响：

- 1) 两节点间路径数量
- 2) 路径长度
- 3) 组成每条路径的节点度

随机游走中，通常存在大量高相似度的短路径连接两个节点，而构成每条路径的节点的度不应过大，以免导致通过每条路径的概率过低。对于只有用户-物品交互信息的**协同过滤**<sup>+</sup>问题，我们只能使用交互图的结构。因此，在构建相似图时，这三个因素应作为**先验知识**<sup>+</sup>。由于用户-物品交互图是**二分图**<sup>+</sup>，即用户直接连接到物品，两条用户/物品路径必须经过中间用户/物品。因此，我们在计算用户-用户相似性、物品-物品相似性和用户-物品相似性时需要同时考虑用户节点和物品节点的度。交互矩阵表示用户节点与物品节点之间存在一条长度为1的路径。然而，原始交互矩阵不能用于描述用户和物品之间的相似性，因为其没有考虑节点的度。因此，我们引入了归一化交互矩阵来表示用户和物品之间的相似性，其定义如下：

$$S_{UI} = (D_U)^{-1/2} R (D_I)^{-1/2}.$$

$D_U$ 和 $D_I$ 为列向量，其中 $(D_U)_{ii} = \sum_{j=1}^n R_{ij}$ ， $(D_I)_{jj} = \sum_{i=1}^m R_{ij}$ 。

**随机游走模型**<sup>+</sup>中，边的权重仅由连接其端点的节点度决定。越频繁与其他节点互动，对该体的描述能力越弱，与该个体相似的物品也越少；反之亦然。

$$S_U = S_{UI} S_{UI}^T, \quad S_I = S_{UI}^T S_{UI}.$$

从随机行走的角度看， $S_U$ 通过模拟用户节点到物品节点（ $S_{UI}$ ）、再到用户节点（ $S_{UI}^T$ ）的两步步行过程来构建。具有更长的多条路径和更高权重的这些路径表示这两个用户节点之间的相似性更高。对于项项**相似度矩阵**<sup>+</sup>  $S_I$ ，也有类似的观点。需要强调的是，在这种情况下，共现关系和**余弦相似度**<sup>+</sup>不适合用于计算相似性。它们的具体计算方法为

$$S_U^{cos} = R R^T, \quad S_U^{cos} = D_U^{-1/2} R R^T D_U^{-1/2}.$$

$$S_I^{cos} = R^T R, \quad S_I^{cos} = D_I^{-1/2} R^T R D_I^{-1/2}.$$

这两种方法未充分考虑节点度对随机游走的影响。

## Construction of Personalized Graph Signal

将用户与用户的相似性和交互信号连接起来，可以更准确地描述用户个性化图信号。

$\hat{R} = S_U || R$ ，在串连操作中， $||$ 表示两个向量的连接。

## Construction of Augmented Similarity Graph

交互矩阵表示用户行为，相似度矩阵描述项与项、用户与用户的关系。增强相似图包含三种关系：用户-项目、项目-用户/用户间的交互。该图信号可容纳更多节点信号，对于基于GSP的CF方法非常有用。

$$A = \begin{bmatrix} S_U & S_{UI} \\ S_{UI}^T & S_I \end{bmatrix}.$$

- 1) 建立更合理的随机游走角度的相似矩阵。
- 2) 使用更丰富信息的个性化图信号来描述用户。
- 3) 利用包含更多拓扑信息的增强相似矩阵来处理个性化图信号。

## Mixed-Frequency Graph Filter

本文提出了一个混合频率图滤波器，它能同时捕捉全局平滑信号和局部平滑但全局粗糙信号。



**Figure 3: The ideal low-pass filter makes the signal globally smooth, and the linear low-pass filter makes the signal locally smooth but globally rough.**

知乎 @SmartMindAI

我们使用增强相似度图的定义来定义拉普拉斯矩阵 $L = I - A$ ，其中 $I$ 是单位矩阵。理想的低频响应函数 $h(\lambda) = 1$ 如果 $\lambda \leq \lambda_k$ ，否则为0，其中 $\lambda_k$ 是低频滤波器的截止频率。将 $h(\lambda)$ 放入等式中，我们可以得到理想的低频滤波器如下：

$$\mathcal{H}_{ideal} = U \text{diag}(\underbrace{1, \dots, 1}_k, \underbrace{0, \dots, 0}_{m+n-k}) U^T = U_k U_k^T,$$

$U$ 为 $L$ 特征向量矩阵<sup>+</sup>， $U_k$ 为 $U$ 第一 $k$ 列，对应较小特征值。理想低通滤波器<sup>+</sup>构建只需计算对应较小特征值的特征向量。

理想的低通滤波器仅使用全图中低频傅里叶基底重构空间信号。过滤后的信号在全球范围内呈现出平滑特性。图1中的左箭头说明了这一特性。

该混合频率图滤波器是一种用于解决数据稀疏性和交互信号问题的方法。其工作原理是从空间域的角度看，与增强相似矩阵 $A$ 的乘积可以导致局部平滑，过滤后，节点信号只会扩散到直接相连的节点。通过定理证明， $A$ 是一种线性低通滤波器，其频率响应函数为 $h(\lambda) = 1 - \lambda$ ，因此过滤后的信号允许一些高频成分通过，而不会导致全局平滑。

增强相似性矩阵 $A$ 是一个低通滤波器，其频率响应函数为 $h(\lambda) = 1 - \lambda$ 。

首先，我们有：

$$L = U \Lambda U^T = U \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_{m+n}) U^T,$$

这意味着 $L$ 是一个图滤波器，其频率响应函数为 $h(\lambda) = \lambda$ 。

然后，我们有： $L = I - A$ 。假设 $u_i$ 是 $L$ 的对应于 $\lambda_i$ 的特征向量，则推导如下：

$$L u_i = \lambda_i u_i = (I - A) u_i = u_i - A u_i.$$

所以，我们有：

$$A u_i = (1 - \lambda_i) u_i,$$

这意味着 $A$ 和 $L$ 具有相同的特征向量，对应的特征值有关系：

$$(\lambda_A)_i = 1 - \lambda_i,$$

其中 $(\lambda_A)_i$ 是 $A$ 的第 $i$ 大特征值。假设：

$$\Lambda_A = \text{diag}((\lambda_A)_1, (\lambda_A)_2, \dots, (\lambda_A)_{m+n}).$$

所以，我们有：

$$A = U \Lambda_A U^T = U \text{diag}(1 - \lambda_1, 1 - \lambda_2, \dots, 1 - \lambda_{m+n}) U^T,$$

这意味着 $A$ 是一个频率响应函数为 $h(\lambda) = 1 - \lambda$ 的低通滤波器。

为了平衡用户群体需求与个性化需求，我们将引入线性低通滤波器，该滤波器模仿理想低通滤波器在一定程度上平滑信号局部。

$$\mathcal{H} = (1 - \phi) \mathcal{H}_{ideal} + \phi A,$$

## PGSP Pipeline

在本节中，我们提出了一种名为“个性化图信号处理”的流程，该流程包括预处理、图卷积和后处理步骤。1) 预处理步骤：首先通过( )获取个性化交互矩阵。然后将其规范化以获得规范化后的个性化交互矩阵如下：

$$\tilde{R}_{norm} = \tilde{R} \tilde{D}^{-\beta}, \hat{R}_{norm} = \tilde{R}_{norm} \mathcal{H}.$$

3) “后处理步骤”。我们通过将 $\tilde{D}^{-\beta}$ 相乘来恢复预测的个性化交互矩阵，然后截取最后n列作为预测用户偏好矩阵。

$$\hat{R} = (\hat{R}_{norm} \tilde{D}^{-\beta})_{:, -n:},$$

通过图示说明PGSP方法的工作方式。使用1表示强节点信号，0表示弱节点信号。如果用户A与物品1交互，用户B与物品1和2交互，用户C与物品3交互，并且用户A为目标用户，则有两个节点之间存在强烈相似性：用户A与用户B相似因为他们都与物品1交互，物品1与物品2相似因为它们都与用户B交互。我们首先构造一个增强相似图，其中包含用户-用户相似度（蓝色部分）、物品-物品相似度（黄色部分）以及用户-物品交互信息（虚线）。在预处理阶段，将原始交互信号(1,0,0)（表示用户A只与物品1交互）转化为(1,1,0,1,0,0)(用户A的个性化图形信号)。然后使用混合频率图滤波器，对全局平滑信号和局部平滑信号的结合结果进行预测，如图(iii)所示。这个过程可以从两个角度看待：一方面，从物品-物品相似图的角度看，强信号会传递到物品2，从而导致物品2信号增强；另一方面，从用户-物品相似图的角度看，与用户A相似的用户B有强信号，这也会促进物品2信号强度的提升。用户c与用户a相似度低，因此其信号弱，弱化了物品3的信号。我们提升喜欢物品的信号强度，使其高于不喜欢的物品。最终预测的信号是(0, 1, 0)，表示模型将向用户a推荐可能感兴趣的物品2，因用户b与用户a相似且已与之互动。

## Comparison with GF-CF

GF-CF与PGSP类似，但仅使用用户交互信号；GF-CF未考虑观测信号中的高频成分。相比之下，PGSP包含更多的用户信息和个人化图信号来描绘用户兴趣，并构建增强相似图以更好地表示用户兴趣。我们提出了一种混合**频谱图+滤波器**，该滤波器结合了理想低通滤波器和线性低通滤波器，以便引入观测信号中的高频成分。我们还进行了实验分析，研究高频信息对推荐准确度的影响。

## Experiments

评估方法：实验，评估PGSP准确性，分析个性化图信号、增强相似图和混合频率图滤波器影响。

## Experimental Settings

### Dataset

我们使用三个公开数据集（Gowalla, Yelp2018, Amazon-Book）评估我们的建议方法。数据集包含用户的历史交互记录。我们将每个用户的历史交互的80%作为训练集，其余的作为**测试集+**。此外，我们还从训练集中选取了10%的交互作为验证集以调整超参数。

### Metrics

我们使用了两个流行的Top-N推荐协议：Recall@K和NDCG@K，其中K为20。

### Baselines

- MF模型利用潜在向量将用户和物品映射到同一潜在空间，通过点积计算用户和物品之间的交互强度，包括ENMF、MF-CCL和SimpleX。
- 图神经网络+**方法的基本思想是通过消息传递将用户和项目嵌入到空间中。用户和项目有各自的嵌入向量，点积用于表示不同用户和项目的交互可能性。这些方法包括LR-GCCF、NIA-GCN、LightGCN、DGCF、NGAT4Rec、SGL-ED、UltraGCN和DGCF。



最新工作对比，省略经典基准。

Performance Comparison

Table 2: Performance comparison to state-of-the-art CF methods in recent two years. *RI* represents the relative improvement between PGSP and the corresponding method.

Dataset	Gowalla		Yelp2018		Amazon-book		Reported by	Avg RI	
	recall	ndcg	recall	ndcg	recall	ndcg		recall	ndcg
LR-GCCF [3]	0.1519	0.1285	0.0561	0.0343	0.0335	0.0265	[19]	54.88%	71.75%
ENMF [2]	0.1523	0.1315	0.0624	0.0515	0.0359	0.0281	[19]	45.79%	47.70%
NIA-GCN [29]	0.1726	0.1358	0.0599	0.0491	0.0369	0.0287	[29] [28]	40.65%	46.80%
LightGCN [11]	0.1830	0.1554	0.0649	0.0530	0.0411	0.0315	[11]	28.95%	32.89%
DGCF [30]	0.1842	0.1561	0.0654	0.0534	0.0422	0.0324	[30]	26.94%	30.75%
NGAT4Rec [28]	-	-	0.0675	0.0554	0.0457	0.0358	[28]	30.27%	34.18%
SGL-ED [33]	-	-	0.0675	0.0555	0.0478	0.0379	[33]	26.86%	29.57%
DGCF [16]	0.1891	0.1602	0.0703	0.0575	0.0476	0.0369	[16]	17.16%	19.95%
MF-CCL [19]	0.1837	0.1493	0.0698	0.0572	0.0559	0.0447	[19]	11.01%	13.36%
SimpleX [19]	0.1872	0.1557	0.0701	0.0575	0.0583	0.0468	[19]	8.47%	9.75%
UltraGCN [20]	0.1862	0.1580	0.0683	0.0561	0.0681	0.0556	[20]	3.70%	3.51%
GF-CF [27]	0.1849	0.1518	0.0697	0.0571	0.0710	0.0584	[27]	1.83%	2.81%
PGSP (ours)	<b>0.1916</b>	<b>0.1605</b>	<b>0.0710</b>	<b>0.0583</b>	<b>0.0712</b>	<b>0.0587</b>	-	-	-

- 相较于近年来的最优方法，我们的方法在NDCG上有显著提升，说明我们同时优化了召回率与排序。
- PGSP在大型数据集如亚马逊图书的评估中表现优于最新提出的参数化方法，主要原因是数据驱动的方法可能在面对稀疏数据时效果不佳。
- 我们的方法在GF-CF基础上进行了改进，采用了更强的相似矩阵和个性化图信号，并考虑到高频信息的影响以及归一化矩阵的应用。

Effectiveness of High-frequency Signal




Figure 5: Effectiveness of high-frequency signals on three datasets. The x-axis is  $\phi$ , which controls the weight of the high frequency (locally smooth but globally rough) information in the prediction signal. We can see that high-frequency signals can help to improve accuracy in all three datasets.

"Amazon-Book"(0.062%)\<"Gowalla"(0.084%)\<"Yelp2018"(0.130%)\<"ML-1M"(4.845%)。同时，我们进行了五折交叉验证<sup>+</sup>，并报告了平均结果，以避免因数据集划分而导致的偏差。我们观察到，与仅使用低频信号相比，由高频信号带来的相对改进如下："Amazon-Book"(81.25%)>"Gowalla"(17.89%)>"Yelp2018"(4.47%)>"ML-1M"(0.79%)，这实证了我们的观点。考虑到推荐系统数据在大多数现实场景下都是稀疏的，我们认为引入高频信号很重要。

Training Time Comparison

PGSP是非参数方法，无需参数学习，训练效率高。我们在对比不同CF方法时考虑了MF、GNN和GF-CF。注意MF和GNN方法需多个epochs才可得到模型。ENMF和LightGCN只展示了其中一个epoch的训练时间，但需要多次训练至收敛。PGSP和GF-CF展示了所有训练时间的总和。观察到，训练PGSP所需总时间甚至少于训练一个epoch在基于MF和GNN的CF方法上所需的时间，验证了其高效性。尽管如此，我们的运行时间仍略高于完全基于GSP的GF-CF方法，这是由于引入了额外信息所致。

Method	PGSP	ENMF	LightGCN	GF-CF
Running time	8m42s	11m5s	69m40s	5m31s
Need multiple epochs	✗	✓	✗	✗

Conclusion

我们通过随机游走的方式建立相似性关系，基于该相似性，提出一种包含个性化信息的个性化图信号和一种包含拓扑信息的增强相似图，以提高GSP在CF任务中的性能。我们还发现了观察信号中

原文《Personalized Graph Signal Processing for Collaborative Filtering》

发布于 2023-11-24 17:09 · IP 属地北京

推荐系统 微软 (Microsoft) 协同过滤

▲ 赞同 3 ▼ ● 添加评论 ↗ 分享 ❤ 喜欢 ★ 收藏 📄 申请转载 ...

 理性发言，友善互动




还没有评论，发表第一个评论吧

推荐阅读



脸部一致性模型又出新-- InstantID在ComfyUI的安装...

老李的AI研究



CVPR 2019 | 微软文字转图像技术又进化，提出两种 GAN ...

AI研习社



一键部署 Hugging Face 模型! LMDeploy 与...

OpenM...

发表于OpenM...

R 数据可视化 —— ggplot2 图形创建与布局

前言 在前面几节，我们对 ggplot2 进行了一些简单介绍。接下来要介绍的是 ggplot2 包的使用，ggplot2 会和 tidyverse 搭配使用，这两个包都是 John Fox 写的。tidyverse 名本无名