

微软：MoRec-以数据为核心的多目标学习框架，提升多目标效果



SmartMindAI

专注搜索、广告、推荐、大模型和人工智能最新技术，欢迎关注我

已关注

19 人赞同了该文章

Introduction

推荐系统\*通过深度学习优化个性化内容推荐，以满足用户、平台和内容创作者的需求。尽管主要优化用户满意度，但还需平衡公平性、收入和长期参与度等责任。多目标学习成为解决这一问题的关键，尤其在工业推荐系统中，通过多任务学习，每个目标被视为独立任务，通过分享模型并动态调整权重来平衡不同责任。推荐系统通过多目标学习，如PID驱动的MoRec框架，解决了在优化用户满意度的同时平衡公平性、收入和长期参与度等复杂需求。

MoRec通过三层结构：PID控制器调整目标权重，符号梯度引导数据采样，结合标准优化器更新模型，确保在帕累托最优解附近训练，避免过度偏向某一目标。

知乎

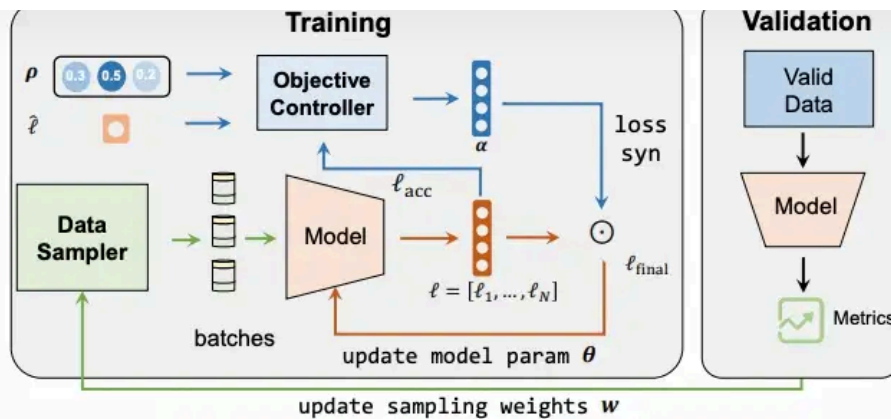



Figure 1: MoRec Framework.



(a) Data Sampler

(b) Objective Coordinator

Figure 2: Primary components in MoRec.

- 我们设计了MoRec，一个数据驱动的多目标优化框架，它整合了PI控制器，用于在推荐系统中动态平衡多个目标，如用户满意度、公平性、收入和长期参与。这个三层结构（PID控制器调节目标权重、符号梯度引导数据、标准优化器更新模型）确保在保持原模型完整性的基础上，实现帕累托最优解<sup>+</sup>，避免过度偏向某个目标。MoRec适用于现有推荐系统的集成，无需改动基础模型和优化器，实现了目标优化的高效、可控和灵活。
- 在MoRec中，我们定义了四个关键目标，然后构建了层次清晰的模块来处理这四个目标。这种结构设计使得优化过程既能保证可控性，确保每个目标都能得到适度的关注，又能在多目标间实现帕累托最优。通过这样的架构，MoRec不仅能够应对单一目标优化，还能灵活应对不同类型的多目标情况，从而实现对用户满意度、公平性、收入和长期参与度等全面优化。

## Preliminary

$$L(\theta, D) = -\sum_{i=1}^N [y_i \log(f(e_i | u_i; \theta)) + (1 - y_i) \log(1 - f(e_i | u_i; \theta))]$$

其中 $N$ 表示样本数量 $y_i$ 是实际的用户反馈（1代表喜欢，0代表不喜欢）

$f(\cdot | u_i; \theta)$  是模型对用户 $u_i$ 对物品 $e_i$ 的预测。这个损失函数<sup>+</sup>衡量了模型预测与实际标签的差异，通过最小化它，模型能更好地理解 and 适应用户偏好。

在MoRec框架中，我们将这个基本的优化目标融入到多目标优化中，以平衡各个维度的需求。

$$l_{acc}(x_i) = -y_i \log f(x_i | \theta) - (1 - y_i) \log(1 - f(x_i | \theta))$$

在推荐系统中，我们利用二元标签 $y_i \in \{0, 1\}$ 来区分正负样本，强调了准确性。然而，为了实现全面的优化，我们引入了如FairBatch这样的框架，它采用双层优化策略，通过动态权重 $w$ 来平衡多个目标。

FairBatch的核心思想是根据每个数据样本的敏感属性 $g_i$ 进行分组，共 $|Z|$ 个组，每个组对应一个权重 $w_z$ 。

为了确保公平性，他们追求的是公平对数比（Equalized Odds），即模型对不同敏感属性群体（如优势群体和弱势群体）的预测概率应该是相等的，无论实际标签如何。因此，优化的目标可以数学表达为：

其中  $P(y_i|u_i, g_i; \theta, w)$  是模型在考虑了动态权重后的预测概率

$\log P(y_i = 1|g_i; \theta)$  是针对敏感属性的基线概率。通过这种方式，MoRec能够在保持准确性的同时，实现对公平性的有效控制，适应多目标优化的需求。

$$\min_w \max_{z_i \neq z_j} \{ |L^{z_i}(\theta_w) - L^{z_j}(\theta_w)| \}, \text{ s.t. } \forall w_z > 0, \\ \theta_w = \arg \min_{\theta} \sum_{z \in \mathcal{Z}} w_z L^z(\theta).$$

MoRec通过  $y_i \in \{0, 1\}$  量化样本标签，强调准确性，同时引入FairBatch处理多目标问题。该框架通过动态权重  $w$  分配，依据敏感属性  $g_i$  按组优化，目标是公平对数比（Equalized Odds），确保不同群体预测概率相等。具体优化过程如下：

- $L^z(\theta)$  代表组  $z$  的平均损失  $w$  是组别权重向量。
- 内层优化用SGD更新模型参数， $\theta_w$
- 外层优化使用符号梯度法<sup>+</sup>，通过比较组间损失差 ( $L^{z_i} - L^{z_j}$ ) 寻找最大差异，计算  $\Delta w_z$  作为权重调整。
- 学习率  $\eta$  控制了权重的变化  $\text{sgn}(\cdot)$  确保调整方向，使权重向有利于减少公平差距的方向偏移。

这样，MoRec在不改变原始模型和优化器的前提下，实现了对准确性和公平性的多目标优化。

$$w_{i^*}^{(t+1)} = w_{i^*}^{(t)} - \alpha \cdot \text{sign}(L^{z^*}(\theta_w) - L^{z^*}(\theta_w)), \\ w_{j^*}^{(t+1)} = w_{j^*}^{(t)} + \alpha \cdot \text{sign}(L^{z^*}(\theta_w) - L^{z^*}(\theta_w)).$$

在论文中提到的公平batch算法（FairBatch）中，关于权重向量  $w$  的解释可通过Lemma 1验证其合理性。这里  $w$  不再简单代表单个  $\lambda_i$  的和，而是代表一组  $\lambda$  值的分布。该更新规则通过调整  $\Delta w_z$ ，即增加劣势群体的权重并减少优势群体的权重，来间接地改善公平性，因为这增加了对这些群体的代表性。

基于这个原则，MoRec借鉴了FairBatch的思路，设计了一个以数据为中心的**多目标优化<sup>+</sup>**框架。该框架的目标是在保持推荐准确性的同时，通过动态调整权重来促进多样性和公平性。这意味着在优化过程中，系统会寻求在满足各种目标（如准确性、公平性等）之间找到一个平衡点，确保推荐结果既准确又公正。

## Methodologies

### Limitations of FairBatch

1. 底层：数据准备，处理实际需求和条件，如用户行为及业务目标，进行预处理。
2. 中层：MoRec扩展，采用多目标优化，借鉴如FairBatch的动态权重管理，平衡各目标，如进行多目标双层优化。
3. 顶层：系统应用和策略调整，根据反馈和业务环境，动态优化策略，确保在满足多元目标的同时符合特定商业需求和公平准则。

MoRec通过这样的三层设计，既保证了对多种目标的适应性，又强化了对目标和约束的精确控制，超越了公平Batch在多目标推荐系统中的局限。

- 外层 目标协调者：此角色是目标管理的核心，它监控并调整目标设置，以实现均衡和最优性能，确保所有相关目标都得到兼顾。
- 中间层次 自适应数据调整器：作为目标协调者的助手，它依据指导，动态调整样本权重，从数据集中优先选择那些需要改进或平衡的目标方向，进行有针对性的训练。
- 内层 目标导向的样本优化器：它依据外层目标的需求，对模型参数进行优化，如MoRec中的SGD，专注于提高模型性能，同时确保公平性，就像在内层进行传统SGD的训练。

这个层次保证了模型的准确性，同时融入了内在的公平性考虑，使得模型在追求精度的同时，能有效平衡不同目标。

## Foundation Objectives

## 知乎

各类目标，确保灵活性。接下来的章节将深入探讨每个目标的采样权重更新策略，它们对于提升数据采样的最优性能和整体效能至关重要。对于准确性，我们遵循直观原则，设定采样权重为所有数据点的均等分配，如  $w_i^{acc} = \frac{1}{|D|}$

这与传统的以准确度为中心的模型训练方法保持一致。

$$\mathcal{O}_{acc} = -L(\theta) = -\frac{1}{|D|} \sum_{i=1}^{|D|} l_{acc}(x_i, \theta)$$

收益部分，工业级推荐系统追求经济效益，目标是最大化推荐项的预期收益。每个推荐项  $e_i$  与利润值  $r(e_i)$  相关，通过设置收益权重  $w_i^{rev}$ ，数据采样器<sup>+</sup>依据此目标调整样本，确保策略带来最大收益。公平性关注避免偏见，定义为减少不同群体（如细分群体间）平均损失差异。公平性权重更新规则基于最大化差异绝对值，通过学习率  $\eta$  来调节：

$$\Delta w_z^{fair} = -\eta \cdot \frac{(L^{z*} - L^{z'})}{|L^{z*} - L^{z'}|} \times (w_i^{fair} - w_{j'}^{fair})$$

一致性（Alignment）保证模型预测与用户偏好一致，通过在损失函数中加入正则化项，惩罚偏离的样本，其权重更新规则为：

$$\Delta w_i^{align} = -\eta \cdot (w_i^{align} \times (1 - \text{alignment}(u_i, \hat{u}_i)))$$

MoRec通过这些目标和权重更新策略，综合优化推荐，同时满足准确性、收益、公平性和一致性要求。

$$\mathcal{O}_{rev} = \frac{1}{|D|} \sum_{i=1}^{|D|} r(e_i) \cdot p(e_i | u_i)$$

MoRec的目标是最大化接受概率，即用户对推荐结果的满意程度，通过调整权重  $w_i^{acc}$  来体现用户对不同推荐的重视。数据采样器据此调整样本，确保推荐策略符合用户实际需求。此外，它还通过整合公平性和一致性（Alignment）的目标，通过附加的权重更新规则，如针对公平性的差分<sup>+</sup>调整 ( $\Delta w_z^{fair}$ ) 和一致性相关的正则化<sup>+</sup> ( $\Delta w_i^{align}$ )，在保证准确性的同时，兼顾多目标优化，实现推荐的全面改进。

$$\mathcal{O}_{rev} = -\frac{1}{|D|} \sum_{i=1}^{|D|} r(e_i) \cdot l_{acc}(x_i)$$

MoRec的目标是优化群体内的公平性，最大化每个群体用户对推荐结果的满意度 ( $w_i^{fair}$ )，通过计算公式

$$\min_g \sum_{i \in G_g} p(e_i | u_i) \cdot w_i^{fair}$$

数据采样器会着重于这些群体，以降低不公平影响。同时，它会综合考虑其他目标的权重更新，确保在追求公平的同时，也能达到多目标的平衡优化。

$$\mathcal{O}_{fair} = \max \{\mathcal{O}_{acc}^z, \forall z \in \mathcal{Z}\} = \min \{L^z, \forall z \in \mathcal{Z}\}$$

MoRec的目标是通过优化  $w_i^{fair}$  来最大化总收益，同时平衡公平性。具体表达为，寻求使群体收益最大化且群体间平均准确率差距最小的解决方案。这里  $\lambda_f$  控制公平性权重的相对重要性  $\gamma$  调节对公平性损失的关注度。外层优化关注总体收益最大化，内层优化则通过最小化每个群体的不公平（Least Misery）来促进公平。通过这样的双层优化，MoRec在保证经济效益的同时，实现了多目标推荐系统的最优综合。

$$w^{fair} = \arg \min_w \max_{z \in \mathcal{Z}} \{L^z(\theta_w)\}, \text{ s.t. } \forall w_z > 0,$$

$$\theta_w = \arg \min_{\theta} \sum_{z \in \mathcal{Z}} w_z L^z(\theta).$$

$$\Delta w_i^{fair} = -\lambda_f \cdot \frac{\partial(\mathcal{O}_{acc}^z - \gamma L^z)}{\partial w_i^{fair}}$$

这里  $\Delta w_i^{fair}$  表示在公平性指标上的权重变化。内层计算了群体  $z$  的平均准确率与公平性损失的偏差  $\lambda_f$  决定了对公平性要求的力度。外层通过负梯度调整，确保在追求收益最大化的同时，减小不

$$w_i^{(t+1)} = w_i^{(t)} - \alpha \cdot \text{sign}(0 - L^{z^*}(\theta_{w^{fai}})) = w_i^{(t)} - \alpha \cdot (-1)$$

一致性关注消除模型预测与期望分布之间的偏差，即解决偏差放大问题。由于机器学习模型可能会倾向于热门商品，导致冷门商品被忽视，为此，我们设定了一致性目标。具体来说，通过调整权重更新规则，如：

$$\Delta w_i^{align} = -\lambda_a \cdot (\hat{p}(e_i) - \text{desired\_distribution}(e_i))$$

这里 $\Delta w_i^{align}$ 表示在一致性目标下的权重变化 $\hat{p}(e_i)$ 是模型对商品 $e_i$ 的预测概率

$\text{desired\_distribution}(e_i)$

是期望的分布。 $\lambda_a$ 控制着对一致性的要求程度。这样的更新旨在使模型预测更接近真实需求，从而提高推荐的多样性和公平性，同时保持推荐的平衡性。

$$\mathcal{O}_{ali} = D_{KL}(Q||P) = \sum_{i=1}^{|D|} Q(x_i) \log \frac{Q(x_i)}{P(x_i, \theta)}$$

一致性目标通过最小化预测值与预设分布 $Q(x_i)$ 的绝对误差来确保模型预测的一致性。具体地，使用 $\Delta w_i^{ali}$ 来驱动权重更新，通过负梯度调整以减少误差。这样做的目的是消除模型预测与期望流行度分布的偏差，防止热门商品被过度推荐而忽视了长尾商品，从而提高推荐的多样性和公平性。通过这种方式，MoRec能够在保持推荐质量的同时，确保推荐结果与实际需求相匹配。

$$w^{ali} = \arg \min_w \sum_i Q(x_i) \log \frac{Q(x_i)}{P(x_i, \theta_w)}, \text{ s.t. } \forall w_z > 0,$$

$$\theta_w = \arg \min_{\theta} \sum_{i=1}^{|D|} w_i l_{acc}(x_i, \theta).$$

为优化 $w^{ali}$ 以最小化 $\mathcal{O}_{ali}$ （一致性误差），我们使用负梯度<sup>+</sup>更新，公式为：

$$\Delta w_i^{ali} = -\eta_{ali} \cdot \frac{\partial \mathcal{O}_{ali}}{\partial w_i^{ali}}$$

其中 $\eta_{ali}$ 是学习率 $\mathcal{O}_{ali}$ 是各样本预测值与预设分布 $Q(x_i)$ 偏差的总和。通过这个过程，MoRec通过反向调整权重，致力于减少误差，确保推荐结果与预设的流行度分布一致，降低偏差并提升推荐的一致性。

$$w_i^{(t+1)} = w_i^t - \alpha \cdot \text{sign}(P(x_i, \theta_w) - Q(x_i)), \forall i \in \mathcal{Z}$$

在一致性调整（Alignment）部分，通过计算样本预测值与期望分布的绝对差（ $\mathcal{O}_{ali}$ ），我们用负梯度更新权重 $\Delta w_i^{ali}$ ，以减小误差。学习率 $\eta_{ali}$ 控制了调整的步长<sup>+</sup>。初始时，权重设置为所有样本数量的倒数，以保证每个样本对模型贡献相等。随着训练过程，权重将根据一致性误差调整，确保推荐结果更贴近预设的流行度分布，从而减少偏差，增强推荐的一致性。

## Objectives Coordinator

在处理多目标协调问题时，我们通过设定目标的界限值构建Pareto前沿，依据业务需求从中选取最优方案。我们通过偏好向量生成涵盖广泛权衡的解集，但实验表明，这种方法并不比线性加权方法更优。原因可能是数据采样策略实际上平滑了训练监督下的梯度，有利于线性加权的效力。因此，我们决定采用线性加权方法，因为它既简单又有效。具体来说，我们定义一个目标权重向量

$$\rho = [\rho_1, \rho_2, \dots, \rho_n]$$

每个元素 $\rho_{obj_i}$ 对应一个目标的权重，共有 $n$ 个目标。每个目标的损失向量为 $\ell = [\ell_1, \ell_2, \dots, \ell_n]$

综合损失 $\ell_{final}$ 通过 $\rho^T \ell$ 计算得出。通过调整 $\rho$ 的值，我们生成一个多目标解决方案的分布。

$$\ell_{final} = (\rho_{acc}(t) \cdot \ell_{obj_1} + \rho_{int}(t) \cdot \ell_{obj_2} + \rho_{der}(t) \cdot \ell_{obj_3} + \dots + \ell_{obj_n})$$

$$\times (\rho_{acc} + \rho_{int} + \rho_{der})$$



标的同时，也能确保模型精度的维持。

$$\ell_{\text{final}} = \alpha_{\text{acc}} \cdot \ell_{\text{acc}} + \sum_{\text{obj} \neq \text{acc}} \alpha_{\text{obj}} \cdot \ell_{\text{obj}}$$

在优化过程中，

$\text{OC}(\ell^{(t)}; \rho, \hat{\ell})$  定义为一个动态适应的优化准则，其中：

$$\text{OC} = \rho_{\text{acc}}(t) \cdot (\hat{\ell} - \ell^{(t)}) + \rho_{\text{int}}(t)$$

这里  $\rho_{\text{acc}}(t)$  和  $\rho_{\text{int}}(t)$  是两个随时间变化的系数，分别代表对当前时刻准确性的重视程度和累积误差<sup>+</sup>的权重。它们动态调整，确保在优化过程中，模型既考虑了当前任务的精确度（ $\hat{\ell}$  与  $\ell^{(t)}$  的差值），又兼顾了累积误差，从而能够在追求其他目标的同时，保持一定的准确性。

在PI方程中  $\text{err}(t) = \hat{\ell} - \ell^{(t)}$

表示模型在时刻  $t$  的实际精度误差。 $K_p$  和  $K_i$  是超参数  $K_p$  负责比例项  $K_i$  关注积分项，它们都是非负的。 $\alpha_{\text{min}}$  设定了一个下限，以防止过拟合<sup>+</sup>。PI方程的核心策略是通过P项（比例项）实时调整，当  $\text{err}(t)$  绝对值大且与预设损失值差距远时，它增加以强化对精度的学习；反之，若正向误差大，P项减少，以避免过度依赖精度。I项（积分项）则关注累计误差，通过累计误差的增减来平衡模型<sup>+</sup>对  $\ell_{\text{acc}}$  的控制，确保在优化过程中保持一定的精度水平。这样，无论数据集的整体趋势如何，PI方程都能确保模型在优化其他目标的同时，保持精度的稳定性，从而增强其控制能力。

## Overall Framework

初始化采样权重  $w$  在DS中使用  $D_t$  和  $D_v$ ，根据权重  $w$  从  $D_t$  中抽取小批量数据。计算损失  $\ell$  使用  $\theta$ 。

然后，依据公式 (eq : alpha) 计算  $\alpha$ 。

接下来，计算总损失  $\text{loss} = \alpha^T \ell$ 。

利用该损失更新参数  $\theta$ ，并根据公式 (eq : update\_w\_fai) 和 (eq : update\_w\_ali) 结合  $D_v$  更新DS中的采样权重  $w$ 。

### Algorithm 1: The Tri-level Framework MoRec.

**Input:** Training Data  $D_t$ , Valid Data  $D_v$ , Data Sampler DS, Objective Coordinator OC, Objective priority vector  $\rho$ , Expected accuracy loss  $\hat{\ell}$   
**Output:** Model  $\theta$ .

- 1 Initialize sampling weight  $w$  in DS with  $D_t$  and  $D_v$ ;
- 2 **repeat**
- 3     Draw minibatches from  $D_t$  according to sampling weight  $w$ ; // Middel Level: data sampling
- 4     **for** batch  $\in$  minibatches **do**
- 5          $\ell \leftarrow$  Calculate loss with  $\theta$ ;
- 6          $\alpha \leftarrow \text{OC}(\ell; \rho, \hat{\ell})$  according to Eq. (14);     // Outer Level: objective control
- 7          $\text{loss} \leftarrow \alpha^T \ell$ ;
- 8         Update  $\theta$  with loss;     // Inner Level: model optimization
- 9     Update sampling weight  $w$  in DS with  $D_v$  according to Eq. (8) and Eq. (11);  
        // Middel Level: sampling weight update
- 10 **until** Convergence or reaching max epoch;

知乎 @SmartMindAI

## Experimental Setting

### Dataset

准确率、收入增长、流行度一致性及公平性。由于实现多目标要求，除交互数据外，还利用商品类别和价格信息。为衡量公平性，按类别对商品分类，并以价格作为推荐利润预测依据。为防止流行度偏差，我们按商品流行度将其分组，确保推荐结果在训练集分布相似。

准确率、收入增长、流行度一致性以及公平性。由于涉及多目标优化，我们不仅依赖交互数据，还利用商品类别和价格信息来辅助决策。公平性通过按类别分类商品并利用价格信息来评估，以消除流行度可能带来的偏见。总的来说，我们通过这种方法来评估MoRec与其他先进算法在这些复杂任务上的相对效能。

尽管我们的主要目标函数可能不直接满足可导性要求，特别是那些涉及一致性（Alignment）和公平性（Fairness）的非直接利润加权损失，我们巧妙地设计了适应性。对于一致性，我们定义了基于流行度倒数的损失权重（如公式所示），确保样本级别具有可导性。对于公平性，我们采用了皮尔逊相关性作为正则化项（公式所体现），同样实现了可导处理。因此，这些基线方法能够在优化准确率、促进收入增长、保持流行度平衡的同时，兼顾对一致性和公平性的追求。通过合理设定权重 $w_{align}$ 、 $w_{fair}$ 和正则化强度 $\lambda$ ，所有模型都将全面应对这四个目标。

$$L_{rev} = \sum_{(u,i)} r(i) \cdot \ell(u,i)$$
$$L_{ali} = \sum_{(u,i)} \frac{1}{pop(i)} \cdot \ell(u,i)$$
$$L_{fai} = \frac{(\sum_i \hat{y}_\theta(x_i) - \mu_{\hat{y}_\theta})(\sum_i g_i - \mu_g)}{\sigma_{\hat{y}_\theta} \sigma_g}$$

### Evaluation Metrics

为了保证准确性，我们使用广泛认可的Hit指标来评估。为衡量公平性，我们采用最不痛苦度（基于Hit指标的度量）。对于一致性，我们利用KL散度来度量推荐物品频率分布 $P(x_i, \theta)$ 与指定流行度分布 $Q(x_i)$ 的差异，目标是Pop-KL值越小，说明模型推荐更贴近真实情况。收入方面，我们使用价格加权的Hit指标rHit，其目的是评估潜在收入。所有这些指标都基于前10个推荐结果来计算。此外，我们还通过计算相对于基线模型在所有目标上的平均相对改进（Imp）来评判和选择最佳解决方案。

### Implementation Details

为了检验我们的方法的普遍适用性，我们在实验中采用了两种不同的基线模型作为对比。

### Overall Performance

我们通过实验评估了模型在兼顾四个目标时的表现。如果模型的准确率未显著低于97%的基线模型，则认为有效。对于每个基线（MF-BPR和SASRec）和我们的MoRec模型，我们产生了至少六个解决方案。若所有方案无效，我们选择平均相对改进（Imp）最高的作为最优解，或者在所有方案无效时，以准确率为准。

Table 2: Performance over four objectives with MF-BPR. Bold and underline represent the best and second best results, respectively. <sup>↓</sup> represents the performance of accuracy drops more than 3% compared with Base. Numbers are in percentage.

Dataset	Electronics						Movies					Xbox				
Metrics	Hit	rHit	Pop-KL	min-Hit	Imp	Hit	rHit	Pop-KL	min-Hit	Imp	Hit	rHit	Pop-KL	min-Hit	Imp	
Base	1.62	135.42	142.54	0.91	0.00	4.09	112.68	83.11	3.57	0.00	20.27	532.53	51.94	3.28	0.00	
Static	1.62	197.56	37.09	1.00	32.41	4.06	136.92	27.74	2.16	11.99	18.22	681.73	4.93	3.68	Invalid	
MGDA	1.32 <sup>↓</sup>	262.84	20.37	0.32	Invalid	3.90 <sup>↓</sup>	179.71	9.32	3.23	Invalid	14.38 <sup>↓</sup>	418.16	11.33	9.05	Invalid	
PEMTL	1.68	167.53	99.08	1.03	17.60	4.08	161.25	9.09	3.10	29.70	17.54 <sup>↓</sup>	679.04	6.34	3.37	Invalid	
EPO	1.51 <sup>↓</sup>	162.99	35.75	0.98	Invalid	3.97	160.46	9.14	2.44	24.22	17.35 <sup>↓</sup>	645.64	11.91	Invalid	Invalid	
MoRec	1.63	225.19	16.81	1.05	42.60	3.98	164.44	9.73	3.68	33.69	19.71	575.66	18.52	11.98	83.79	

结果显示，MF-BPR的基线模型在某些目标上有所提升，但MoRec在保持较低准确率损失的情况下，显著提升了所有目标的性能，特别是在工业数据集上，最大相对精度<sup>+</sup>下降仅为2.76%。值得注意的是，没有哪个基线模型能确保在所有设置下都有有效解决方案。MoRec在平均提升上领先，尽管并非所有目标都超越了最先进的技术，但总体性能强劲且对不同基线模型的适应性良好。

### Pareto Efficiency Study

为了证明MoRec的帕累托效率<sup>+</sup>，我们对每个方法生成五个解决方案，并绘制帕累托前沿图。我们选择二元目标，即在公开数据集上同时优化准确性和收益/公平性。具体图表见图。这些图展示了各方法在精确性和效益/公平性之间的最优平衡点。MoRec的帕累托前沿位置显示了其在资源分配上的优越性，即使在不同条件下也能提供较好的性能。

Metrics	Hit	rHit	Pop-KL	min-Hit	Imp	Hit	rHit	Pop-KL	min-Hit	Imp	Hit	rHit	Pop-KL	min-Hit	Imp
Base	1.81	174.53	26.38	0.75	0.00	5.93	175.17	10.78	4.13	0.00	25.99	809.74	17.16	7.84	0.00
Static	1.84	259.75	20.49	0.40	6.51	5.21 <sup>↓</sup>	163.30	8.63	3.24	Invalid	13.73 <sup>↓</sup>	700.68	32.45	0.67	Invalid
MGDA	1.70 <sup>↓</sup>	175.00	42.23	0.37	Invalid	5.50 <sup>↓</sup>	167.22	14.34	4.57	Invalid	25.66	932.78	20.88	8.46	4.00
PEMTL	2.46	220.91	45.40	1.28	15.10	5.81	153.64	14.69	4.08	-12.94	25.41	812.74	32.84	9.63	-17.58
EPO	1.69 <sup>↓</sup>	228.42	43.57	0.03	Invalid	5.15 <sup>↓</sup>	157.85	18.05	3.24	Invalid	27.22	995.70	47.22	1.03	Invalid
MoRec	2.32	239.54	14.87	1.47	51.38	6.25	189.26	1.64	5.17	30.84	25.96	899.47	7.64	14.12	36.65

在实验中，我们发现MoRec在所有四个案例中，无论是电子产品还是其他领域，都展现出卓越的帕累托效率。相比之下，基线方法在公平性方面的表现明显逊色。这归因于其公平性设计与最大化准确性的目标不一致，以及与准确性损失处理方式的不同，使得公平性优化效果欠佳。MoRec通过PID目标协调器在控制精度下降方面表现出较强的有效性，而基线如MGDA的解决方案则在这一点上显得更加中心化，与PEMTL和EPO相比，其在这方面的倾向更为明显。然而，由于原始文本中未提供具体图表的编号，我们无法详细讨论图表内容。若需要，我们可以深入解析这些图表的数据和分析结果。

原文《A Data-Centric Multi-Objective Learning Framework for Responsible Recommendation Systems》

编辑于 2024-05-24 15:40 · IP 属地北京

推荐系统 多目标优化 帕累托最优

▲ 赞同 19 ▼ ● 添加评论 ↗ 分享 ❤ 喜欢 ★ 收藏 📄 申请转载 …

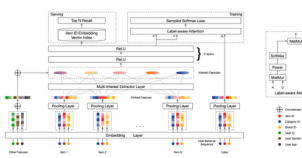


理性发言，友善互动



还没有评论，发表第一个评论吧

推荐阅读



**MIND: 多兴趣网络Multi-Interest Network**

luchi... 发表于计算广告实...



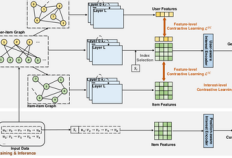
**推荐系统 | Google多目标学习MMOE**

机器学习 发表于推荐系统学...



**多目标学习在推荐系统中的应用**

Micro... 发表于人工智能



**阿里2022-用于序列推荐对比学习框架《Multi-le**

SmartMindAI