

赞同 54



分享

谷歌2023-揭秘序列推荐中的用户潜在意图-论文深度解析



SmartMindAI

专注搜索、广告、推荐、大模型和人工智能最新技术，欢迎关注我

已关注

54 人赞同了该文章

论文原文《Latent User Intent Modeling for Sequential Recommenders》

Introduction

推荐系统广泛应用于在线平台，考虑用户-物品交互顺序的序列推荐模型越来越受欢迎。大多数现有的序列推荐模型主要依赖用户的物品级交互历史来捕捉其主题兴趣。然而，这些模型缺乏对用户意图的高级理解，即用户在请求时刻希望从平台上获得什么，例如探索新内容、继续上一个会话的内容、播放背景音乐等。用户意图往往跨越多个会话，因此理解用户意图对于优化长期用户体验至关重要。

用户意图可以明确定义，例如搜索意图被分为导航性、信息性和交易性。有了这种方法，我们可以使用明确定义的用户意图来注释训练数据，并将其作为监督学习任务来预测用户意图。这种表述具有明显的优点：它允许良好的解释性和模型预测的可信评估。然而，这种方法需要专业知识来手动定义和列举用户意图。与搜索情况相比，有机推荐中的用户意图往往更加多面性和潜意识，这使得手动定义变得更加困难。

我们提出使用潜在变量模型将用户意图视为潜在变量。这些模型已被广泛研究和应用于各种领域，包括统计学、机器学习和经济计量学⁺。这是一个关联观测变量或证据与潜在变量的概率模型⁺。具体而言，它定义了观测变量和潜在变量的联合分布。然后通过边缘化获得观测变量的相应分布。在线平台上的用户行为信号-例如搜索、浏览、点击和消费-通常是潜在用户意图的良好指标。因此，它们可以用作潜在变量模型中的观测变量。换句话说，我们将用户意图形式化为潜在变量，并将它们与用户行为信号联合建模，避免了手动定义意图的需要。

以下是我们共同做出的贡献：

- 提出一种概率模型，将用户意图表述为潜在变量，并将其与行为和上下文信号联系起来。
- 应用变分推理技术进行高效和可扩展的推理。
- 为工业用例的概率模型训练稳定性提供依据。
- 对潜在空间进行深入分析，以获得语义方面的见解。
- 在为数十亿用户和数百万商品提供服务的商业推荐平台上，通过大规模现场实验证明所提出技术的优势。

Related Work

顺序推荐系统是基于用户物品交互顺序进行建模的推荐系统，已经采用了各种模型来捕捉用户物品交互中的长期和复杂依赖关系，例如循环神经网络⁺(RNN)、卷积神经网络(CNN)和自注意力模型。然而，大多数方法主要关注物品级别的交互历史，往往缺乏对用户意图的更高级理解。已经提出了多种方法来建模用户意图，以改善推荐系统；特别是，隐式用户意图方法已经变得流行。

据我们所知，将潜在变量模型引入意图建模并利用行为信号是一种新颖的贡献。潜在变量模型和变分自编码器⁺潜在变量模型是概率模型，表示观察变量由未观察的潜在变量生成。

该模型学习观察变量和潜在变量的联合分布，并通过求⁺边际分布⁺获得观察变量的分布。变分自编码器（VAE）提供了学习深度潜在变量模型和推理模型的原则框架。随后，一些VAE的扩展被提出，包括条件VAE，它模拟⁺条件分布⁺，以及用于模拟序列数据的变分RNN。VAE在⁺推荐系统⁺中的应用也是研究的活跃领域。本文提出了潜在变量模型在用户意图建模方面的新颖应用。

Probabilistic Model

我们以有向⁺概率图模型⁺（PGM）或⁺贝叶斯网络⁺为起点，分解感兴趣的⁺随机变量⁺的联合分布。高级结构假设表明，用户请求之前的过去用户行为和上下文信息揭示了用户的当前意图，并进一步预测用户的未来行为。图⁺提供了该模型的图形表示。按惯例，带阴影的⁺节点⁺表示观察变量，透明节点表示潜在变量。图中节点代表以下变量：

- 节点 x ：代表过去用户的行为以及上下文信息。具体来说，行为可以包括过去15分钟内的点击次数或搜索次数，而上下文可以包括一天中的时间、设备等信息。
- 节点 y 表示未来用户行为，具体为未来15分钟内的点击或搜索次数。
- 节点 z ：潜在变量（即用户意图）。

注意到，给定 z ，我们假设 x 和 y 是⁺条件独立⁺的。换句话说，过去用户行为（ x ）与上下文（ z ）和未来行为（ y ）之间的联系是由潜在意图（ z ）所调节的。




Figure 1: Probabilistic graphical model. The connection from past user behavior and context x to future user behavior y is mediated by the user intent z . Note that x and y are observed variables whereas z is latent. 知乎 @SmartMindAI

Inference with Variational Autoencoders

从概率建模的角度来看，潜在意图模型旨在捕捉条件分布 $p(y|x)$ ，其中 x 和 y 之间的联系通过潜在变量 z 调解。然而，由于⁺后验分布⁺难以处理，已知潜在变量模型很难学习和推断。为了使学习和推理易于处理，我们采用了条件VAE，一种变分推理算法，以便有效地扩展到大型数据集。其核心思想是引入一个变分分布 $q(z|x, y)$ 来近似真实后验分布，并最大化 \log -likelihood的下界： $\log p(y|x)$ 。它将推断作为一个优化问题。有关变分推理和VAE的更多详细信息，请参阅@Kingma2019和相关参考文献。

- ⁺先验知识⁺：给定 x 的情况下， z 的⁺概率分布⁺遵循均值为 μ_ψ ，协方差矩阵为 Σ_ψ 的⁺正态分布⁺，即
- $p(z|x) \sim \mathcal{N}(\mu_\psi, \Sigma_\psi)$ 。
- ⁺解码器⁺/似然性： $p(y|z) \sim \mathcal{N}(\mu_\theta, \Sigma_\theta)$ 其中，解码器/似然性是指给定⁺隐变量⁺ z 的条件下，观察变量 y 的概率分布，其满足正态分布的形式，参数为 μ_θ 和 Σ_θ 。
- 在我们的编码器/变分分布中，给定输入 x 和 y ，我们使用一个神经网络来计算⁺均值向量⁺ μ_ϕ 和协方差矩阵 Σ_ϕ ，从而定义一个⁺高斯分布⁺ $q(z|x, y) \sim \mathcal{N}(\mu_\phi, \Sigma_\phi)$ 。

所有分布都被参数化为对角协方差矩阵的多变量高斯分布，均值和对数方差是⁺多层感知器⁺（MLP）的输出，其中ReLU作为⁺激活函数⁺。网络的参数被训练为最大化证据下界（ELBO）。

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q(z|x,y)}[\log p(y|z)] - D_{\text{KL}}(q(z|x,y) \| p(z|x)),$$

意图 z ， z 应包含关于 y 信息，模型将能真实重构 y 。ELBO中第二个术语是正则化损失；鼓励近似后验分布 $q(z|x, y)$ 不要偏离先验分布 $p(z|x)$ 太多。




Figure 2: The latent intent module consists of three networks: prior, decoder; and encoder. The loss can be written as two terms: reconstruction loss and regularization loss.

Training Stability

在实践中，我们观察到潜在意图模块的训练稳定性问题，是由于KL散度爆炸造成的，无论是在训练初期还是中期。两种技术被发现可以有效缓解这一问题。第一个是适当地初始化可训练参数。我们通过将权重 θ 初始化为零附近的均匀分布 $\mathcal{U}(-\epsilon, \epsilon)$ ，并将偏置初始化为零来初始化权重。结果是， $q(z|x, y)$ 和 $p(z|x)$ 在初始化时都接近 $\mathcal{N}(0, I)$ ，因此KL散度 $\mathcal{KL}(q(z|x, y) \parallel p(z|x))$ 接近零。其次，在训练过程中对log方差进行软限制可以防止KL散度爆炸。特别是，我们使用softplus函数将log方差限制在区间 (a, b) 内：

$$f(x) = x - \log(1 + \exp(x - b)) + \log(1 + \exp(a - x)).$$

将这两种技术结合使用时，我们观察到KL散度在整个模型训练过程中仍然是有界的。

Incorporation into Sequential Recommenders

序列推荐模型使用循环神经网络来概括用户在平台上的交互历史。RNN的隐藏状态与其他上下文信息拼接起来，并通过后融合层（具有ReLU激活的多层感知器）传递，该层的输出用作用户表示。在顶部定义了一个softmax策略和物品表示。我们使用REINFORCE算法训练模型以优化用户的长期满意度；损失函数 \mathcal{L}_{rec} 。在潜在意图模型（包括先验网络、编码器和解码器）中，仅先验网络与主要推荐模型交互。先验网络 $p(z|x)$ 根据用户行为和上下文 x 推断用户意图 z 。在训练和服务时，我们通过先验网络从 $p(z|x)$ 中采样一个样本 z 。为解耦潜在意图模块与主推荐模型，对 z 实施了停止梯度操作。随后，采样后的用户意图 z 与最终RNN隐藏状态拼接，并传递给后融合层。最终输出是带有推断用户意图的用户表示，它将决定推荐策略。序列推荐模型的训练目标 \mathcal{L}_{rec} 保持不变。总体损失函数 $\mathcal{L} = \mathcal{L}_{\text{rec}} - \lambda \mathcal{L}_{\text{ELBO}}$ ，其中 $\lambda > 0$ 是控制ELBO损失相对强度的超参数 λ 。请参考图。


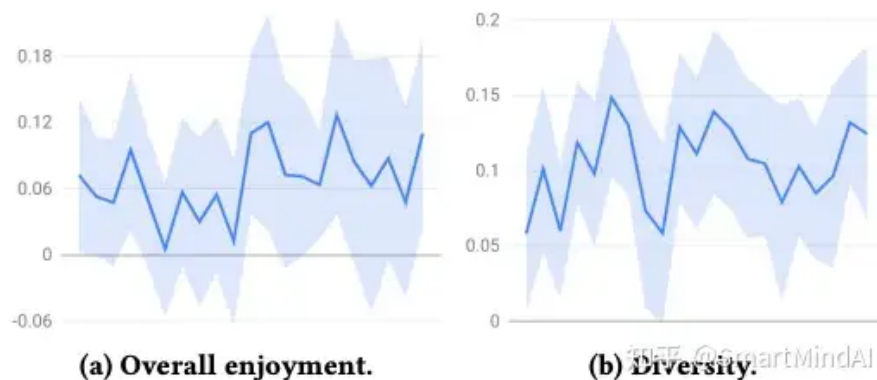


Figure 3: The overall architecture incorporating the latent intent module to the sequential recommendation model. Only the prior network is used and a stop gradient is applied to further decouple them.

知乎 @SmartMindAI

Live Experiments

我们在为数十亿用户提供服务的实时系统中进行了A/B实验，以衡量所提出的潜在意图建模技术⁺的优势。顺序推荐系统旨在每个用户请求时从数百万条目的语料库中检索数百个候选条目，与其他来源返回的条目一起，在向用户显示顶部结果之前，由单独的排名系统进行评分和排名。实验运行了三个星期，在此期间，控制模型⁺和实验模型都使用新的交互和反馈作为训练数据进行持续训练。我们关注以下两个指标：（1）用户对平台的整体满意度；（2）用户-物品交互的多样性，这代表用户与之互动的唯一主题集群的数量。结果表明，消费多样性是长期用户体验的有效替代品。实验模型和控制模型是带有和不带有潜在意图模块的顺序推荐模型。图总结了现场实验的结果。在x轴上是日期，在y轴上是实验和对照之间度量的相对差异百分比。我们报告了这些指标的平均值和95%置信区间⁺。与对照相比，实验模型的整体满意度提高了+0.07%，95%置信区间为（+0.02%，+0.11%）。用户-物品交互的多样性提高了+0.10%，95%置信区间为（+0.08%，+0.13%）。此外，整体满意度指标呈上升趋势，表明存在用户学习效应，即用户状态会响应推荐策略而改变。该提议的模型已部署到生产系统两个多星期。部署方式描述于此段开始部分。



Conclusion

提出了潜在用户意图模型，这是一种概率建模方法，用于捕捉用户意图并补充现有的顺序推荐器。采用变分推断技术高效且可扩展，同时研究使模型稳定和可解释的技术。最后，在大型现场实验中验证了所提出方法的效力。未来的一个研究方向是通过设计离散潜在空间来进一步提高潜在用户意图的可解释性，使用Gumbel zsoftmax或VQVAE。



理性发言，友善互动

1 条评论

默认 最新



快乐的IT小民工

站在业务角度，这里面的用户潜在意图具体是指什么呢？可以举一个例子吗？

09-05 · 广东

回复 喜欢

推荐阅读



Google Developers

谷歌走了吗？没了搜索，还有技术！

夏雯



Google Developers

谷歌走了吗？没了搜索，还有技术！

夏雯 发表于谷歌开发者...



谷歌是一家什么样的公司

跨境姣姣子



2021年谷歌SEO必备！谷歌高排位入门（建议收藏）

Runwi... 发表于今日