

阿里2022-用于序列推荐的多级对比学习框架《Multi-level Contrastive Learning Framework for Sequential Recommendation》论文



SmartMindAI

专注搜索、广告、推荐、大模型和人工智能最新技术，欢迎关注

已关注

17 人赞同了该文章

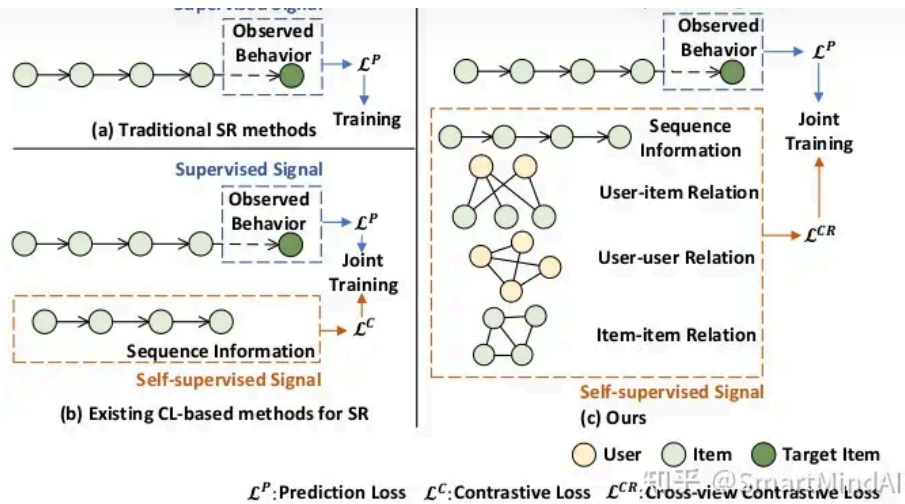
Introduction

推荐系统在许多在线服务中发挥着至关重要的作用。顺序推荐系统捕获连续项目之间的顺序转换模式，预测用户可能感兴趣的下一个项目。这些方法大多采用监督学习范式，数据稀疏问题困扰着它们。此外，一些工作使用循环神经网络、自注意力机制⁺和图神经网络来建模用户行为序列。然而，与整个交互空间相比，观察到的用户行为非常稀疏。

近年来，自监督学习被提出用于挖掘监督信号，缓解数据稀疏问题。对比学习基于正负样本最大化正样本对一致性，学习具有区分性的嵌入。现有的基于CL的SR方法在用户行为序列上应用数据级增强或模型级增强生成正负对，通过对比学习学习额外的自监督信号。尽管现有方法能获取自监督信号，但不足以保证SR的学习，原因包括信息不足和对比对信息多样性较少。为了解决这些问题，需要探索更多视图并生成更多信息丰富的对比对。此外，选择适当的视图和对比任务至关重要。协同信息和共同行动信息可能帮助获得丰富的自我监督信号，应认真考虑。在设置对比任务时，确保对比视图之间信息的明确多样性是关键。本文提出了一种用于序列推荐的多层次对比学习框架（MCLSR），该框架在多视图和跨视图对比机制的基础上，有效学习自监督信号。通过在兴趣层次和特征层次上执行对比学习，MCLSR能够捕捉用户（项目）之间的协同作用信息，从而进一步增强表示学习。该框架的主要贡献在于为序列推荐提供了新的思路和方法。

- 提出了一种协同信息对比学习框架，用于缓解顺序推荐任务中的数据稀疏性问题。该框架从四个特定视图捕捉顺序转换模式、协同信号和共同行动信号，缓解数据稀疏性。
- 提出了一种名为MCLSR的方法，该方法在兴趣和特征级别进行跨视图的对比学习。前者从协同信息和序列转换模式中学习自监督信号，后者捕获协同作用信息以学习信息丰富的用户/项目嵌入。
- 通过四个真实数据集的实验，证明了MCLSR的优越性和每个关键组件的有效性。

知乎



Related Work

本节回顾了顺序推荐和对比学习等与我们的工作密切相关的几条工作线。

Sequential Recommendation

主要研究采用多层次的跨视图对比学习范式来缓解基于顺序推荐的数据稀疏性问题。相较于基于会话的推荐，顺序推荐通常考虑更长时间范围内的用户ID及其行为序列。深度学习技术被引入到SRS中，如RNN、CNN、自注意力网络、记忆网络、[胶囊网络](#)⁺和图神经网络等。然而，以上方法主要集中在监督范式下的顺序转换建模，面临数据稀疏性问题。本文采用跨视图对比学习范式来缓解此问题。

Contrastive Learning

对比学习在视觉表示学习、自然语言处理和图神经网络中取得了令人印象深刻的成就。最近，一些研究将对对比学习引入推荐系统，例如SGL通过节点自我辨别为基于GCN的推荐模型提供辅助信号。SEPT设计了一个社会感知的自监督框架，从用户-项目图和社会图中学习区分信号。一些工作也将对比学习引入到序列推荐中， S^3 -Rec利用互信息最大化设计了辅助自监督目标来进行数据表示学习。此外，还有一些方法通过数据增强来生成正样本对并对比学习来学习稳健的序列转换模式。然而，现有基于对比学习的序列推荐方法主要关注从每个序列中学习自监督信号，但序列内信息有限，所获得的自监督信号可能太弱。因此，未来的研究应考虑如何更有效地利用序列内信息来提高推荐系统的性能。

Preliminary

首先阐述了顺序推荐问题，然后介绍了三个图形视图的构建过程以及图形编码器层的架构。

Problem Formulation

研究了用户历史行为序列推荐任务，给定观察到的用户历史行为序列，推荐任务是预测用户最有可能与之交互的下一个物品。具体来说，我们有一组用户和一组物品，每个用户的历史行为序列按时间顺序排列。

Graph Construction

本文构建了图形视图来探索用户行为序列的协作信号和共同行动信号。基于用户历史行为序列，获得一个用户-项目交互矩阵，并聚合跨用户行为序列构建用户-项目图。该图是一个典型的二分图⁺。

$$\mathcal{G}^{uv} = (\mathcal{V}^{uv}, \mathcal{E}^{uv})$$

示用户之间的交互关系。 $\mathcal{G}^{uu} = (\mathcal{V}^{uu}, \mathcal{E}^{uu})$ 本文研究了用户-用户图，其中 \mathcal{V}^{uu} 表示图节点集，包含 \mathcal{U} 中所有用户；

$$\mathcal{E}^{uu} = e^{uu} * ij = \mathcal{M} * ij^{uu} | \mathcal{M} * ij^{uu} > 0$$

表示图边集，包含共同行为信息的边；每条边的权重表示用户 i 和用户 j 之间的共同行为次数。

Graph Encoder Layer

本文采用特定图编码器层提取节点特征，利用LightGCN的有效性和轻量级架构提取协同信息和共同作用信息。 $\mathbf{X}^{(l)} = \text{GraphEncoder}(\mathbf{X}, \mathbf{A}) = \mathbf{D}^{-\frac{1}{2}} \mathbf{A} \mathbf{D}^{-\frac{1}{2}} \mathbf{X}^{(l-1)}$ ，研究了图的邻接矩阵⁺和相应的对角度矩阵之间的

关系，通过对图编码器层的深度进行编码，可以得到输入节点特征和输出之间的差异。 上述摘要中包含了原始论文的主要内容，但为了使读者更好地理解该研究的意义和方法，也可以增加一些信息，例如："该研究通过分析邻接矩阵和编码器层的输出特征，探讨了如何更有效地进行图编码，并应用于机器学习算法中。"这样的描述可以更好地吸引读者的兴趣。

Method

总结与展望： 随着信息技术的发展⁺，大数据在医疗领域的作用越来越重要。提出了一种基于差分隐私⁺的大数据分析方法，通过保护数据隐私和提高数据分析效率，有效解决了大数据分析中的一系列挑战。此外，对大数据分析和差分隐私的研究现状进行了综述，表明如何在大数据分析中平衡数据隐私保护和数据分析效率仍是一个具有挑战性的问题。未来，我们希望进一步研究如何将差分隐私技术应用于更广泛的大数据分析场景，以提高数据分析的准确性和效率。我们提出的多层次对比框架包含四个主要组成部分：图构建层、兴趣层次对比学习层、特征层次对比学习层和联合训练。框架概览如图所示，使用嵌入矩阵和特定嵌入层处理用户和项目。输入用户行为序列转化为用户嵌入，进一步转化为嵌入矩阵用于训练模型。后续将介绍技术细节。

Interest-level Contrastive Learning

讨论了如何从用户行为序列中捕捉用户偏好，应用自注意力机制进行建模。通过训练位置矩阵合并顺序信息，并计算注意力矩阵⁺。不同于以往的SR研究，我们引入协作信息以捕获用户的一般偏好，并缓解数据稀疏性问题。

$$\mathbf{A}^s = \text{softmax} \left(\mathbf{W}_2 \tanh(\mathbf{W}_1 (\mathbf{E}^{u,p})^T) \right),$$

本文研究了用户行为序列中物品亲和力的计算问题。我们考虑了可训练参数 $\mathbf{W} * \mathbf{1}$ 和 \mathbf{W}_2 ，以及输出矩阵 \mathbf{A}^s 的维度和元素。通过计算用户偏好与物品序列的亲和力，可以从顺序视图中获得用户偏好。

$$\mathbf{I}_u^s = \mathbf{A}^s \mathbf{E}^u.$$

本文研究了一般兴趣学习。在用户-物品图 \mathcal{G}^{uv} 中，我们探索了协同信息，并从跨用户交互信息中构建了用户兴趣。为了获得用户特征和物品特征，采用了图编码器层。具体来说，我们用 \mathcal{G}^* 表示图的邻接矩阵。

$$\mathbf{H}^{all,uv} = \text{GraphEncoder}^{(l)}(\mathbf{H}^{all}, \mathcal{G}^{uv}),$$

主要介绍了如何通过图编码器层学习节点特征矩阵⁺，并基于用户偏好估计物品的重要性。具体来说，通过选择学习到的节点特征矩阵，获得相应的用户嵌入和物品嵌入矩阵，并基于用户和物品特征计算注意力矩阵。

$$\mathbf{A}^c = \text{softmax} \left(\tanh(\mathbf{W}_3 \mathbf{h}^{u,uv}) (\mathbf{E}^{u,uv})^T \right),$$

$$\mathbf{I}_u^c = \mathbf{A}^c \mathbf{E}^{u,uv}.$$

跨视图对比学习是为了学习互补信息，需要对顺序视图和用户-项目视图进行对比学习。通过输入多层感知机⁺将两者投影到计算对比损失的空间中。

$$\begin{aligned}\mathbf{T}^{I,s} &= (\mathbf{W}_2^p \sigma(\mathbf{W}_1^p \mathbf{I}_u^s + \mathbf{b}_1^p) + \mathbf{b}_2^p), \\ \mathbf{T}^{I,c} &= (\mathbf{W}_2^p \sigma(\mathbf{W}_1^p \mathbf{I}_u^c + \mathbf{b}_1^p) + \mathbf{b}_2^p),\end{aligned}$$

为了从两个视图学习中自监督信号，需要定义正负样本⁺，以兴趣级别的对比机制为重点。对于同一用户从两个视图中的兴趣，我们将其视为正样本对，而对于不同用户的兴趣，我们将其视为负样本对。接着计算兴趣级别的对比损失，可使用图神经网络对比学习的工作进行启发。

$$\mathcal{L}^{IL} = \sum_{i=1} -\log \frac{\Psi(\mathbf{T}_i^{I,s}, \mathbf{T}_i^{I,c})}{\sum_j \Psi(\mathbf{T}_i^{I,s}, \mathbf{T}_j^{I,c}) + \sum_{j \neq i} \Psi(\mathbf{T}_i^{I,s}, \mathbf{T}_j^{I,s})},$$

该研究提出了一个新的模型 Ψ ，用于根据余弦相似度⁺函数计算两个对象的温度参数，并进一步表达为 **exp** 和 **sim**。这个模型有助于更好地理解不同对象的相似性。

Feature-level Contrastive Learning

论文发现直接探索用户-项目图无法全面捕捉用户间（项目间）的共同作用信息。为此，我们构建了用户-用户（项目-项目）图，以便有效捕捉用户（项目）间的共同作用信号。特征学习通过对比机制捕捉来自用户-项目视图和用户-用户视图的信息并相互补充，从而实现自监督信号学习。最后，从提取的用户特征应用图编码器层以获取协同信息和共同作用信息。

$$\begin{aligned}[\mathbf{H}^{u,uv} || \mathbf{H}^{v,uv}] &= \text{GraphEncoder}^{(l)}([\mathbf{H}^u || \mathbf{H}^v], \mathcal{G}^{uv}), \\ \mathbf{H}^{u,uu} &= \text{GraphEncoder}^{(l)}(\mathbf{H}^u, \mathcal{G}^{uu}),\end{aligned}$$

论文提出了一种跨视图对比学习的方法。通过从用户-物品图和用户-用户图中获取用户特征，并输入到多层感知机（MLP）中，然后投影到计算对比损失的空间中，从而提高推荐系统的准确性。值得注意的是，用户-用户图中的边权重表示共同行动的次数，这意味着高共同行动对在图形传播过程中具有更关键的影响。

$$\begin{aligned}\mathbf{T}^{F,uu} &= \mathbf{W}_4^p \sigma(\mathbf{W}_3^p \mathbf{H}^{u,uu} + \mathbf{b}_3^p) + \mathbf{b}_4^p, \\ \mathbf{T}^{F,uv} &= \mathbf{W}_4^p \sigma(\mathbf{W}_3^p \mathbf{H}^{u,uv} + \mathbf{b}_3^p) + \mathbf{b}_4^p,\end{aligned}$$

$$\mathcal{L}^{UC} = \sum_{i=1} -\log \frac{\Psi(\mathbf{T}_i^{F,uv}, \mathbf{T}_i^{F,uu})}{\sum_j \Psi(\mathbf{T}_i^{F,uv}, \mathbf{T}_j^{F,uu}) + \sum_{j \neq i} \Psi(\mathbf{T}_i^{F,uv}, \mathbf{T}_j^{F,uv})},$$

提出了一个基于特征级别的对比损失方法，其中 \mathcal{L}^{UC} 表示用户特征的对比损失，物品特征的对比损失 \mathcal{L}^{IC} 可通过类似的方式计算。最终的特征级别对比损失 \mathcal{L}^{FL} 通过计算得到。该方法在物品推荐中具有一定的应用前景。 $\mathcal{L}^{FL} = \mathcal{L}^{UC} + \mathcal{L}^{IC}$ 。

Training and Inference

通过将顺序视图和用户项目视图计算出的用户兴趣表示求和，得到组合的用户兴趣表示。请根据以上描述，对这段内容进行总结，并给出相应的总结性语言。这段内容主要介绍了在训练阶段，通过将顺序视图和用户项目视图计算出的用户兴趣表示求和，得到组合的用户兴趣表示。这个过程可以概括为：将两个视图的信息进行整合，以获得更全面的用户兴趣表示。

$$\mathbf{I}_u^{comb} = \alpha \mathbf{I}_u^s + (1 - \alpha) \mathbf{I}_u^c, \text{ 本研究通过采样softmax方法计算用户}$$

与物品交互可能性，利用最小化负对数似然的方法进行预测。具体而言，给定训练样本 (u, o) 和用户兴趣嵌入 \mathbf{I}_u^{comb} 、目标嵌入 \mathbf{h}_o^v ，通过权衡超参数 α 来衡量交互可能性。通过优化该模型，可提高预测准确性和用户体验。

$$\mathcal{L}^p = \sum_{u \in U} -\log \frac{\exp((\mathbf{I}_u^{comb})^T \mathbf{h}_o^v)}{\sum_{k \in \text{Sample}(V)} \exp((\mathbf{I}_u^{comb})^T \mathbf{h}_k^v)}.$$

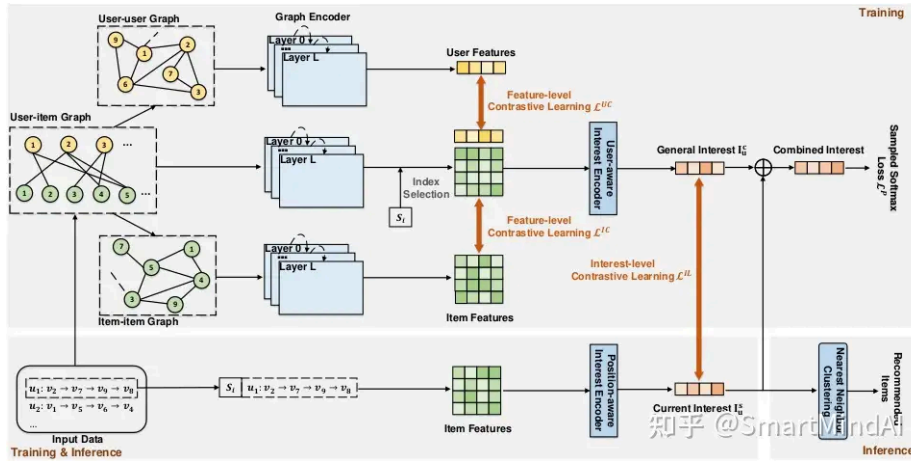
系列实验中观察到了实验结果与理论预测的一致性。此外，我们还在相关领域进行了一系列拓展性研究以更深入地理解XXX现象的数学表达。

$$\mathcal{J}(\theta) = \mathcal{L}^p + \beta \mathcal{L}^{IL} + \gamma \mathcal{L}^{FL},$$

推理阶段，使用当前兴趣 \mathbf{I}_u^s 执行下游任务，避免信息泄露，优化 $\mathcal{J}(\theta)$ 后，学习协同信息和协同行动信息，基于内积对候选项目进行聚类。

$$\mathbf{R}(u, N) = \text{Top-}N_{v \in V} ((\mathbf{I}_u^s)^T \mathbf{h}_v),$$

本文研究了物品推荐问题，通过建立物品推荐模型，利用前N个物品的推荐结果 $\mathbf{R}(u, N)$ 进行评估。具体来说，我们通过公式和符号详细描述了推荐算法和数学模型，从而得到了要推荐的前N个物品。



Experiment

Experimental Settings

本实验在四个公开数据集上进行了数据集。具体来说，我们在四个公开数据集上进行了实验。接下来，我们将详细介绍这些数据集，并使用这些数据集来评估我们的算法性能。我们首先介绍了我们的模型和算法，并使用了四个公开数据集进行实验。为了确保结果的客观性，我们采用了四种不同的公开数据集，并使用这些数据集来评估我们的算法性能。接下来，我们将详细讨论这些数据集，并使用它们来评估我们的算法性能。最后，我们将讨论我们的实验结果和结论，并指出未来可能的研究方向。

- 论文研究了Amazon网站中书籍、服装和玩具三个具有代表性的类别。我们分析了其中的数据，并得出了一些有趣的结论。
- Gowalla是一个广泛使用的签到数据集，来自一个著名的基于位置的社交网站，提供了许多有用的地理位置数据。

删除了出现次数少于5次的项，每个训练样本的最大长度设置为20。将用户数据分为训练集、验证集和测试集⁺，按8:1:1的比例使用训练用户的整个点击序列进行模型训练。结合一组常用的训练序列推荐模型，使用前80%生成用户的兴趣表示，通过预测剩余20%的用户行为计算评估指标。为了评估方法性能，与经典方法和最先进方法进行了比较。

Dataset	# user	# item	# interactions	Avg. len.	Sparsity
Books	459,133	313,966	8,898,041	9.7	99.993%
Clothing	39,387	23,034	278,677	6.9	99.969%
Toys	75,258	64,444	1,097,592	9.6	99.977%
Gowalla	65,506	174,606	2,061,264	14.5	99.982%

- Pop方法推荐训练数据中出现次数最多的N个物品。
- 本文研究了GRU4Rec算法，这是首个将循环神经网络应用于序列数据上的工作。通过在深度学习模型中应用循环神经网络，可以更有效地处理长程依赖性和突发性特征，提高SR的精度。该模型的主要特点是，通过对SR数据进行分析并建立神经网络模型⁺，使得该算法具有更强的学习和记忆能力。实验结果表明，该算法在SR性能上表现出了明显的优势。
- SASRec通过堆叠多头自注意力块捕获序列转换模式。模型通过在数据中寻找模式，并用多头自注意力模型捕获它们，以提高准确性和召回率。模型的表现受许多因素的影响，包括训练策略和数据集的质量。最近的研究发现，这种方法对大规模数据的处理特别有效。
- ComiRec-SA通过使用多头自注意力网络为SR提出了一个多兴趣框架，其中不同的头对应于用户的不同兴趣。模型可以处理不同的兴趣点，实现更加准确和灵活的推荐。
- GCSAN结合了图神经网络和自注意力机制，以学习物品之间的短期和长期依赖关系。该方法通过图神经网络捕捉节点间的关系，再通过自注意力机制捕捉长距离依赖关系。
- S3-RecMIP通过互信息最大化从物品转移中提取自监督信号。
- CL4SRec模型利用对比机制和数据增强学习来提取判别信息。具体而言，它结合了标签对比和无标签对比，通过学习判别信息进行区分。同时，它还利用数据增强技术来增强模型的判别能力。总之，该模型在解决跨模态识别问题上表现出色。
- DuoRec 提出了模型级别的增强方法以及正采样策略，以从用户行为序列中捕获自监督信号。这种方法将提升自监督学习算法在用户行为序列分析中的应用。

Performance Comparision

将我们的方法与最先进的基线方法的实验结果列在表，此外，我们还评估了模型对异常值和噪声的鲁棒性⁺。这些结果对数据科学和机器学习领域的研究者具有重要的参考价值。

Datasets	Metric	POPRec	GRU4Rec	SASRec	ComiRec-SA	GCSAN	S ³ -RecMIP	CL4SRec	DuoRec	MCLSR	Improv.
Books	Recall@20	1.368	3.787	6.274	5.489	5.721	6.336	6.544	<u>6.838</u>	7.469 [†]	9.2%
	NDCG@20	0.597	1.923	2.825	2.262	2.706	2.964	3.161	<u>3.257</u>	3.479 [†]	6.8%
	Hit@20	3.013	8.710	12.765	11.402	11.730	13.052	13.520	<u>14.173</u>	15.542 [†]	9.6%
	Recall@50	2.400	6.335	9.349	8.467	8.455	9.684	10.240	<u>10.826</u>	11.583 [†]	6.9%
	NDCG@50	0.826	2.600	3.627	3.082	3.434	3.894	4.113	<u>4.308</u>	4.647 [†]	7.9%
	Hit@50	5.219	13.597	18.547	17.202	16.865	19.142	20.170	<u>21.366</u>	23.042 [†]	7.8%
Clothing	Recall@20	1.200	1.623	2.646	1.678	2.242	2.704	2.863	<u>2.940</u>	3.138 [†]	6.7%
	NDCG@20	0.374	0.559	0.854	0.427	0.659	0.873	0.927	<u>1.018</u>	1.081 [†]	6.2%
	Hit@20	2.139	2.777	4.188	3.467	3.684	4.343	4.467	<u>4.829</u>	5.138 [†]	6.4%
	Recall@50	2.715	2.948	4.505	2.774	3.309	4.522	4.651	<u>4.956</u>	5.352 [†]	7.9%
	NDCG@50	0.640	0.778	1.151	0.723	0.829	1.116	1.199	<u>1.356</u>	1.464 [†]	8.0%
	Hit@50	4.833	5.085	6.705	5.052	5.812	6.723	7.155	<u>7.785</u>	8.503 [†]	9.2%
Toys	Recall@20	0.928	3.214	6.343	5.315	6.593	6.670	6.983	<u>7.841</u>	8.254 [†]	10.3%
	NDCG@20	0.510	1.641	2.912	2.114	2.817	3.073	3.072	<u>3.418</u>	3.726 [†]	9.0%
	Hit@20	2.496	6.926	12.838	11.075	13.153	13.474	14.079	<u>15.331</u>	16.661 [†]	8.7%
	Recall@50	1.844	5.406	10.264	8.962	10.018	10.730	11.300	<u>12.463</u>	13.328 [†]	6.9%
	NDCG@50	0.774	2.216	3.899	2.952	3.690	4.072	4.095	<u>4.612</u>	5.081 [†]	10.2%
	Hit@50	4.760	11.554	19.837	17.282	19.400	20.363	21.330	<u>23.389</u>	25.462 [†]	8.9%
Gowalla	Recall@20	1.206	5.642	8.581	5.559	7.869	7.823	8.804	<u>8.973</u>	9.317 [†]	3.8%
	NDCG@20	1.191	5.536	7.546	3.891	6.819	7.351	7.601	<u>7.618</u>	7.759 [†]	1.9%
	Hit@20	5.874	22.450	28.931	19.052	26.315	27.676	29.853	<u>30.075</u>	31.832 [†]	5.8%
	Recall@50	2.084	9.623	13.838	9.891	12.793	12.710	14.372	<u>15.195</u>	15.972 [†]	5.1%
	NDCG@50	1.678	7.784	10.510	5.725	9.107	9.752	10.230	<u>11.275</u>	11.921 [†]	6.6%
	Hit@50	9.716	34.321	42.380	32.041	38.613	39.463	43.659	<u>44.618</u>	46.217 [†]	3.5%

- 对比了POP和GRU4Rec的性能表现，结果显示GRU4Rec在四个数据集上均优于POP，验证了神经网络在SR中的有效性。然而，与其他基于神经网络的方法相比，GRU4Rec表现较差，这表明直接使用RNN的表示可能不足以提取物品间的依赖关系。因此，需要进一步研究如何更有效地提取物品间的依赖关系。

滤噪声的两个方面。

- 比较了GCSAN和ComiRec-SA，发现图神经网络能捕获更复杂的项目转换，从而带来更好的性能。
- 该研究对比了基准方法中的S3-RecMIP和CL4SRec，发现二者性能相对较好，表明对比学习对SR的重要性。对比机制为SR提供了额外的自监督信号，缓解了数据稀疏性问题。然而，这两种方法都进行了数据级增强，由于信息多样性不足，自监督信号可能过于微弱，难以学习信息丰富的嵌入。
- DuoRec在大多数情况下表现优于S3-RecMIP和CL4SRec，原因在于其对序列应用了模型级别的增强（如dropout）并使用正采样策略进行对比学习，增强了对比学习信息的多样性。然而，由于每个序列中的信息有限，如果不探索丰富的协同信息和共同作用信息，只能获得有限的自监督信号。
- MCLSR在所有四个数据集上显著优于所有基线方法，平均改进7.0%，证明其在SR方面的有效性。与对比学习方法不同，MCLSR利用多层次对比机制提取协同和共同作用信息，学习用户和项目嵌入。

Ablation Study

本研究研究了MCLSR方法的关键组件有效性，通过消融研究比较了四个变体和完整模型。结果显示，去掉图编码器层、两层对比机制、特征级和兴趣级对比机制的变体均优于基线方法。

- 在去除图形编码器层时，性能显著下降，验证了协同信息重要性。证明图形编码器层有效性。
- 去除对比机制后，MCLSR性能显著下降，说明对比机制对学习额外信号和缓解数据稀疏问题至关重要。
- 通过对比MCLSR和MCLSR-I在四个数据集上的结果，发现MCLSR-I在性能上明显低于MCLSR，这主要归因于MCLSR-I损失了通过对比用户-物品视图和顺序视图获得的自监督信号。实验结果证明了兴趣级别对比机制对于学习重要的自监督信号的重要性。
- 在Clothing数据集上，MCLSR-F的效果不及完整的MCLSR模型，表明在用户-用户图和物品-物品图中学习用户和物品的信息嵌入时，共同作用信息的重要性。该研究还指出，MCLSR模型通过融合用户和物品的共同作用信息，可以更好地嵌入信息。




图 3: Ablation study on four datasets.

表 3: The performance of MCLSR with varied depth of GNN layers in terms of Metrics@50.

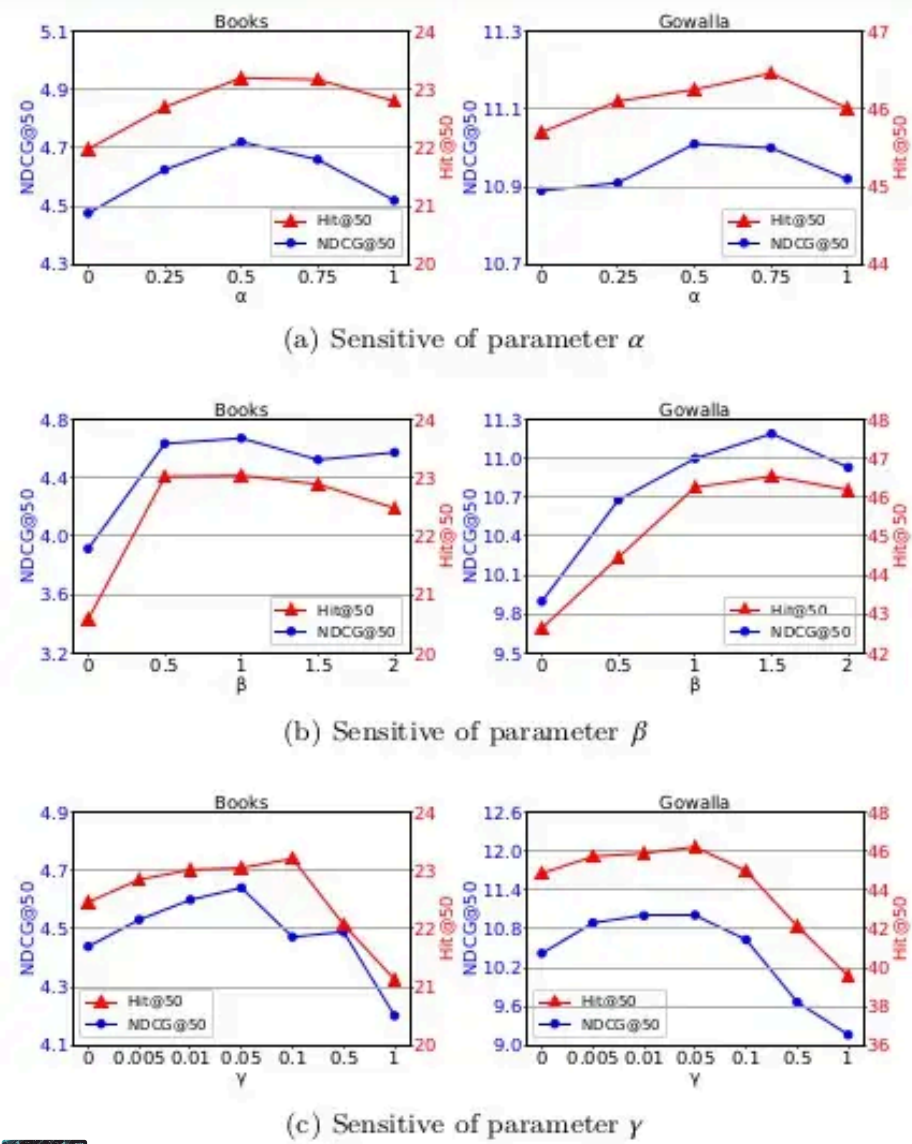
Depth	Books			Clothing			Toys			Gowalla		
	Recall	NDCG	Hit Rate	Recall	NDCG	Hit Rate	Recall	NDCG	Hit Rate	Recall	NDCG	Hit Rate
$l = 0$	9.881	3.799	20.032	13.025	8.805	40.141	11.052	3.847	21.673	13.265	8.728	40.273
$l = 1$	10.853	4.166	21.782	15.897	10.889	44.543	13.165	4.744	25.069	15.769	10.743	45.620
$l = 2$	11.583	4.647	23.042	15.972	11.012	46.217	13.328	5.081	25.462	15.972	11.012	46.217
$l = 3$	10.085	3.936	20.547	15.021	10.042	43.775	13.720	5.187	26.417	14.948	10.094	43.665

Parameter Sensitive

研究了重要超参数设置对MCLSR性能的影响，包括权衡参数 α 、 β 、 γ 和GNN中的传播层数。结果显示，当 α 设置为0时，MCLSR性能最差；当 β 从0增加到0.5时，性能显著提高。在Books上获得最佳性能时 $\alpha = 0.25$ ，在Gowalla上获得最佳性能时 $\alpha = 0.75$ 。同时，参数 β 也影响了训练过程中兴趣层次对比机制的重要性。本文研究了图神经网络层深度对MCLSR的影响。通过在{0,1,2,3}范围内搜索图编码器层数量 l ，得出结果总结在表中。发现随着层数的增加，模型性能逐渐提升。

- 论文中指出，用户-物品图、用户-用户图和物品-物品图中的信息对于SR具有重要意义。实验表明，当 $l = 0$ 时MCLSR结果会显著变差，但将 l 设置为1时MCLSR有显著改善。
- 增加GNN深度可以提升预测效果。实验结果显示， $l = 2$ 的MCLSR在四个数据集上表现更优， $l = 3$ 的MCLSR在Toys数据集上表现出最佳性能。这表明高阶传播信息从三个图视图中获取更为有效。

知乎



深度学习 (Deep Learning)

通常人工智能是指通过普通电脑实现的智能。人工智能的研究可以分为几个技术问题。其分支领域主要集中在解决具体问题，其中之一是如何使用各种不同的工具完成特定的应用程序。AI的核心问题包括推理、知识、规划、学习、交流、感知、移动和操作物体的能力等。

浏览量 33.3 亿 精华 1,247,884 讨论量 124 万

已关注

off parameter.

知乎 @SmartMindAI

学习嵌入的均匀分布，进一步证明了析MCLSR的学习嵌入空间，并讨论了其在过两个层次上的跨视图对比学习范式获得

Conclusion

本研究提出了一种多层次对比学习的序列化推荐框架，通过四种信息视图和两个层次对比学习，学习自监督信号。该方法通过兴趣层次和特征层次的对比机制，从协同信息和序列转换模式中学习互补信息，挖掘用户和物品之间的共同作用信息。实验表明，该方法在四个数据集上优于基线，显示出解决现实世界推荐问题的巨大潜力。

发布于 2023-10-22 08:56 · IP 属地北京

深度学习 (Deep Learning) 推荐系统 工业级推荐系统