

赞同 84

分享

2024美团：UpliftRec-精准评估推荐系统中用户兴趣探索的效果



SmartMindAI

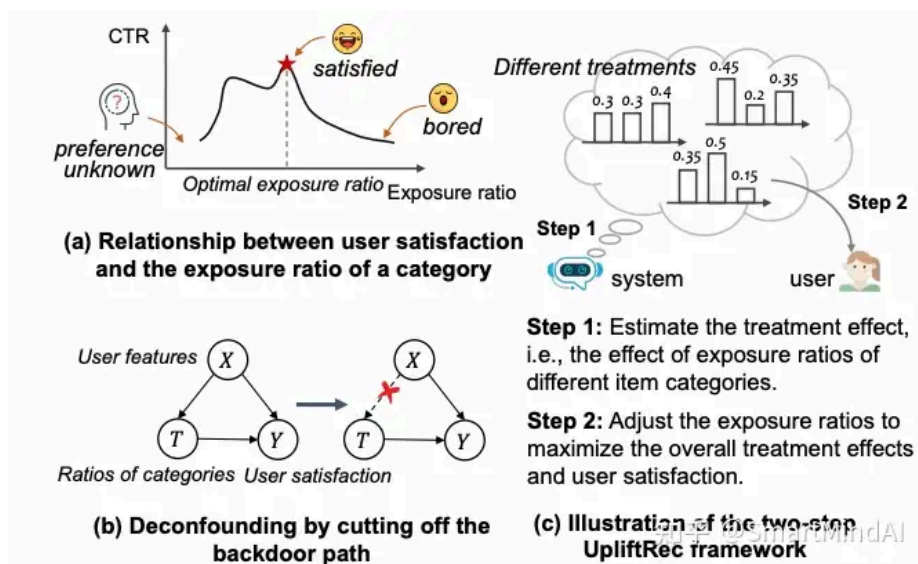
专注搜索、广告、推荐、大模型和人工智能最新技术，欢迎关注

已关注

84 人赞同了该文章

Introduction

推荐系统⁺在个性化信息推荐中使用用户行为反馈学习用户偏好，然而反馈可能存在偏见，忽视了潜在兴趣。为克服这个问题，本文聚焦于改进推荐模型，如偏差纠正、混合探索-利用策略和全局推荐策略。为了解决这些问题，本文提出了UpliftRec 框架，通过提升模型和动态规划⁺方法，旨在提供更有效且全面的用户兴趣探索，同时保持推荐的准确性和公正性，以打破“信息茧房⁺”和“回音室”现象，提升推荐准确性。



UpliftRec框架主要有以下三点：

- 1) 利用观测到的用户反馈进行效果估计，即使用ADRF方法，不依赖于用户个体水平，而是基于相似用户特征的组级效应来估算未暴露类别对用户潜在兴趣的影响，从而利用协同过滤⁺来探索用户的潜在兴趣。
- 2) 通过逆概率加权（IPW）技术，UpliftRec能有效地处理偏倚，实现无偏的ADRF估计。
- 3) 为应对数据规模的要求，我们采用分段处理连续探索并将其聚类⁺为紧凑的组，以高效利用有限的观测反馈数据。

PROBLEM FORMULATION

户潜在的兴趣反应。

用户兴趣探索任务在当今信息过剩的背景下，由推荐系统通过点击率来评估用户满意度。然而，受反馈偏见影响，实际兴趣可能未完全反映。我们关注的是量化各类别在不同曝光水平下（如图(a)所示）的实际点击率，这不仅是已知兴趣，还包括潜在兴趣。任务目标是精确预测这些点击率，以优化推荐策略，避免过度偏向已知兴趣，同时平衡各类别曝光，提升总体点击率和用户满意度。通过这样的方式，我们寻求在推荐的精确性和全面兴趣探索之间找到最佳平衡。

1. Average Click-Through Rate (ACRF):

$$\text{ACRF}(t_u) = \mathbb{E}[Y_u(t)|T_u = t_u]$$

这表示在用户 u 接收到特定时间 t 的曝光时，其点击率的期望值。 $Y_u(t)$ 表示用户在这一时刻的点击结果 T_u 是用户是否接受特定曝光的指示（比如曝光比例）。

1. Mean Treatment Effect for Exposure (MTEF):

$$\text{MTEF}(t) = \mathbb{E}[Y_u(t) - Y_u(0)|T_u = t]$$

MTEF计算的是在用户在时间 t 接受曝光后（相对于不接受曝光的基线），其点击率的平均差异。 $Y_u(0)$ 是在没有任何曝光情况下（即初始状态）的点击率。

通过这两个指标，我们能够精确量化各类别在不同曝光条件下的实际效果，进而优化推荐策略，确保既关注已有的兴趣，又发掘潜在的兴趣，提高推荐的全面性和用户满意度。

$$\begin{aligned} \text{ADRF}_u(t) &= \mathbb{E}[y_u(t)] \\ &= [\mathbb{E}[y_u(t_1)], \mathbb{E}[y_u(t_2)], \dots, \mathbb{E}[y_u(t_C)]] \\ &\triangleq [\text{ADRF}_u(t_1), \dots, \text{ADRF}_u(t_C)], \end{aligned}$$

这是用户 u 在给定曝光探索 t 下每个类别的平均点击率期望，用ACRF（Average Causal Response Function）来表示：

$$\text{ACRF}(t_u) = \mathbb{E}[Y_u(t)|T_u = t_u]$$

这里的 \mathbb{E} 表示期望值 $Y_u(t)$ 是用户 u 在所有类别都接受曝光比例为 t 时的点击率向量。ACRF计算的是在特定处理下，用户实际可能的点击行为的平均结果。这个概念在理解推荐系统中各类别的影响以及如何根据用户偏好调整推荐策略时非常重要。

$$\begin{aligned} \text{MTEF}_u(t) &= \frac{\mathbb{E}[y_u(t + \Delta t)] - \mathbb{E}[y_u(t)]}{\Delta t} \\ &= \frac{\text{ADRF}_u(t + \Delta t) - \text{ADRF}_u(t)}{\Delta t}, \end{aligned}$$

在 t 附近的曝光探索梯度近似（ADRFA, Average Direct Response Function Around Treatment），我们用 Δt 表示 t 的变化范围，表达式如下：

$$\text{ADRFA}(\Delta t) = \frac{\partial}{\partial t} \mathbb{E}[Y(t)|T = t]$$

其中 $\frac{\partial}{\partial t}$ 表示关于 t 的导数，表示随着曝光比例变化，点击率的微小变化。基于ADRFA，我们可以将寻找最优曝光比例的问题转化为一个约束优化问题：

$$\min_{\Delta t} \quad \text{ADRFA}(\Delta t)$$

这本质上是在寻找一个能使点击率曲线接近平坦（最小斜率）的曝光增量，这样可以确保在有限的资源下，提高用户满意度的同时，最大化总点击量。通过解决这个优化问题，我们能够确定最佳的曝光策略分布，以达到最优的推荐效果。

$$s.t. \quad \sum_{c=1}^C t_c = 1; t_c \geq 0; \\ \sum_{c=1}^C |t_c - t_{0,c}| \leq \epsilon,$$

1. 因果可观察性假设：我们假定模型能够精确捕捉到用户对不同类别兴趣的因果关系，这使得点击行为成为兴趣程度的直接指标。
2. 随机独立同质性假设：认为用户对各类别的反应是独立的，且不受未曝光类别干扰，保证了分析的准确性。
3. 有限暴露空间限制：我们限定曝光比例变化的范围，确保推荐策略在实际操作中是可行的。
4. 长期影响考虑：尽管短期效果可能不明显，但MTEF能揭示长期来看最有利的曝光策略。
5. 稳定环境假设：推荐系统运行在一个相对稳定的环境中，排除了外部干扰对结果的显著影响。

基于这些假设，我们能够在优化模型的同时，保证推荐的个性化和有效性，同时确保用户体验的连续性和一致性。

Method

Treatment Effects Estimation

1. 用户历史记录：我们基于用户过去的 λ 次交互行为。
2. 探索数据：剩下的 $(1 - \lambda)$ 次交互中指向特定类别的部分。
3. 响应指标：这些点击情况，即CTR (Click Through Rate)。

通过对用户过去交互和探索数据的分析，我们利用这些信息来估计每个用户在不同类别下的ADRFA，这是优化决策的基础。这有助于我们深入了解用户在不同曝光情境下的点击行为模式，进而优化推荐策略。




Figure 2: Illustration of generating a sample out of a real interaction trail, including history and treatment&outcome.

- 用户的历史交互记录 D_u 实际上对应于用户样本 \hat{D}_u 中的最初 λ 次行为。这些行为数据⁺构成了用户早期行为模式的图谱，反映了他们在未接触特定探索（曝光）之前的偏好和习惯。
- 探索 T_u 涉及的是对用户 \hat{D}_u 中从第 $\lambda + 1$ 次交互开始的类别曝光，这些是用户在接触特定类别后的互动。我们通过分析用户在这些后期交互中的类别选择来确定每个用户的曝光比率。
- 潜在结果 $Y_u(t)$ 代表用户 \hat{D}_u 在后 λ 次交互中（无论针对所有类别）的实际点击率。点击率（CTR, Click Through Rate） c 则是计算方法：对于类别 c ，计算其正向项目（即点击）数量除以该类别所有被曝光项目总数。

当面临推荐数据集不明确商品类别的情况时，我们先通过K-means聚类⁺技术，利用物品的嵌入（通常由推荐模型生成）对物品进行无标签的分组。这样，在生成增强数据集之前，我们就预先对物品进行了非监督的类别划分，以便后续处理。

混淆因子修正：在探究用户交互与结果因果关系时，潜在的混淆因子（如用户特性 \mathbf{X} ）可能导致偏差，如图(b)所示。为克服这一问题，我们应用IPW (Inverse Propensity Weighting) 方法进行校正。IPW不是简单地计算单一物品的倾向得分，而是聚焦于估计给定用户特征 \mathbf{x} 时接受特定探索 t 的条件概率⁺ $P(t|\mathbf{x})$ ，即用户选择该探索的倾向。

通过计算加权和：

$$\text{Debiased ADRF}_{u,c} = \frac{\sum_t w_t(y_{c,t}, \mathbf{x})}{\sum_t w_t(\mathbf{x})}$$

期估计。这种方法确保了因果关系的准确估计。

$$\begin{aligned}\text{ADRF}(t_c) &= \mathbb{E}[y(t_c)] = \sum_x P(y|t_c, x)P(x) \\ &= \sum_x \frac{P(y, t_c|x)}{P(t_c|x)} P(x) \\ &= \mathbb{E}_x \left[\frac{P(y, t_c|x)}{P(t_c|x)} \right].\end{aligned}$$

通过引入逆概率 $P(t_c|x)$ ，我们避免了从处理 T_c 到结果 Y 的因果链⁺。然而，面对数据稀疏性问题，直接用多层感知器⁺（MLP）估计 $P(t_c|x)$ 是个挑战。因此，我们采用了聚类方法来解决。

首先，我们利用用户历史交互数据学习真实用户及其对应的增强样本。这通过获取用户嵌入来实现。接着，我们计算每个真实用户与这些增强样本的余弦⁺相似性，找到最接近的前 K_p 个样本。这些样本的处理暴露比例用于估算 $P(t|x)$ 。

为了处理数据的稀疏性，我们将连续的分类暴露分布划分为 K 个离散区间，这样 $P[c][t_c]$ 表示的是类别 c 落在 t_c 区间内的概率。这种方法通过将复杂度降低到一个 $C * (K + 1)$ 矩阵，有效地处理了稀疏性问题，提高了 $P(t|x)$ 的估计准确性。

$$P[c][t_c] = \frac{\sum_{j=1}^{K_p} \mathbb{I}(\text{Dis}(t_{u_j}) = t_c)}{K_p},$$

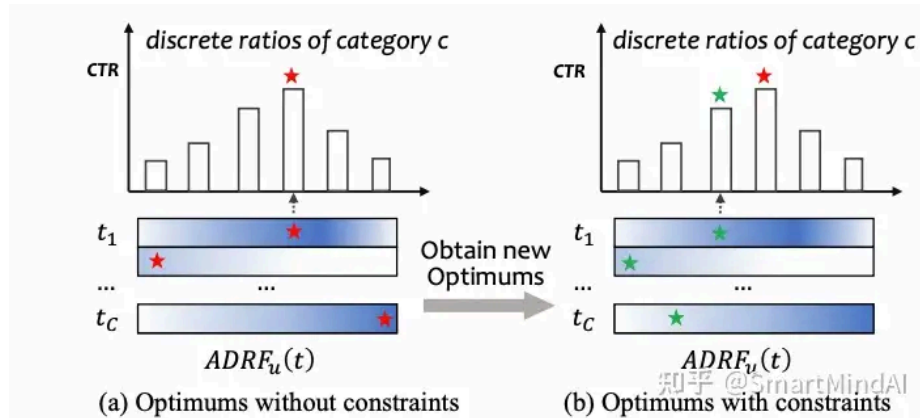
$$c = 1, 2, \dots, C; t_c = 0, 1, \dots, K,$$

其中 Dis 代表的是一个将连续曝光比例 T 转换为离散形式 T 的映射函数。为克服可能的溢出问题，当 $P(t|x)$ 的估计超出阈值 v_p 时，我们采用了一个限制机制。这样做的目的是保持估计结果的合理性，避免因数值过大而引起的不准确或误导性的结果。

在计算ADRF（Average Daily Return on Clicks for Ads，广告日点击回报率）时，我们首先利用离散化函数 Dis 处理曝光比例 T ，然后构建 $C \times (K + 1)$ 的矩阵。 C 是类别数量 K 是处理的最大离散级别。我们用背包问题⁺的思路来优化，因为这允许线性时间求解最佳曝光分配。

我们考虑每个类别的离散化⁺处理 \tilde{t}_c ，目标是在满足 $\sum_{c=1}^C \tilde{t}_c = K$ 的条件下最大化前 N 个推荐列表中所有项目的点击率总和。为了获得这个估计，我们利用前 K_s 个最相关样本的平均结果 y_{u_j} 和它们的逆倾向得分 $P(t_c|x_{u_j})^\gamma$ 。具体操作是通过加权平均来计算 $\text{ADRF}[c][k]$ ，这里 γ 可能是调整参数，用来控制逆概率的影响力：

$$\text{ADRF}[c][k] = \frac{\sum_{j=1}^{K_s} y_{u_j} P(t_c|x_{u_j})^\gamma}{\sum_{j=1}^{K_s} P(t_c|x_{u_j})^\gamma}$$



这个过程旨在综合考虑了用户特征和倾向得分，同时通过离散化处理和背包问题的优化，确保了ADRF估计的准确性和有效性。

$$c = 1, 2, \dots, C; t_c = 0, 1, \dots, K,$$

在ADRF的计算中, 我们用 $t_{u,j}$ 和 $y_{u,j}$ 分别表示用户样本 j 的处理量和点击率 P 是倾向得分矩阵 γ 调节逆概率的权重。矩阵ADRF以 $C \times (K + 1)$ 结构表示, 其中第一列初始化为0, 代表未曝光的类别点击率默认为0。

对于缺失的处理-结果数据, 我们用填充值 v_a 填充, 确保矩阵完整性。这意味着对于那些没有观察到的数据点ADRF $[c][k]$ 将用 v_a 代替, 这样所有位置都能被有效处理。通过这种方式, 我们在估计ADRF时既保持了数据的完整, 又利用了已有的倾向得分信息。

Fetching the Best Treatment

与注重单个预测精度的算法相比, 我们的顶级-N推荐系统视作资源分配问题。首先, 我们计算每个用户的真实ADRF。接着, 我们将问题转化为背包模型, 运用动态规划算法⁺求解。为此, 我们引入新矩阵 f $f[c][k]$ 表示前 c 类分配 k 曝光单位后可能达到的最大点击率。状态转移方程⁺定义为:

$$f[c][k] = \max_{0 \leq j \leq k} \{ \text{ADRF}[c][j] \times P[c][j] + f[c-1][k-j] \times (1 - P[c][j]) \}$$

其中 $P[c][j]$ 是第 c 类在第 j 个位置的倾向得分ADRF $[c][j]$ 是对应位置的点击率预期。此方程表示在资源有限(k)的情况下, 通过动态分配, 最大化总点击率。通过动态规划, 我们找到最优化的类别分配策略, 为每个用户定制推荐。

$$f[c][k] = \max_{|t_{0,c}-j| < \epsilon} (f[c-1][k], f[c-1][k-j] + j * \text{ADRF}[c][j]), c = 1, 2, \dots, C; k = 0, 1, \dots, K,$$

其中 t_0 表示实际推荐列表的类别分布 ϵ 是对后端推荐分布允许的最大误差。 $f[C][K]$ 是我们追求的最大总体点击率目标。通过遍历 f 矩阵从 $[C][K]$ 到其他位置的路径, 我们找到最优的处理策略, 即优化推荐列表。这种方法被称为UpliftRec-ADRF。

动态规划算法因其时间效率高, 以 $O(CK\epsilon)$ 的时间复杂度⁺处理, 避免了随数据量增大呈指数级增长的问题。这意味着无论数据规模如何增加, 算法都能保持良好的运行性能。

MTEF Approximation

ADRF方案的一个主要挑战是面对数据稀疏性带来的高方差问题。为此, 我们提出了MTEF (Modified Tapered Estimation of Fidelity) 方法, 这是一种简化版的ADRF。MTEF通过近似梯度来减少稀疏数据的影响。我们理解, 远离后端推荐列表 t_0 的处理 t , 模型的方差可能会显著增加。因此, 我们利用接近 t_0 的处理效果进行微调。MTEF以 t_0 的局部信息为基础, 通过计算 $\frac{\partial y(t_0)}{\partial t}$ 的离散形式, 它代表在 t_0 附近增加曝光对各类别的潜在点击率影响, 来降低这种影响。这样, 即使数据稀疏, 也能提供更稳定和准确的估计。

$$\text{MTEF}(t) = \frac{\mathbb{E}[y(t+\Delta t)] - \mathbb{E}[y(t)]}{\Delta t}$$

在每 Δt 步长⁺的采样间隔中, 如果存在空值, 我们会用 v_m 来填充。重要的是, 每个用户特定的ADRF和MTEF都是个性化的。为了简化, 我们不在此处展示具体下标。计算了MTEF后, 我们将这个量结合后端模型的原始分数, 生成最终的得分。

$$s_{u,i} = s_{0,u,i} + \alpha * \text{MTEF}(t_0)[c_i]$$

其中, $s_{0,u,i}$ 代表用户 u 对项目 i 的初始后台评分 α 是控制MTEF影响的调整参数。项目 i 属于的类别用 c_i 表示。我们采用的方法, UpliftRec-MTEF, 是通过将MTEF与 $s_{0,u,i}$ 相加来改进推荐, 以此生成用于策略优化的综合评分。

Experimental Settings

Datasets

映了真实的用户行为和偏好。

Table 1: Statistics of the three datasets. "int." denotes "interactions". "TP." denotes "Training Positive". "TN." denotes "Training Negative".

| Dataset | #User | #Item | #TP. int. | #TN. int. | Density |
|----------|-------|-------|-----------|-----------|---------|
| Yahoo!R3 | 15.4K | 1.0K | 125.1K | 167.9K | 1.9% |
| Coat | 290 | 300 | 1.9K | 5.1K | 8.0% |
| KuaiRec | 7.1K | 10.7K | 936.5K | 11.6M | 15.5% |

Evaluation Metrics

在评估模型性能时，我们使用了两种常见的精确度指标：Recall@K ($R@K$) 和NDCG@K。此外，为了评价模型发掘潜在兴趣的能力，我们引入了两个额外的指标：1. Hit Rate@K ($HR@K$): $HR@K$ 计算的是模型在前K个推荐中准确找到目标项的比例，即实际目标项被成功推荐的比例。2. Average Discounted Cumulative Gain (DCG): DCG是一种衡量推荐排序质量的指标，它对推荐结果的评分按照重要性递减给予折扣，越靠后的推荐得分越少。 $D@K$ 代表在前K个推荐中的累积得分与按真实兴趣排序的理想情况下的最大得分之比，以此评估模型对重要性和新颖性的综合表现。

- 实验中，我们还引入了RUE@K这一独特指标，它关注的是在前K个推荐中，那些不在用户前三次交互行为中但属于非热门类别的新发现项的召回率⁺。由于Yahoo!R3数据集未提供类别标签，所以无法直接应用此指标进行评估。RUE@K衡量了模型在推荐中发现新颖且非热门内容的的能力，这对于评估模型的创新性和用户惊喜体验至关重要。
- 实验中，我们定义了一个新的评估指标，称为RUP@K，它代表了在前K个推荐列表中，用户未接触过且非热门类别的项的召回率。RUP关注的是模型推荐中冷门内容的挖掘能力。由于Yahoo!R3数据集不提供类别标签，这个指标无法直接应用，但它对于评估模型在发掘潜在兴趣和避免过度推荐热门项的平衡性非常有帮助。

Overall Performance (RQ1)

在三个不同的数据集上，UpliftRec-MTEF都保持着显著领先，特别是在 $R@10$ 和 $N@10$ 的评估中，它的表现无可比拟，这强调了其在预测用户兴趣和提高推荐精度方面的卓越能力。尤其值得注意的是，UpliftRec在RUE@10和RUP@10上的优异表现，这反映了其挖掘潜在非热门兴趣领域的强大力量。RUE@10的上升意味着推荐了用户鲜有接触的商品类别，而RUP@10的增长则意味着增加了用户发现和接触冷门商品的机会。这些数据显示，UpliftRec-MTEF在对抗推荐系统的热门商品偏倚和忽视冷门商品的问题上具有显著效果。

| Dataset Metric | Yahoo!R3 | | | Coat | | | | KuaiRec | | | |
|----------------------|----------|---------|---------|---------|---------|---------|---------|---------|---------|---------|---------|
| | R@10 | N@10 | RUP@10 | R@10 | N@10 | RUE@10 | RUP@10 | R@10 | N@10 | RUE@10 | RUP@10 |
| Random | 0.0093 | 0.0044 | 0.0110 | 0.0307 | 0.0212 | 0.0321 | 0.0327 | 0.0009 | 0.0066 | 0.0010 | 0.0009 |
| MF | 0.0621 | 0.0338 | 0.0735 | 0.0705 | 0.0397 | 0.0636 | 0.0751 | 0.0870 | 0.2741 | 0.0949 | 0.0875 |
| FM | 0.0532 | 0.0267 | 0.0630 | 0.0875 | 0.0416 | 0.0836 | 0.0932 | 0.0468 | 0.1629 | 0.0498 | 0.0470 |
| LightGCN | 0.0614 | 0.0299 | 0.0727 | 0.0796 | 0.0374 | 0.0777 | 0.0848 | 0.0797 | 0.2417 | 0.0877 | 0.0802 |
| IPS | 0.0606 | 0.0325 | 0.0717 | 0.0686 | 0.0309 | 0.0734 | 0.0730 | 0.0886 | 0.2666 | 0.0983 | 0.0891 |
| BC Loss | 0.0694 | 0.0360 | 0.0822 | 0.0819 | 0.0357 | 0.0702 | 0.0873 | 0.0487 | 0.1465 | 0.0464 | 0.0490 |
| iDCF | 0.0675 | 0.0335 | 0.0799 | 0.0755 | 0.0336 | 0.0692 | 0.0804 | 0.0346 | 0.0346 | 0.038 | 0.0348 |
| MMR | 0.0557 | 0.0314 | 0.0660 | 0.0821 | 0.0380 | 0.0730 | 0.0874 | 0.0784 | 0.2616 | 0.0864 | 0.0789 |
| PMF- σ, β | 0.0567 | 0.0301 | 0.0671 | 0.0385 | 0.0214 | 0.0398 | 0.0410 | 0.0787 | 0.2550 | 0.0869 | 0.0792 |
| LinUCB | 0.0610 | 0.0332 | 0.0723 | 0.0571 | 0.0315 | 0.0712 | 0.0608 | 0.0777 | 0.2235 | 0.0924 | 0.0721 |
| HCBC | 0.0347 | 0.0168 | 0.0411 | 0.0683 | 0.0425 | 0.0791 | 0.0728 | 0.0914 | 0.2630 | 0.0862 | 0.0781 |
| UpliftRec-MTEF | 0.0715* | 0.0363* | 0.0847* | 0.1027* | 0.0504* | 0.0984* | 0.1093* | 0.0914* | 0.3169* | 0.0999* | 0.0920* |

原文《Treatment Effect Estimation for User Interest Exploration on Recommender Systems》


发布于 2024-06-06 10:49 · IP 属地北京

uplift 工业级推荐系统



理性发言，友善互动

知乎




Wendy

请问是怎么从茫茫paper海中找到这篇文章?

06-06 · 北京

回复

3



SmartMindAI 作者


是有什么问题吗?

06-06 · 北京

回复

喜欢

推荐阅读



团购运营中最容易被忽略的数据指标：点击率 | 美团点评

小橙小橙 发表于如何做好美...



实例分享：一文详解美团数据指标体系搭建！

Pytho... 发表于Pytho...



美团IPO：重构超级平台

李成东 发表于李成东的互...



超干货：最新的美团&点评人气榜的【上榜攻略】

乘嘉先生T... 发表于美团